

Goethe Universität
Frankfurt am Main

EduTec
Educational Technologies

The present work was submitted to Lehr- und Forschungsgebiet Educational Technologies at DIPF

Span-based Classifier for Short Answer Scoring and Beyond

Masterarbeit

Vorgelegt von

al Mahdi, Malaz

8053932

Erstgutachter:	Prof. Dr. Hendrik Drachsler
Zweitgutachter:	
Betreuung:	Zhifan Sun (DIPF)

Frankfurt, 11. Oktober 2026

Bitte dieses Formular zusammen mit der Abschlussarbeit abgeben!

Erklärung zur Abschlussarbeit

gemäß § 35, Abs. 16 der Ordnung für den Masterstudiengang Informatik vom 13. Juli 2015

Hiermit erkläre ich

_____

(Nachname, Vorname)

Die vorliegende Arbeit habe ich selbstständig und ohne Benutzung anderer als der angegebenen Quellen und Hilfsmittel verfasst.

Ebenso bestätige ich, dass diese Arbeit nicht, auch nicht auszugsweise, für eine andere Prüfung oder Studienleistung verwendet wurde.

Zudem versichere ich, dass die von mir eingereichten schriftlichen gebundenen Versionen meiner Masterarbeit mit der von mir eingereichten elektronischen Version der Masterarbeit übereinstimmen.

Frankfurt am Main, den

_____

Unterschrift der/des Studierenden

Danksagung

Mein Dank gilt Prof. Dr. Hendrik Drachsler für die Möglichkeit, diese Arbeit zu schreiben, und für ihre Begutachtung.

Zhifan Sun danke ich für die engagierte Betreuung, die zahlreichen Diskussionen und die hilfreichen Rückmeldungen während der gesamten Arbeit.

Schließlich danke ich meiner Familie und meinen Freunden für ihre Unterstützung.

Zusammenfassung

Die automatische Bewertung kurzer Schülerantworten (Automatic Short Answer Grading, ASAG) muss mit Bewertungsskalen umgehen, die sich zwischen Aufgaben unterscheiden. Das rubrik-geleitete Span-Alignment begegnet dem, indem es die Rubrikstufen als Textabschnitte in die Eingabe des Modells legt und eine Antwort durch den Abgleich mit jeder Stufe bewertet; dadurch kann ein einziges Modell Aufgaben mit unterschiedlich vielen Stufen verarbeiten. Diese Arbeit überträgt einen solchen span-basierten Klassifikator auf Decoder-only-Sprachmodelle (Llama-3.2-1B, Llama-3.2-3B und Mistral-7B, angepasst per LoRA-Finetuning) und evaluiert ihn auf ASAP-SAS, Beetle und SciEntsBank unter den Bedingungen ungesehener Antworten, Fragen und Domänen. Sämtliche Vergleiche beruhen auf drei Zufallssaaten und werden unter zwei Metriken gegen eine empirisch bestimmte Rauschgrenze geprüft, deren Median von $0{,}036$ QWK die meisten der untersuchten Architekturunterschiede übersteigt.

Gegenüber einem festen Klassifikationskopf bei identischer Eingabe liegt das Span-Alignment nur mit dem kleinsten Backbone vorn, auf Beetle um $0{,}088$ QWK. Entscheidend ist die Eingabe: Ohne jede aufgabenbezogene Information sinkt die Leistung um bis zu $0{,}528$ QWK, während sich die Rubriktexte als austauschbar mit Frage und Musterlösung erweisen. Ein auf ASAP-SAS trainiertes Modell lässt sich ohne Anpassung auf andere Benchmarks anwenden, erreicht dort aber nur Zufallsniveau. Decoder-only-Modelle lassen sich ohne Änderung ihrer Architektur an das Span-Alignment anpassen. Die Wahl des Fusionsmechanismus und der Bezugsgröße bleibt ohne nachweisbare Wirkung, während die Aufhebung der kausalen Attention-Maske die Leistung erheblich verändert, mit einem vom Benchmark abhängigen Vorzeichen. Auf ungesehenen Fragen übertreffen die Decoder-Modelle die Encoder-Vergleichsmodelle deutlich. Insgesamt deuten die Ergebnisse darauf hin, dass es beim rubrik-geleiteten ASAG vor allem darauf ankommt, welche Information das Modell erhält, und weniger darauf, wie sie architektonisch verarbeitet wird.

Abstract

Automatic short answer grading (ASAG) has to cope with scoring scales that differ between tasks. Rubric-guided span alignment addresses this by placing the rubric levels as text spans in the model input and scoring an answer by aligning it with each level, so that a single model can process tasks with different numbers of levels. This thesis transfers such a span-based classifier to decoder-only language models (Llama-3.2-1B, Llama-3.2-3B and Mistral-7B, fine-tuned with LoRA) and evaluates it on ASAP-SAS, Beetle and SciEntsBank under unseen-answer, unseen-question and unseen-domain conditions. All comparisons rest on three random seeds and are tested under two metrics against an empirically determined noise threshold, whose median of 0.036 QWK exceeds most of the architectural differences investigated.

Compared with a fixed classification head on identical input, span alignment is ahead only with the smallest backbone, by 0.088 QWK on Beetle. The decisive factor is the input: without any task-related information, performance drops by up to 0.528 QWK, whereas the rubric texts turn out to be interchangeable with question and reference answer. A model trained on ASAP-SAS can be applied to other benchmarks without adaptation but reaches only chance level there. Decoder-only models can be adapted to span alignment without architectural changes. The choice of fusion mechanism and of the anchor representation has no demonstrable effect, whereas removing the causal attention mask changes performance considerably, with a sign that depends on the benchmark. On unseen questions, the decoder models clearly outperform encoder baselines. Overall, the results indicate that rubric-guided ASAG depends mainly on which information the model receives rather than on how this information is processed architecturally.

Inhaltsverzeichnis

1 Einleitung **1**
- 1.1 Motivation . . . 1
- 1.2 Problemstellung . . . 2
- 1.3 Forschungsfragen . . . 3
- 1.4 Aufbau der Arbeit . . . 3

2 Grundlagen **5**
- 2.1 Automatic Short Answer Grading (ASAG): Aufgabendefinition . . . 5
- 2.2 Evaluationsmetriken im ASAG . . . 8
- 2.3 Encoder-basierte Ansätze im ASAG . . . 13
- 2.4 LLM-basierte Ansätze im ASAG . . . 15
- 2.5 Rubrik-geleitetes Scoring: Guided-Alignment-Architekturen . . . 16
- 2.6 Grundlagen der Transformer-Architektur . . . 18
  - 2.6.1 Self-Attention und Multi-Head Attention . . . 19
  - 2.6.2 Kausale vs. bidirektionale Attention-Masken . . . 21
- 2.7 Parameter-effizientes Finetuning (LoRA) . . . 23
- 2.8 Fusionsmechanismen im Rubrik-Antwort-Alignment . . . 24

3 Datensätze **27**
- 3.1 ASAP-SAS: Struktur, Statistik, Label-Skala . . . 27
- 3.2 Beetle: Domäne und Test-Splits . . . 29
- 3.3 SciEntsBank: Domäne und Test-Splits . . . 30
- 3.4 Herkunft der Rubriktexte und Musterlösungen . . . 31
- 3.5 Vergleich der Benchmarks und Auswahlbegründung . . . 32

4 Methodik: Das RUSPAN-System **35**
- 4.1 Systemarchitektur: Span-Alignment-Modell . . . 35
  - 4.1.1 Eingabeformat . . . 36
  - 4.1.2 Span-Extraktion und Pooling . . . 37
- 4.2 Fusionsmechanismen . . . 39
  - 4.2.1 CONDIFF: Conditional-Difference-Fusion . . . 40
  - 4.2.2 CONCAT: Einfache Konkatenation als Baseline . . . 40
  - 4.2.3 DIFF: Differenz als alleinige Eingabe . . . 40
  - 4.2.4 GATE: Gated Fusion . . . 41

4.3 Bidirektionale Attention in Decoder-only-Modellen . . . 43
4.3.1 Motivation . . . 43
4.3.2 Umsetzung: Anteilige Aufhebung der kausalen Maske . . . 43
4.4 Verwendete Backbone-Modelle . . . 45
4.4.1 Llama-3.2-1B/3B . . . 45
4.4.2 Mistral-7B . . . 46
4.4.3 BERT/RoBERTa als Encoder-Baseline . . . 46
4.5 Varianten für die Ablationsexperimente . . . 46
4.5.1 Fester Klassifikationskopf als Baseline . . . 46
4.5.2 Ablation der Rubriktexte . . . 47
4.5.3 Variation des Aufgabenkontexts . . . 47
4.5.4 Antwort-Span als Bezugsgröße der Fusion . . . 47
4.5.5 Übertragung zwischen Benchmarks . . . 48
4.6 Trainingskonfiguration . . . 48

5 Experimente und Ergebnisse 53
5.1 Experimentelles Design . . . 53
5.2 Rauschgrenze: Streuung zwischen Läufen . . . 55
5.3 RQ1: Span-Alignment gegenüber den Vergleichsbedingungen . . . 58
5.3.1 Span-Alignment gegenüber einem festen Klassifikationskopf . . . 58
5.3.2 Der Beitrag aufgabenbezogener Information . . . 60
5.3.3 Encoder- gegenüber LLM-basierten Ansätzen . . . 65
5.3.4 Übertragung zwischen Benchmarks . . . 66
5.4 RQ2: Anpassung von Decoder-only-Modellen . . . 68
5.4.1 Fusionsmechanismen . . . 68
5.4.2 Bezugsgröße der Fusion . . . 71
5.4.3 Attention-Maske . . . 72
5.4.4 Effekt der Modellgröße . . . 76
5.5 Ergänzende Analysen . . . 78
5.5.1 Ergebnisse je Aufgabe auf ASAP-SAS . . . 78
5.5.2 Instabile Läufe . . . 79
5.5.3 Robustheit gegenüber der Metrik . . . 81
5.6 Zusammenfassung der Befunde . . . 84

6 Diskussion 87
6.1 Beantwortung der Forschungsfragen . . . 87
6.2 Einordnung in die Forschung . . . 90
6.3 Methodische Implikationen . . . 91
6.4 Limitationen . . . 92
6.5 Implikationen für die Praxis . . . 93

7 Fazit und Ausblick 95
7.1 Fazit . . . 95
7.2 Ausblick . . . 96

Tabellenverzeichnis 99

Abbildungsverzeichnis **103**

Literatur **105**

Appendices **111**

1 Einleitung

1.1 Motivation

Kurze, frei formulierte Antworten sind ein verbreitetes Instrument, um fachliches Verständnis zu erfassen. Anders als Auswahlaufgaben verlangen sie, dass Lernende einen Sachverhalt selbst erinnern oder erschließen und in eigenen Worten darstellen. Diese Stärke hat einen Preis: Jede Antwort muss einzeln gelesen und gegen die Bewertungskriterien abgeglichen werden, und der Aufwand wächst mit der Zahl der Lernenden. Gerade in großen Lerngruppen erschwert dies zeitnahe Rückmeldungen. Automatic Short Answer Grading (ASAG) zielt darauf, diese Bewertung maschinell zu unterstützen, und ist seit Langem ein eigenständiges Forschungsfeld der Bildungstechnologie [5, 2].

Methodisch hat sich das Feld von manuell konstruierten Merkmalen über vortrainierte Encoder-Modelle wie BERT [13] hin zu großen Sprachmodellen entwickelt, die eine Antwort auf Grundlage eines Prompts bewerten [29, 7]. Für den Einsatz in der Bildungspraxis stellen sich dabei zwei Anforderungen, die in der Forschung bislang getrennt behandelt werden.

Die erste betrifft den Datenschutz. Schülerantworten sind personenbezogene Daten, sofern sie einer identifizierbaren Person zugeordnet werden können, und die Daten von Kindern genießen besonderen Schutz [18, Art. 4 Nr. 1 und Erwägungsgrund 38]; auch Leitlinien zum Einsatz generativer KI im Bildungsbereich betonen entsprechende Schutzpflichten [56]. Die Übermittlung von Antworten an externe Modellanbieter ist daher problematisch, und ASAG-Systeme sollten lokal betreibbar sein. Lokal betriebene generative Modelle ausreichender Größe sind jedoch rechenintensiv. Eine Alternative eröffnet eine jüngere Forschungslinie, die Decoder-only-Sprachmodelle nicht generativ, sondern als Encoder nutzt und ihre internen Repräsentationen für diskriminative Aufgaben verwertet [3, 31]. Damit lässt sich das im Vortraining erworbene Wissen großer Sprachmodelle in einem einzigen Vorwärtspass nutzen, ohne zur Inferenzzeit Text erzeugen zu müssen.

Die zweite Anforderung betrifft die Heterogenität der Bewertungsskalen. Ein klassischer Klassifikator bildet die Antwort über einen Ausgabekopf fester Breite auf die Stufen eines bestimmten Benchmarks ab. Er ist damit an Zahl und Bedeutung dieser Stufen gebunden; eine Aufgabe mit abweichender Skala erfordert einen neuen Kopf und ein erneutes Training [22]. Bereits innerhalb eines einzelnen Benchmarks wie ASAP-SAS wechselt die Stufenzahl zwischen den Aufgaben (Kapitel 3). Eine naheliegende Antwort auf dieses Problem ist das rubrik-geleitete Scoring: Jede Bewertungsstufe wird nicht durch einen Index, sondern durch ihre Rubrik, also die sprachliche Beschreibung der Kriterien, repräsentiert, und das Modell bewertet die Passung

zwischen Antwort und Kriterienbeschreibung. Ein solches Modell ist nicht an einen festen Labelraum gebunden und grundsätzlich auf ungesehene Rubriksätze übertragbar. Die Aktualität dieses Ansatzes zeigt sich auch darin, dass die rubrik-basierte Bewertung Gegenstand eines aktuellen Shared Tasks ist [23].

1.2 Problemstellung

Rubrik-geleitete Verfahren lassen sich auf zwei Arten umsetzen. Paarweise Verfahren kodieren die Antwort mit jeder Rubrik einzeln und benötigen daher je Instanz so viele Vorwärtspässe, wie Bewertungsstufen existieren [50]. Span-Alignment-Verfahren kodieren dagegen Antwort und sämtliche Rubriken gemeinsam in einer einzigen Sequenz, extrahieren die Repräsentation jeder Rubrik als Span aus derselben Zustandsmatrix und richten sie an einer Kontextrepräsentation aus [22]. Sie verbinden damit die Flexibilität des paarweisen Vergleichs mit dem Aufwand eines einzelnen Vorwärtspasses (Abschnitt 2.5).

Die Übertragung dieses Prinzips auf Decoder-only-Sprachmodelle wirft drei Fragen auf, die bislang nicht systematisch untersucht sind.

Die erste betrifft die *Prämisse* des Ansatzes selbst. Rubrik-geleitetes Scoring setzt voraus, dass das Modell die Kriterienbeschreibungen tatsächlich für die Bewertung nutzt und dass ihre explizite Extraktion als Span gegenüber einem einfachen Klassifikator mit festem Kopf einen Vorteil bringt. Beides ist nicht selbstverständlich, zumal Rubriktexte inhaltlich eng mit Frage und Musterlösung verbunden sind und für zwei der drei verwendeten Benchmarks keine originalen Bewertungsrichtlinien vorliegen (Abschnitt 3.4).

Die zweite betrifft die *Ausgestaltung des Alignments*. Offen ist, welche Kontextrepräsentation an den Rubrik-Spans ausgerichtet werden soll – die Repräsentation des Antwort-Spans oder die Repräsentation der gesamten Sequenz – und mit welcher Fusionsfunktion beide verknüpft werden. Unter kausaler Attention ist diese Wahl nicht neutral: Der Antwort-Span steht vor den Rubriken und hat sie nicht gesehen, während der letzte Zustand der Sequenz die gesamte Eingabe einschließlich aller Rubriken zusammenfasst.

Die dritte betrifft die *Attention-Maske*. Decoder-only-Modelle sind unter einer kausalen Maske vortrainiert, die jeder Position nur den Blick auf vorangehende Positionen erlaubt. Für eine reine Bewertungsaufgabe ist diese Einschränkung sachlich nicht motiviert: Die Antwort kann die nachfolgenden Rubriktexte nicht berücksichtigen, und die Rubrik-Repräsentationen sind asymmetrisch von den jeweils vorangehenden Stufen abhängig. Arbeiten zur Umwidmung von Sprachmodellen als Encoder zeigen, dass sich die Maske aufheben lässt, der Eingriff aber gegenüber der Vortrainingsbedingung nicht folgenlos ist [3, 34]. Ob eine anteilige oder vollständige Aufhebung im Rahmen eines parameter-effizienten Finetunings für ASAG nützt, ist offen.

Für alle drei Fragen kommt eine methodische Schwierigkeit hinzu. Die zu erwartenden Unterschiede zwischen Architekturvarianten sind klein, während bereits die Wahl der Zufallssaat das Ergebnis eines Finetunings erheblich beeinflussen kann [43, 14]. Ein Vergleich einzelner Läufe kann daher nicht zwischen einem Effekt der Architektur und bloßem Trainingsrauschen unterscheiden. Ebenso hängt die Aussagekraft eines Ergebnisses davon ab, ob ein Modell lediglich

neue Antworten auf bekannte Fragen bewertet oder auf ungesehene Fragen und Domänen übertragen wird [16].

1.3 Forschungsfragen

Ziel dieser Arbeit ist es, einen span-basierten Klassifikator für das rubrik-geleitete Scoring auf Decoder-only-Sprachmodelle zu übertragen und die genannten Fragen kontrolliert zu untersuchen. Sie folgt dabei zwei Forschungsfragen:

RQ1 *Übertrifft der span-basierte Klassifikator die Vergleichsbedingungen?* Untersucht wird dies gegenüber einem Klassifikator mit festem Ausgabekopf, der dieselbe Eingabe erhält, gegenüber Bedingungen ohne Rubriktext oder ohne jede aufgabenbezogene Information sowie gegenüber Encoder-Modellen. Dabei wird insbesondere geprüft, welchen Beitrag die Rubriktexte im Verhältnis zu Frage und Musterlösung leisten und ob sich ein trainiertes Modell über die Rubriktexte auf einen anderen Benchmark übertragen lässt.

RQ2 *Lassen sich Decoder-only-Sprachmodelle an den span-basierten Klassifikator anpassen?* Untersucht werden die Ausgestaltung des Alignments zwischen Rubrik-Spans und Kontext – Fusionsfunktion und Bezugsgröße, also Sequenzrepräsentation oder Antwort-Span – sowie die anteilige und vollständige Aufhebung der kausalen Attention-Maske.

Untersucht werden diese Fragen auf drei englischsprachigen Benchmarks (ASAP-SAS, Beetle und SciEntsBank) mit Llama-3.2-1B, Llama-3.2-3B und Mistral-7B als Decoder-Backbones sowie BERT und RoBERTa als Encoder-Vergleichsbasis.

Die Arbeit leistet damit vier Beiträge. Sie vergleicht erstens das Span-Alignment mit einem festen Klassifikationskopf bei identischer Eingabe und trennt in einem vollständigen 2×2-Schema den Beitrag der Rubriktexte von dem der übrigen Aufgabeninformation; ergänzend prüft sie die Übertragung eines auf ASAP-SAS trainierten Modells auf Beetle und SciEntsBank. Sie überträgt zweitens das Span-Alignment auf Decoder-only-Modelle und vergleicht dabei vier Fusionsfunktionen und zwei Bezugsgrößen bei ansonsten identischer Architektur. Sie variiert drittens die Attention-Maske schichtweise von der rein kausalen bis zur vollständig bidirektionalen Bedingung. Viertens wertet sie sämtliche inhaltlichen Vergleiche über drei Zufallssaaten gegen eine empirisch bestimmte Rauschgrenze aus, getrennt nach Generalisierungsbedingung und unter zwei Metriken, und prüft die Verlässlichkeit dieser Rauschgrenze an einer Gruppe mit acht Saaten.

1.4 Aufbau der Arbeit

Kapitel 2 führt in die Aufgabenstellung des ASAG und ihre Evaluation ein, stellt encoder- und LLM-basierte Ansätze sowie das rubrik-geleitete Scoring dar und beschreibt die für diese Arbeit relevanten Grundlagen der Transformer-Architektur, insbesondere die Attention-Maske, sowie das parameter-effiziente Finetuning. Kapitel 3 beschreibt die drei verwendeten Benchmarks, ihre Evaluationssplits und die Herkunft der Rubriktexte. Kapitel 4 entwickelt das untersuchte Span-Alignment-Modell, die Fusionsmechanismen, die anteilige Aufhebung der kausalen

Maske und die Vergleichsbedingungen. Kapitel 5 bestimmt zunächst die Rauschgrenze und berichtet anschließend die Ergebnisse entlang der Forschungsfragen. Kapitel 6 beantwortet die Forschungsfragen, ordnet die Befunde in die Literatur ein und benennt die Grenzen der Untersuchung. Kapitel 7 fasst die Arbeit zusammen und gibt einen Ausblick auf weiterführende Fragestellungen.

2 Grundlagen

Das vorliegende Kapitel legt die begrifflichen, methodischen und technischen Grundlagen, auf denen das in Kapitel 4 beschriebene RUSPAN-System aufbaut. Zunächst wird die Aufgabe des Automatic Short Answer Grading formal gefasst und von benachbarten Aufgabenstellungen abgegrenzt (Abschnitt 2.1). Anschließend werden die in dieser Arbeit verwendeten Evaluationsmetriken hergeleitet und hinsichtlich ihrer Messvoraussetzungen diskutiert (Abschnitt 2.2). Die Abschnitte 2.3 und 2.4 referieren den Stand der Forschung zu Encoder- und LLM-basierten Verfahren; Abschnitt 2.5 führt in rubrik-geleitete Scoring-Architekturen ein, aus denen sich der Ansatz dieser Arbeit unmittelbar ableitet. Die technischen Voraussetzungen – Transformer-Architektur, Self-Attention, Attention-Masken und parameter-effizientes Finetuning – werden in den Abschnitten 2.6 bis 2.7 entwickelt. Abschnitt 2.8 ordnet die untersuchten Fusionsmechanismen in die breitere Literatur zur Kombination von Vektorrepräsentationen ein.

2.1 Automatic Short Answer Grading (ASAG): Aufgabendefinition

Begriffsbestimmung und Abgrenzung

Unter Automatic Short Answer Grading (ASAG) wird die maschinelle Zuweisung einer Bewertung zu einer frei formulierten, kurzen Schülerantwort verstanden, die auf eine inhaltlich determinierte Frage gegeben wurde. Der maßgebliche Überblicksartikel von Burrows, Gurevych und Stein [5] grenzt die Aufgabe über fünf Merkmale ab: Die Frage verlangt einen erinnerten oder erschlossenen Sachverhalt, die Antwort ist in natürlicher Sprache formuliert, sie umfasst typischerweise eine bis wenige Sätze, die Bewertung bezieht sich auf den Inhalt und nicht auf die sprachliche Form, und der Antwortraum ist offen, aber sachlich eng begrenzt. Damit unterscheidet sich ASAG systematisch vom Automated Essay Scoring (AES), bei dem neben dem Inhalt auch Schreibkompetenzen wie Stil und Struktur in die Bewertung eingehen [2]. Ebenso grenzt es sich von Multiple-Choice-Formaten ab, bei denen kein sprachliches Verstehen erforderlich ist. In der jüngeren Literatur ist daneben die Bezeichnung Automatic Short Answer Scoring (ASAS) gebräuchlich [2]. Die vorliegende Arbeit verwendet beide Bezeichnungen synonym und folgt dem etablierteren Kürzel ASAG.

Die praktische Relevanz der Aufgabe ergibt sich aus dem Missverhältnis zwischen dem didaktischen Wert konstruierter Antworten und ihren Korrekturkosten: Konstruierte Antworten verlangen im Gegensatz zu geschlossenen Formaten, dass Lernende eine Antwort selbst formulieren und ihr Vorgehen begründen [2]. Ihre manuelle Bewertung ist jedoch aufwendig, und

große Lerngruppen erfordern effiziente Lösungen [5].

Formalisierung

Ein Datensatz für ASAG wird als Menge annotierter Instanzen

$$\mathcal{D} = \{(x_i, y_i)\}_{i=1}^{N} \tag{2.1}$$

aufgefasst, wobei y_i das von menschlichen Beurteilenden vergebene Referenzlabel ist. Jede Instanz x_i ist ein Tupel textueller Felder

$$x_i = \big(q_i,\ s_i,\ a_i,\ \mathcal{R}_i\big), \tag{2.2}$$

bestehend aus der Aufgabenstellung q_i (*question*), einer Musterlösung oder Referenzantwort s_i (*sample solution*), der zu bewertenden Schülerantwort a_i (*answer*) sowie der Menge

$$\mathcal{R}_i = \big(r_{i,0},\ r_{i,1},\ \ldots,\ r_{i,K_i-1}\big) \tag{2.3}$$

der K_i Rubrik-Beschreibungen, die jeweils eine Leistungsstufe sprachlich charakterisieren. Die Felder s_i und $\mathcal{R}_i$ sind benchmarkabhängig verfügbar; ihre Herkunft für die in dieser Arbeit verwendeten Datensätze wird in Kapitel 3 dargestellt.

Die klassische Formulierung der Aufgabe besteht in einer Scoring-Funktion

$$f_\theta :\ (q_i, s_i, a_i) \ \longmapsto\ y_i, \qquad y_i \in \mathcal{Y}, \tag{2.4}$$

die auf einen *global* festgelegten Labelraum $\mathcal{Y}$ abbildet. $\mathcal{Y}$ ist in aller Regel ordinal skaliert, das heißt zwischen den Stufen besteht eine inhaltlich begründete Rangordnung, ohne dass die Abstände zwischen benachbarten Stufen als äquidistant interpretiert werden dürften. Die Kardinalität und Semantik von $\mathcal{Y}$ variiert zwischen den Benchmarks und teilweise sogar zwischen den Einzelaufgaben eines Benchmarks (vgl. Kapitel 3).

Genau diese Variabilität motiviert die in dieser Arbeit verfolgte Alternative. Statt eines globalen Labelraums wird die Aufgabe rubrik-konditioniert formuliert: Für jede Instanz existiert eine instanzspezifische Kandidatenmenge $\mathcal{Y}_i = \{0, \ldots, K_i - 1\}$, deren Elemente durch die zugehörigen Rubriktexte $r_{i,k}$ semantisch beschrieben sind. Die Scoring-Funktion vergibt dann für jede Stufe einen Score

$$\sigma_\theta :\ (q_i, s_i, a_i, r_{i,k}) \ \longmapsto\ s_{i,k} \in \mathbb{R}, \qquad \hat{y}_i = \operatorname*{arg\,max}_{k \in \mathcal{Y}_i} s_{i,k}. \tag{2.5}$$

Formulierung (2.5) ist strikt allgemeiner als (2.4): Sie ist auch dann anwendbar, wenn K_i zwischen Instanzen variiert, und sie erlaubt die Übertragung auf ungesehene Rubriksätze, da das Modell keine Indexzuordnung, sondern eine Passung zwischen Antwort und Kriterienbeschreibung lernt. Die konkrete architektonische Umsetzung von (2.5) sowie die zugehörige Trainingszielfunktion werden in Kapitel 4 entwickelt; die vorliegende Arbeit vergleicht sie durchgängig mit der klassischen Formulierung (2.4) als Baseline. Abbildung 2.1 stellt beide Formulierungen einander gegenüber.

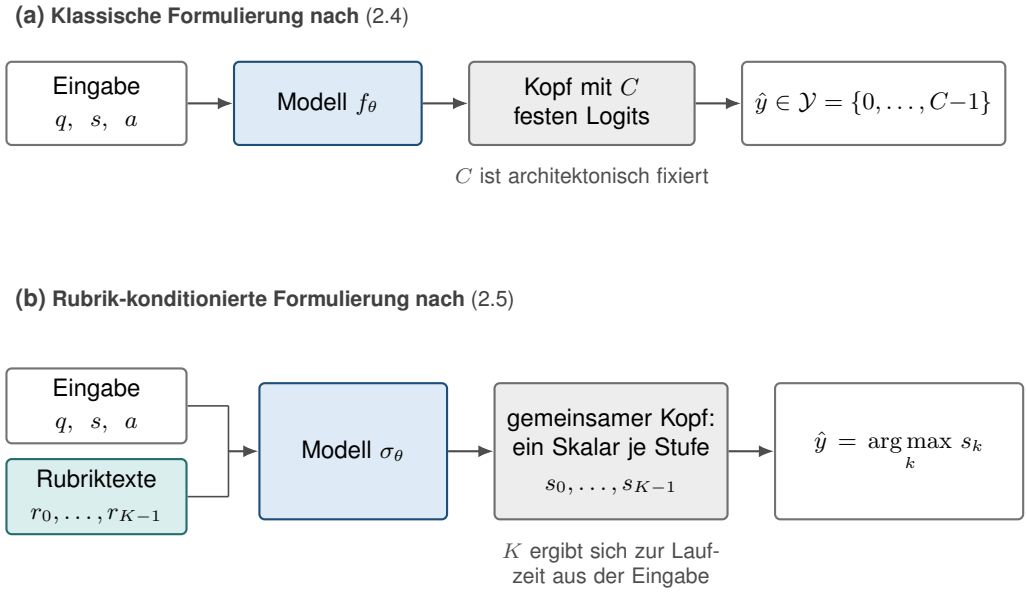


Abbildung 2.1: Klassische **(a)** und rubrik-konditionierte **(b)** Aufgabenformulierung. In **(b)** vergibt ein gemeinsamer Kopf je Rubrik einen Skalar, sodass die Zahl der Ausgaben aus der Zahl der Rubriken folgt.

Generalisierungsdimensionen und Evaluationssplits

Ein einzelner Kennwert auf einer einzelnen Testmenge sagt über ein ASAG-System wenig aus, solange nicht geklärt ist, *welcher Art von Neuheit* das System dabei begegnet. Ein System, das in einer Lehrveranstaltung dieselbe Klausuraufgabe über mehrere Jahrgänge hinweg bewertet, steht vor einer völlig anderen Aufgabe als eines, das auf eine neu formulierte Frage oder gar auf ein anderes Fachgebiet angewandt wird. Die im Rahmen von SemEval-2013 Task 7 eingeführte und seither übliche Aufteilung bildet genau diese Abstufung ab, indem sie drei Testbedingungen danach unterscheidet, welche Bestandteile einer Testinstanz bereits im Training vorkamen [16]:

- *Unseen Answers* (UA): Neu ist ausschließlich die Schülerantwort. Frage, Musterlösung und Rubriktexte hat das Modell im Training bereits vielfach gesehen. Gemessen wird die Fähigkeit, die Bewertungskonvention einer *bekannten* Aufgabe zu reproduzieren.
- *Unseen Questions* (UQ): Neu sind Frage und Antwort, die Fachdomäne bleibt dieselbe. Das Modell muss das Bewertungsprinzip von der einzelnen Aufgabe abstrahiert haben, kann sich aber weiterhin auf vertraute Inhalte stützen.
- *Unseen Domains* (UD): Neu sind Frage, Antwort und Fachgebiet. Diese Bedingung stellt die höchste Anforderung, da weder die Aufgabenformulierung noch der Gegenstandsbereich im Finetuning vorkam.

Abbildung 2.2 stellt die drei Bedingungen als geschachtelte Neuheitsgrade dar. Die Aufteilung ist dabei nicht nominell, sondern in den verwendeten Datensätzen strukturell realisiert: Bei Beetle etwa verwendet der UA-Split exakt dieselben 47 Fragen wie das Training, während die 9 Fragen des UQ-Splits mit den Trainingsfragen eine leere Schnittmenge bilden. Bei SciEntsBank

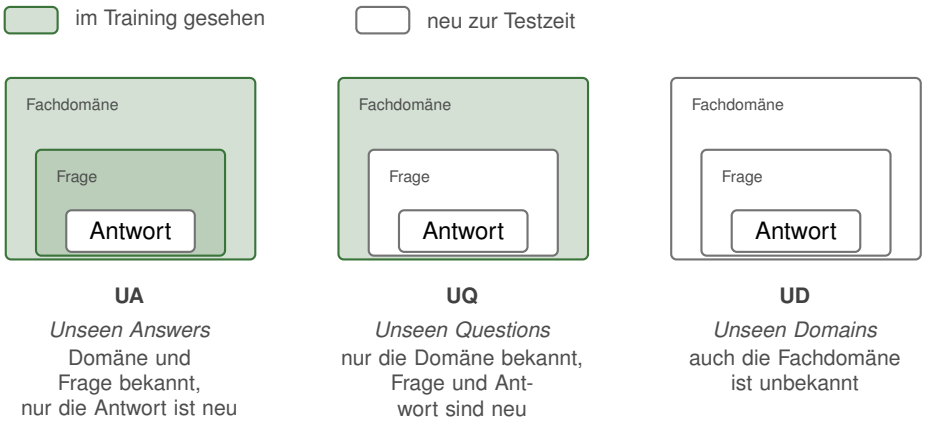


Abbildung 2.2: Die drei Evaluationsbedingungen nach [16]: Neu sind bei UA die Antwort, bei UQ zusätzlich die Frage, bei UD auch die Fachdomäne.

stammen die 46 Fragen des UD-Splits ausschließlich aus drei Themenblöcken, die in keiner einzigen Trainingsfrage auftreten (Kapitel 3).

Für diese Arbeit ist die Unterscheidung mehr als eine Konvention. Unter UA kann ein Modell eine hohe Übereinstimmung bereits über wiederkehrende Formulierungsmuster bekannter Fragen erreichen, ohne die Bewertungskriterien inhaltlich zu verarbeiten; dass dieser Kurzschluss in den vorliegenden Daten tatsächlich auftritt, zeigt Abschnitt 5.3.2. Vor allem aber ist das Versprechen der rubrik-konditionierten Formulierung (2.5), auf ungesehene Aufgaben und Rubriksätze übertragbar zu sein, nur unter UQ und UD prüfbar, da die Rubriktexte unter UA mit denen des Trainings identisch sind. Sämtliche Ergebnisse werden daher in Kapitel 5 nach Split getrennt berichtet, und Aussagen über die Übertragbarkeit stützen sich ausschließlich auf UQ und UD. Einschränkend ist festzuhalten, dass allein SciEntsBank einen UD-Split bereitstellt (Kapitel 3); alle Befunde zum Domänentransfer beruhen daher auf einem einzigen Benchmark.

2.2 Evaluationsmetriken im ASAG

ASAG-Ergebnisse werden in dieser Arbeit über drei Maße berichtet: Quadratic Weighted Kappa (QWK), Macro-F_1 und Accuracy. Alle drei Maße lassen sich aus der Konfusionsmatrix ableiten, unterstellen aber unterschiedliche Skalenniveaus und reagieren unterschiedlich auf Klassenungleichgewichte. Der Abschnitt entwickelt sie zunächst formal und diskutiert anschließend ihre Voraussetzungen.

Notation

Sei $\mathcal{Y} = \{0, 1, \ldots, C-1\}$ der betrachtete Labelraum mit C Stufen, seien y_i die Referenz- und $\hat{y}_i$ die Modellvorhersagen über N Testinstanzen. Die Konfusionsmatrix $O \in \mathbb{N}^{C \times C}$ ist definiert durch

$$O_{jk} = \left|\{\, i \in \{1, \ldots, N\} \;:\; y_i = j \;\wedge\; \hat{y}_i = k \,\}\right|, \tag{2.6}$$

das heißt O_{jk} zählt die Instanzen mit Referenzstufe j und Vorhersage k. Die Randverteilungen werden mit $n_j^{\text{ref}} = \sum_k O_{jk}$ und $n_k^{\text{pred}} = \sum_j O_{jk}$ bezeichnet.

Accuracy

Die Accuracy ist der Anteil exakt korrekt vorhergesagter Instanzen,

$$\text{Acc} = \frac{1}{N} \sum_{j=0}^{C-1} O_{jj}. \tag{2.7}$$

Sie ist unmittelbar interpretierbar, hat aber zwei für ASAG gravierende Nachteile. Erstens gewichtet sie alle Fehler gleich: Die Verwechslung einer maximalen mit einer minimalen Punktzahl geht ebenso ein wie die Verwechslung benachbarter Stufen, obwohl Letztere aus Bewertungssicht deutlich weniger schwer wiegt. Zweitens ist sie gegenüber unbalancierten Labelverteilungen nicht robust: Ein triviales Modell, das stets die häufigste Stufe vorhersagt, erreicht bereits die relative Häufigkeit dieser Stufe. Da die in dieser Arbeit verwendeten Benchmarks teils deutlich unbalanciert sind (vgl. Kapitel 3), wird Accuracy ausschließlich als ergänzende Größe berichtet.

Macro-F_1

Für eine Stufe k werden Präzision und Recall klassenweise definiert als

$$P_k = \frac{O_{kk}}{n_k^{\text{pred}}}, \qquad R_k = \frac{O_{kk}}{n_k^{\text{ref}}}, \qquad F_{1,k} = \frac{2\,P_k\,R_k}{P_k + R_k}, \tag{2.8}$$

wobei $F_{1,k} := 0$ gesetzt wird, falls $P_k + R_k = 0$. Das Macro-F_1 ist das ungewichtete arithmetische Mittel über alle Stufen,

$$F_1^{\text{macro}} = \frac{1}{C} \sum_{k=0}^{C-1} F_{1,k}. \tag{2.9}$$

Die ungewichtete Mittelung ist der entscheidende Punkt: Jede Stufe geht unabhängig von ihrer Häufigkeit mit gleichem Gewicht ein, sodass eine schwache Leistung auf seltenen Stufen nicht durch eine starke Leistung auf der Mehrheitsstufe kompensiert werden kann. Macro-F_1 ist damit das strengere Maß unter Klassenungleichgewicht. Es ist allerdings gegenüber der Ordinalität des Labelraums blind, da es die Stufen wie nominale Kategorien behandelt.

Quadratic Weighted Kappa

Cohens κ misst die Übereinstimmung zweier Beurteilungsinstanzen unter Korrektur der zufällig zu erwartenden Übereinstimmung [10]. Die gewichtete Variante κ_w verallgemeinert dieses Prinzip, indem Abweichungen unterschiedlicher Schwere unterschiedlich stark gewichtet wer-

den [11]. Sei $E \in \mathbb{R}^{C \times C}$ die unter Unabhängigkeit der Randverteilungen erwartete Häufigkeitsmatrix,

$$E_{jk} = \frac{n_j^{\text{ref}} \cdot n_k^{\text{pred}}}{N}, \tag{2.10}$$

und sei $W \in \mathbb{R}^{C \times C}$ eine Gewichtsmatrix, die jeder Zelle die Schwere der zugehörigen Abweichung zuordnet. Dann gilt

$$\kappa_w = 1 - \frac{\sum_{j,k} W_{jk}\, O_{jk}}{\sum_{j,k} W_{jk}\, E_{jk}}. \tag{2.11}$$

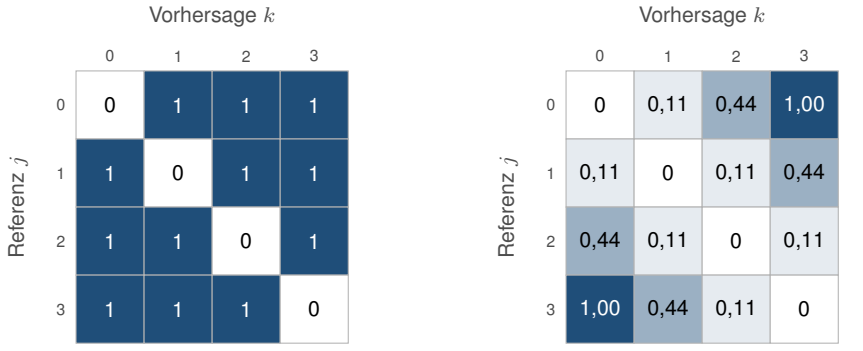
Die in dieser Arbeit verwendete quadratische Gewichtung setzt

$$W_{jk} = \frac{(j-k)^2}{(C-1)^2}, \tag{2.12}$$

sodass $W_{jj} = 0$ für die Diagonale und $W_{jk} = 1$ für die maximal mögliche Abweichung gilt. Einsetzen von (2.12) in (2.11) ergibt das Quadratic Weighted Kappa

$$\text{QWK} = 1 - \frac{\sum_{j,k} (j-k)^2\, O_{jk}}{\sum_{j,k} (j-k)^2\, E_{jk}}, \tag{2.13}$$

in dem sich der Normierungsfaktor $(C-1)^{-2}$ herauskürzt. Der Wertebereich ist QWK ≤ 1; der Wert 1 entspricht perfekter Übereinstimmung, der Wert 0 einer Übereinstimmung auf Zufallsniveau, negative Werte einer systematisch schlechteren als zufälligen Übereinstimmung. Der quadratische Term bestraft weit entfernte Verwechslungen überproportional und bildet damit die Ordinalstruktur des Bewertungsschemas ab. QWK ist das im Bereich des automatisierten Scorings etablierte Standardmaß und wurde unter anderem als offizielle Metrik des ASAP-Wettbewerbs verwendet [54, 2]. Abbildung 2.3 stellt die quadratische Gewichtung derjenigen $0/1$-Gewichtung gegenüber, die der Accuracy zugrunde liegt.



(a) $0/1$**-Gewichtung**
jeder Fehler zählt gleich
(entspricht der Accuracy)

(b) quadratische Gewichtung
$W_{jk} = (j-k)^2/(C-1)^2$
benachbarte Stufen zählen kaum

Abbildung 2.3: Gewichtsmatrizen für $C = 4$: $0/1$-Gewichtung der Accuracy **(a)** und quadratische Gewichtung des QWK nach (2.12) **(b)**.

Voraussetzungen und Grenzen von QWK

Die Verwendung von QWK ist an eine inhaltliche Voraussetzung gebunden, die in der ASAG-Literatur nicht immer explizit gemacht wird: Die quadratische Gewichtung (2.12) setzt voraus, dass die Labelindizes j und k auf einer geordneten Skala liegen und dass ihre numerische Differenz als sinnvolles Maß der Abweichungsschwere interpretiert werden kann. Faktisch unterstellt QWK damit ein intervallskaliertes Verhalten der Distanzen, obwohl Bewertungsskalen streng genommen nur ordinal skaliert sind. Bei Punkteskalen wie derjenigen von ASAP-SAS ist diese Idealisierung vertretbar, da die Stufen die Anzahl korrekt genannter inhaltlicher Elemente abbilden und die Abstände daher näherungsweise gleichbedeutend sind.

Problematisch wird die Voraussetzung dagegen bei nominalen Labelsätzen. Das ursprüngliche Fünf-Wege-Schema von SemEval-2013 Task 7 unterscheidet die Kategorien *correct*, *partially_correct_incomplete*, *contradictory*, *irrelevant* und *non_domain* [16]. Diese Kategorien bilden keine Rangordnung: Eine *contradictory*-Antwort ist nicht in einem wohldefinierten Sinne „besser“ oder „schlechter“ als eine *irrelevant*-Antwort, und eine Verwechslung von *correct* mit *non_domain* ist nicht deshalb viermal so schwerwiegend wie eine Verwechslung von *correct* mit *partially_correct_incomplete*, weil die willkürliche Indizierung dies nahelegt. In diesem Fünf-Wege-Setting ist QWK folglich kein sinnvolles Maß, und die Ergebnisse hängen von der arbiträren Reihenfolge der Kategorien ab.

Die vorliegende Arbeit verwendet für Beetle und SciEntsBank nicht das nominale Fünf-Wege-Schema, sondern eine dreistufige ordinale Fassung mit den Stufen *incorrect*, *partially correct* und *correct*, die eine echte Rangordnung des Leistungsgrades darstellt (vgl. Kapitel 3). Sie ist nicht mit der offiziellen Drei-Wege-Variante von SemEval-2013 Task 7 zu verwechseln, die *correct*, *contradictory* und *incorrect* unterscheidet und damit ebenfalls keine Rangordnung bildet [16]. Unter dieser Wahl ist die Ordinalitätsannahme von QWK erfüllt und die Metrik über alle drei Benchmarks hinweg vergleichbar interpretierbar. Diese Festlegung wird hier ausdrücklich als methodische Entscheidung ausgewiesen, weil sie die Vergleichbarkeit mit älteren Arbeiten einschränkt, die auf dem Fünf- oder Drei-Wege-Schema von SemEval-2013 berichten.

Unabhängig vom Skalenniveau weist QWK weitere bekannte Schwächen auf. Doewes, Kurdhi und Saxena [15] zeigen, dass der Wert erheblich von der Form der Randverteilungen und von der Länge der Skala abhängt, dass die aus der Kappa-Literatur bekannten Paradoxa auch im Kontext des automatisierten Scorings auftreten und dass QWK deshalb nicht als alleinige Kennzahl verwendet werden sollte. Aus diesem Grund wird Macro-F_1 in dieser Arbeit als zweite Metrik herangezogen: QWK erfasst die ordinale Nähe der Fehlklassifikationen, Macro-F_1 die Leistung auf seltenen Stufen. Die Ergebnistabellen in Kapitel 5 berichten überwiegend QWK; sämtliche Vergleiche mit mehreren Zufallssaaten werden in Abschnitt 5.5.3 unter Macro-F_1 wiederholt, wo auch die Abweichungen zwischen beiden Maßen diskutiert werden.

Zuverlässigkeit gemessener Unterschiede

Die bisher eingeführten Maße beschreiben, *was* gemessen wird. Für die Auswertung in Kapitel 5 ist zusätzlich zu klären, *wie genau* eine solche Messung ist – also welcher Unterschied zwischen zwei Konfigurationen überhaupt als Ergebnis gelten darf.

Stochastische Anteile im Training

Das Training eines neuronalen Modells ist kein deterministisches Verfahren. Mehrere Komponenten beruhen auf Zufallsentscheidungen:

- die Initialisierung neu hinzugefügter Module – in dieser Arbeit die Fusions- und Scoring-Parameter (Abschnitt 2.7) sowie die LoRA-Matrizen,
- die Reihenfolge, in der die Trainingsinstanzen zu Batches zusammengestellt werden,
- die zufällige Deaktivierung von Einheiten durch Dropout,
- die Aufteilung in Trainings- und Validierungsmenge, sofern kein offizieller Entwicklungssplit vorliegt; in dieser Arbeit erfolgt sie mit einer festen, von der Saat des Laufs unabhängigen Zufallssaat (Abschnitt 4.6).

Diese Quellen lassen sich über eine *Zufallssaat* (*random seed*) steuern: Ein fest gewählter Startwert des Zufallszahlengenerators legt die Folge aller Zufallsentscheidungen fest und macht einen Lauf im Prinzip wiederholbar. Vollständige Reproduzierbarkeit ist damit allerdings nicht garantiert. Nebenläufige Berechnungen auf Grafikprozessoren summieren Gleitkommawerte in nicht festgelegter Reihenfolge; da die Gleitkommaaddition nicht assoziativ ist, können bereits daraus abweichende Ergebnisse entstehen. Auch das parallele Laden der Daten durch mehrere Prozesse kann die Batch-Zusammenstellung beeinflussen.

Streuung zwischen Läufen

Praktisch folgt daraus: Zwei Trainingsläufe mit identischer Konfiguration, aber unterschiedlicher Zufallssaat liefern nicht denselben Wert. Reimers und Gurevych [43] zeigen für Sequenzmarkierungsaufgaben, dass allein die Wahl der Zufallssaat zu statistisch signifikanten Unterschieden führen kann, und plädieren dafür, Verteilungen über mehrere Läufe statt einzelner Werte zu berichten. Dodge u. a. [14] weisen denselben Effekt für das Finetuning vortrainierter Sprachmodelle nach und führen ihn zu vergleichbaren Anteilen auf die Gewichtsinitialisierung und die Datenreihenfolge zurück.

Daraus folgt eine Auswertungsregel, die in Kapitel 5 durchgehend angewandt wird. Ein einzelner Messwert ist keine Punktmessung, sondern eine Stichprobe aus einer Verteilung. Der Unterschied zwischen zwei Konfigurationen ist nur dann als Effekt interpretierbar, wenn er *größer* ist als die Streuung, die dieselbe Konfiguration bei bloßem Wechsel der Zufallssaat aufweist. Diese Streuung wird im Folgenden als *Rauschgrenze* bezeichnet; sie wird in Abschnitt 5.2 empirisch bestimmt, statt sie anzunehmen.

Bezeichnet $\{m_1, \ldots, m_S\}$ die Messwerte einer Konfiguration über S Zufallssaaten, so wird als Kennwert der Streuung die Spannweite

$$\Delta = \max_s m_s - \min_s m_s \tag{2.14}$$

verwendet. Bei der hier realisierbaren Zahl von $S = 3$ Läufen je Konfiguration ist die Spannweite der robustere Kennwert als eine Standardabweichung, deren Schätzung aus drei Werten

sehr unsicher wäre. Aus demselben Grund wird auf inferenzstatistische Tests verzichtet: Deren Voraussetzungen sind bei drei Beobachtungen je Zelle nicht erfüllt, und ein Vergleich der beobachteten Differenz mit der beobachteten Spannweite ist die ehrlichere Darstellung. Abbildung 2.4 veranschaulicht die daraus folgende Entscheidungsregel.

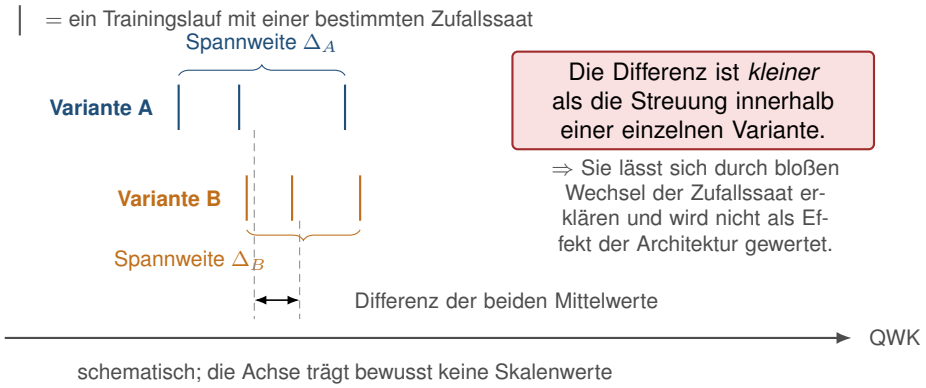


Abbildung 2.4: Schematische Auswertungsregel: Striche markieren Läufe mit unterschiedlicher Zufallssaat, Klammern die Spannweite (2.14). Liegt die Differenz der Mittelwerte unterhalb der Spannweite, wird sie nicht als Effekt interpretiert.

Ablation

Ein wiederkehrendes Auswertungsmuster dieser Arbeit ist die *Ablation*: Aus einer funktionierenden Konfiguration wird gezielt *eine* Komponente entfernt oder ersetzt, während alle übrigen Bestandteile unverändert bleiben. Ein beobachteter Leistungsunterschied ist dann dieser einen Komponente zurechenbar. Die Aussagekraft einer Ablation hängt unmittelbar an der zuvor beschriebenen Rauschgrenze: Sie belegt einen Beitrag der entfernten Komponente nur, wenn der Unterschied die Streuung zwischen Läufen übersteigt.

2.3 Encoder-basierte Ansätze im ASAG

Frühe ASAG-Systeme bewerteten Antworten über manuell konstruierte Merkmale, etwa semantische Ähnlichkeitsmaße zur Musterantwort [39, 52] oder den Abgleich mit vorab formulierten Bewertungsschablonen [38]; einen Überblick über diese Phase geben Burrows, Gurevych und Stein [5]. Ihr gemeinsamer Nachteil liegt im aufgabenspezifischen Aufwand der Merkmalskonstruktion und darin, dass Paraphrasen sowie inhaltlich korrekte, aber lexikalisch abweichende Antworten nur unzureichend erfasst werden.

Neuronale Encoder

Mit der Verfügbarkeit vortrainierter Sprachmodelle verlagerte sich das Feld auf neuronale Encoder. Riordan u. a. [45] untersuchten systematisch rekurrente und konvolutionale Architekturen

für das Short Answer Scoring und zeigten, dass neuronale Modelle eine starke merkmalsbasierte Baseline übertreffen können, wobei Leistung und optimale Parameter zwischen den Aufgaben variieren. Kumar u. a. [30] kombinierten in AutoSAS verschiedene Merkmalsarten, darunter lexikalische Diversität, Word2Vec-Einbettungen sowie die Überlappung mit Aufgabe und Inhalt, zu einem schnellen und skalierbaren Scoring-System.

Den heute dominierenden Ansatz begründete die Übertragung von BERT [13] und verwandten Encoder-Modellen wie RoBERTa [36] auf die Aufgabe. Sung u. a. [53] zeigten, dass ein domänenspezifisches Weitertrainieren von BERT auf fachlichen Ressourcen die Scoring-Güte deutlich steigert; Camus und Filighera [6] untersuchten den Transfer verschiedener Transformer-Encoder auf ASAG-Benchmarks, und Ormerod [41] demonstrierten Gewinne durch Ensembles vortrainierter Modelle.

Architektonisch folgen diese Arbeiten einem einheitlichen Muster. Die textuellen Felder werden, durch Trennsymbole wie `[SEP]` separiert, zu einer Eingabesequenz konkateniert und durch den Encoder verarbeitet. Aus der resultierenden Zustandsmatrix wird eine einzelne Sequenzrepräsentation gewonnen – üblicherweise der Zustand an der `[CLS]`-Position – und über eine lineare Ausgabeschicht auf C Logits abgebildet, aus denen mittels Softmax eine Verteilung über den globalen Labelraum $\mathcal{Y}$ entsteht. Diese Konstruktion entspricht exakt der klassischen Formulierung (2.4).

Ein verwandter, aber architektonisch abweichender Zweig verzichtet auf den festen Klassifikationskopf und bewertet über Ähnlichkeit. Bexte, Horbach und Zesch [4] vergleichen die Schülerantwort mit Ankerantworten verschiedener Bewertungsstufen und leiten die Stufe aus der größten Einbettungsähnlichkeit ab, wobei Sentence-BERT-artige Bi-Encoder [44] zum Einsatz kommen. Li u. a. [33] modellieren die Beziehungen zwischen Antworten, Musterlösungen und Bewertungsstufen als relationales Netz. Diese Verfahren nehmen bereits gedanklich vorweg, was in Abschnitt 2.5 als rubrik-geleitetes Scoring systematisiert wird: Die Bewertungsstufe wird nicht durch einen Index, sondern durch einen Text repräsentiert.

Grenzen

Die Encoder-Linie ist innerhalb eines Benchmarks stark und rechnerisch günstig, weist aber zwei strukturelle Beschränkungen auf. Erstens bindet der feste Klassifikationskopf das Modell an die Kardinalität und Semantik eines konkreten Labelraums; ein Wechsel des Benchmarks oder auch nur eine Aufgabe mit abweichender Punkteskala erfordert eine neue Ausgabeschicht und damit ein erneutes Training [22]. Zweitens erhält das Modell die Bewertungskriterien allenfalls implizit über die Trainingsdaten; die Rubrik als explizite sprachliche Beschreibung dessen, was eine Stufe ausmacht, geht nicht in die Vorhersage ein. Beide Beschränkungen motivieren die in Abschnitt 2.5 dargestellten Architekturen.

2.4 LLM-basierte Ansätze im ASAG

Generative Bewertung

Mit der Verfügbarkeit großer, instruktionsangepasster Sprachmodelle liegt es nahe, die Bewertung als Textgenerierung zu formulieren: Das Modell erhält Frage, Musterlösung, Antwort und gegebenenfalls die Rubriken als Prompt und erzeugt die Bewertungsstufe als Zeichenkette. Kortemeyer [29] evaluiert GPT-4 in dieser Konfiguration auf den SemEval-Datensätzen SciEntsBank und Beetle, Chamieh, Zesch und Giebermann [7] untersuchen Zero- und Few-Shot-Prompting systematisch, Chang und Ginter [8] übertragen den Ansatz auf das Finnische, und Ferreira Mello u. a. [19] vergleichen prompt-optimiertes GPT-4 mit klassischen Modellen.

Der Ansatz ist maximal flexibel, da er keinen festen Labelraum voraussetzt, weist aber drei Nachteile auf. Erstens ist die autoregressive Dekodierung zur Inferenzzeit deutlich teurer als ein einzelner diskriminativer Vorwärtspass. Zweitens sind die Ergebnisse empfindlich gegenüber Formulierung und Format des Prompts, was die Reproduzierbarkeit beeinträchtigt. Drittens erzwingt die Generierung eine Nachverarbeitung, da das Modell nicht garantiert ein parsebares Label ausgibt.

Datenschutzrechtlicher Kontext

Eine zusätzliche, für den Bildungsbereich zentrale Restriktion betrifft die Verarbeitung von Schülertexten durch kommerzielle Modellanbieter. Schülerantworten sind personenbezogene Daten, sofern sie sich einer identifizierbaren Person zuordnen lassen, und die Daten von Kindern verdienen nach der Datenschutz-Grundverordnung besonderen Schutz [18, Art. 4 Nr. 1 und Erwägungsgrund 38]. Beim Einsatz generativer KI im Bildungsbereich sind zudem Pflichten zum Schutz von Kindern und Jugendlichen zu beachten [56]. Die Übermittlung solcher Texte an externe Programmierschnittstellen wirft daher datenschutzrechtliche und governancebezogene Fragen auf. Daraus ergibt sich die Anforderung, ASAG-Systeme lokal betreibbar zu halten. Lokal betreibbare generative Modelle in ausreichender Größe sind jedoch rechenintensiv, sodass ein Verfahren wünschenswert ist, das die Repräsentationsstärke großer Sprachmodelle nutzt, ohne zur Inferenzzeit generieren zu müssen.

LLMs als diskriminative Encoder

Genau diese Möglichkeit erschließt eine jüngere Forschungslinie, die autoregressive Sprachmodelle als Textencoder umwidmet. BehnamGhader u. a. [3] zeigen mit LLM2Vec, dass Decoder-only-Modelle durch die Aufhebung der kausalen Maske, ein maskiertes Weitertrainieren und ein kontrastives Nachtraining zu leistungsstarken Encodern werden. Lee u. a. [31] entwickeln mit NV-Embed Trainingsverfahren, die Decoder-Modelle zu generalistischen Einbettungsmodellen machen. Lin u. a. [34] untersuchen die trainingsfreie Umwandlung und identifizieren dabei den Attention-Sink – die Neigung des Modells, die Attention auf das erste Token zu konzentrieren – als zentrales Hindernis, während Qiao u. a. [42] Decoder-only-Modelle als maskierte Autoencoder reinterpretieren. Weitere Arbeiten belegen die Wirksamkeit des Ansatzes

für Klassifikation [46, 35] und dichte Retrieval-Aufgaben [37]. Gekhman u. a. [21] zeigen ergänzend, dass Sprachmodelle faktisches Wissen in ihren verborgenen Zuständen repräsentieren, selbst wenn sie es generativ nicht zuverlässig abrufen – ein Befund, der die encoderbasierte Nutzung für wissensintensive Diskriminationsaufgaben zusätzlich motiviert.

Für ASAG ist dieser Ansatz aus zwei Gründen attraktiv. Zum einen kann ein Sprachmodell die heterogenen Felder Frage, Musterlösung, Schülerantwort und Rubriken in einer einzigen langen Sequenz gemeinsam repräsentieren, statt sie paarweise zu vergleichen. Zum anderen bringt es das für die fachliche Beurteilung erforderliche Weltwissen mit. Zugleich besteht eine Forschungslücke: Die bisherigen Arbeiten zur Umwidmung von LLMs als Encoder evaluieren überwiegend auf Einzelsequenz- oder Satzpaaraufgaben, wie sie etwa in Retrieval- und Ähnlichkeitsbenchmarks vorherrschen [3, 31, 35]. Die gemeinsame Verarbeitung mehrerer heterogener Eingabefelder, wie sie ASAG erfordert, ist bislang kaum untersucht.

2.5 Rubrik-geleitetes Scoring: Guided-Alignment-Architekturen

Rubriken als Label-Semantik

Eine Rubrik ist im Kontext der Bildungsmessung eine sprachliche Beschreibung, die festlegt, welche Merkmale eine Antwort auf einer bestimmten Leistungsstufe aufweist. Aus modellierungstechnischer Sicht ist sie damit eine *semantische Repräsentation eines Labels*: Statt die Stufe k als bedeutungsloses Element eines Indexraums zu behandeln, wird sie durch den Text $r_{i,k}$ charakterisiert.

Dieser Gedanke ist nicht auf ASAG beschränkt. In der Verarbeitung natürlicher Sprache existiert eine breite Linie von Arbeiten, die Klassifikationsaufgaben durch Einbeziehung der Label-Semantik verbessern. Dazu zählen das Pattern-Exploiting Training, das Labels über einen Verbalisierer auf Wörter abbildet [47], und dessen Erweiterung um einen Label-Encoder, der die Verbalisierung ersetzt [25], sowie diskriminative Formulierungen, in denen Eingabe und Label-Option gemeinsam als Aussage bewertet werden [59, 17]. Solche Verfahren ersetzen die rein indexbasierte Klassifikation und sind insbesondere in Zero- und Few-Shot-Szenarien wirksam. Rubrik-geleitetes ASAG lässt sich als fachspezifische Ausprägung dieses Prinzips verstehen.

Rubric Retrieval und paarweises Matching

Eine verbreitete Umsetzung im ASAG behandelt die Aufgabe als Retrieval- oder Matching-Problem: Jede Instanz wird in K_i Paare $(a_i, r_{i,k})$ expandiert, jedes Paar wird einzeln kodiert, und ein Kopf entscheidet, ob die Antwort die im jeweiligen Rubriktext beschriebenen Kriterien erfüllt [50]. Eine verwandte Variante nutzt Ankerantworten verschiedener Stufen als implizite Rubriken, sei es über Ähnlichkeitsvergleiche [4] oder als Knoten eines relationalen Netzes [33].

Der Vorteil dieser Formulierung ist ihre Flexibilität: Sie ist unabhängig von einem globalen Labelinventar und damit unmittelbar auf ungesehene Rubriksätze anwendbar. Der Nachteil ist ihr Aufwand. Bezeichnet c die Kosten eines Vorwärtspasses, so erfordert die Bewertung einer Instanz $K_i \cdot c$ statt c, sowohl im Training als auch zur Inferenzzeit. Bei großen Backbones und

umfangreichen Datensätzen wird dies schnell prohibitiv. Rubric Retrieval tauscht damit Effizienz gegen Flexibilität ein. Abbildung 2.5 stellt dieses Verfahren der klassischen Klassifikation und dem im Folgenden entwickelten Span-Alignment gegenüber.

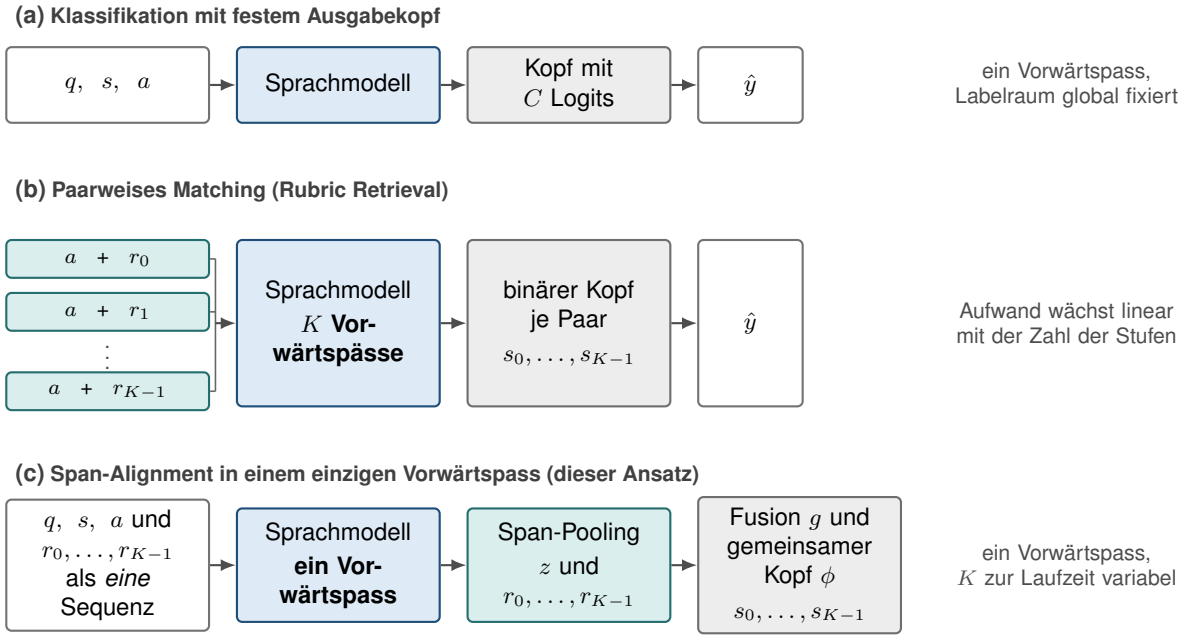


Abbildung 2.5: Fester Klassifikationskopf **(a)**, paarweise Antwort-Rubrik-Kodierung mit K Vorwärtspässen **(b)** und gemeinsame Kodierung mit Span-Pooling in einem Vorwärtspass **(c)**.

Span-Alignment in einem einzigen Vorwärtspass

Einen Ausweg aus diesem Zielkonflikt bietet die gemeinsame Kodierung aller Felder in einer einzigen Sequenz. Gombert u. a. [22] kodieren Antwort und Rubriken zusammen und richten die Repräsentation des Antwort-Spans über ein bilineares Netz an den Repräsentationen der einzelnen Rubrik-Spans aus. Damit entfallen sowohl der feste globale Labelindex als auch die paarweise Expansion.

Das allgemeine Schema dieser Architekturfamilie lässt sich wie folgt fassen. Die Felder aus (2.2) werden zu einer einzigen Zeichenkette serialisiert, wobei die Feldgrenzen markiert werden und die Zeichenpositionen der Rubrik-Spans mitgeführt werden. Nach der Kodierung durch das Sprachmodell liegt eine Zustandsmatrix

$$H_i \in \mathbb{R}^{T \times d} \tag{2.15}$$

vor, wobei T die Sequenzlänge und d die Modelldimension bezeichnet. Aus H_i werden zwei Arten von Repräsentationen extrahiert:

$$r_{i,k} = H_i[e_{i,k}] \qquad \text{Rubrik-Repräsentation der Stufe } k, \tag{2.16}$$

$$z_i = H_i[T] \qquad \text{Sequenzrepräsentation.} \tag{2.17}$$

Dabei bezeichnet $e_{i,k}$ die Position des letzten Tokens des k-ten Rubrik-Spans. Die Wahl des letzten Tokens ist nicht beliebig: Unter kausaler Attention aggregiert der Zustand an der Endposition eines Spans die Information des gesamten vorausgehenden Kontexts einschließlich dieses Spans (vgl. Abschnitt 2.6.2). Analog fasst z_i als Zustand des letzten Sequenztokens die gesamte Eingabe zusammen und wird entsprechend als Eingabe feinjustierter LLM-Klassifikatoren verwendet [46]; für Einbettungsmodelle erweist sich dagegen teils Mean-Pooling als überlegen [3].

Anschließend wird jede Rubrik-Repräsentation mit einer Kontextrepräsentation über eine Fusionsfunktion g verknüpft,

$$v_{i,k} = g\big(z_i,\, r_{i,k}\big), \tag{2.18}$$

und ein gemeinsamer Scoring-Kopf ϕ projiziert das Ergebnis auf einen Skalar,

$$s_{i,k} = \phi(v_{i,k}) \in \mathbb{R}. \tag{2.19}$$

Die Vorhersage ergibt sich als Argmax über die Kandidatenstufen gemäß (2.5). Da ϕ auf einen Skalar und nicht auf C Logits abbildet, ist die Architektur von der Zahl der Rubrikstufen unabhängig und kann Instanzen mit variierendem K_i ohne Modifikation verarbeiten.

Die vorliegende Arbeit setzt an genau dieser Stelle an. Sie untersucht erstens, welche Kontextrepräsentation in (2.18) einzusetzen ist – die Repräsentation des Antwort-Spans, wie bei Gombert u. a. [22], oder die Sequenzrepräsentation z_i –, zweitens, welche Fusionsfunktion g zu wählen ist (Abschnitt 2.8 und Kapitel 4), und drittens, wie Decoder-only-Modelle über die Steuerung der Attention-Maske für diese diskriminative Aufgabe angepasst werden können (Abschnitt 2.6.2).

2.6 Grundlagen der Transformer-Architektur

Sämtliche in dieser Arbeit verwendeten Modelle beruhen auf der Transformer-Architektur [57]. Dieser Abschnitt entwickelt die für das Verständnis der Methodik erforderlichen Komponenten.

Gesamtaufbau

Eine Eingabesequenz wird zunächst durch einen Tokenizer in eine Folge von T Token zerlegt und über eine Einbettungsmatrix $W_E \in \mathbb{R}^{|V|\times d}$ in einen kontinuierlichen Raum abgebildet, was die Ausgangsmatrix $H^{(0)} \in \mathbb{R}^{T\times d}$ liefert. Diese durchläuft L strukturgleiche Blöcke. Jeder Block ℓ besteht aus einer Multi-Head-Self-Attention-Teilschicht und einer positionsweise angewandten Feed-Forward-Teilschicht, die jeweils in eine Residualverbindung eingebettet und durch eine Normalisierungsschicht stabilisiert werden. In der heute üblichen Pre-Norm-Variante gilt

$$\tilde{H}^{(\ell)} = H^{(\ell-1)} + \mathrm{MHA}\big(\mathrm{Norm}(H^{(\ell-1)})\big), \tag{2.20}$$

$$H^{(\ell)} = \tilde{H}^{(\ell)} + \mathrm{FFN}\big(\mathrm{Norm}(\tilde{H}^{(\ell)})\big). \tag{2.21}$$

Als Normalisierung verwendet das ursprüngliche Modell Layer Normalization [1], während die in dieser Arbeit eingesetzten Llama- und Mistral-Modelle die rechnerisch günstigere Root-

Mean-Square-Normalisierung [60] in Pre-Norm-Anordnung nutzen. Diese Anordnung verwendet bereits Llama 2 [55], auf dessen Architektur Llama 3 und Mistral aufbauen [24, 28]. Die Feed-Forward-Teilschicht besteht im ursprünglichen Modell aus zwei linearen Abbildungen mit dazwischenliegender Nichtlinearität; die genannten Modelle verwenden stattdessen eine gated linear unit in der SwiGLU-Variante [48]. Die Ausgabe $H^{(L)}$ der letzten Schicht bildet die in (2.15) verwendete Zustandsmatrix H_i. Abbildung 2.6 fasst Gesamtstapel und Blockaufbau zusammen.

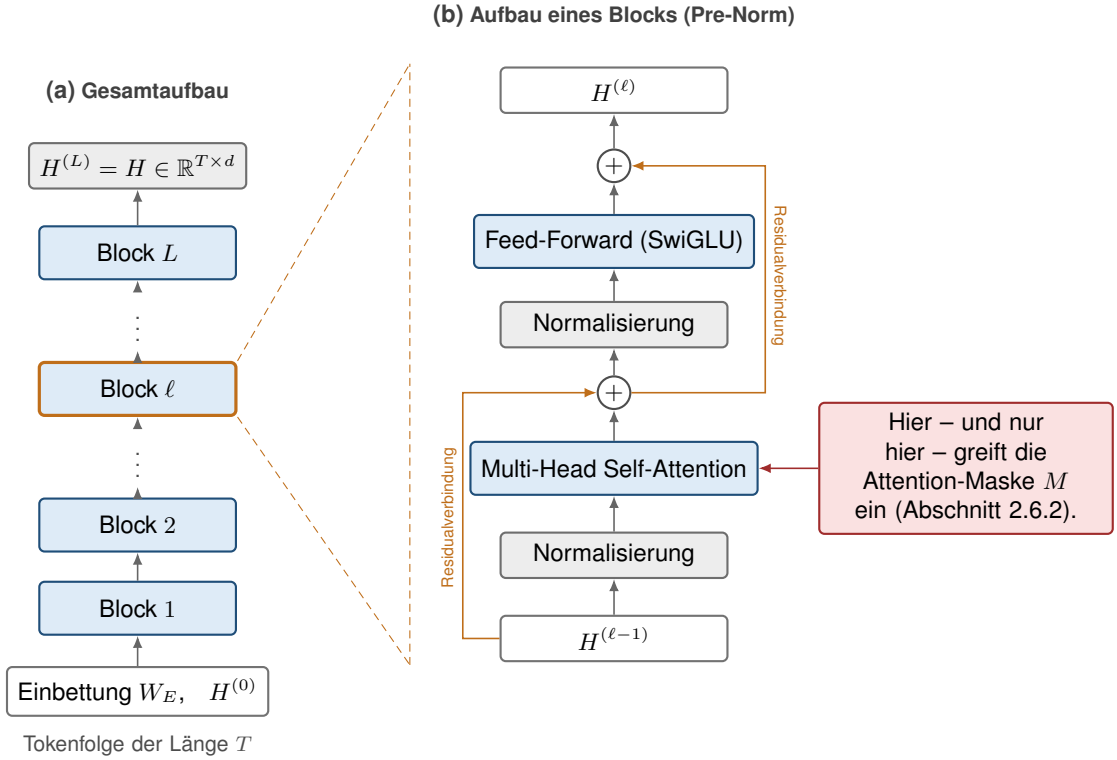


Abbildung 2.6: Gesamtstapel aus L Blöcken **(a)** und einzelner Pre-Norm-Block **(b)** nach (2.20) und (2.21).

Der zentrale architektonische Unterschied zwischen Encoder-only-Modellen wie BERT [13] und Decoder-only-Modellen wie Llama [24] oder Mistral [28] liegt nicht im Blockaufbau, sondern ausschließlich in der Attention-Maske und im Vortrainingsziel; dies wird in Abschnitt 2.6.2 ausgeführt.

2.6.1 Self-Attention und Multi-Head Attention

Self-Attention berechnet für jede Position eine gewichtete Summe über die Repräsentationen aller Positionen, wobei die Gewichte aus der Ähnlichkeit der Positionen zueinander hervorgehen. Ausgehend von $X \in \mathbb{R}^{T\times d}$ werden drei lineare Projektionen gebildet,

$$Q = XW_Q, \qquad K = XW_K, \qquad V = XW_V, \tag{2.22}$$

mit $W_Q, W_K \in \mathbb{R}^{d \times d_k}$ und $W_V \in \mathbb{R}^{d \times d_v}$. Die Zeilen von Q, K und V werden als Anfrage-, Schlüssel- und Wertvektoren bezeichnet. Die Attention-Ausgabe ist

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right) V. \tag{2.23}$$

Die Matrix $S = QK^\top \in \mathbb{R}^{T \times T}$ enthält in Eintrag S_{ij} das Skalarprodukt zwischen der Anfrage an Position i und dem Schlüssel an Position j, also ein unnormiertes Maß der Relevanz von Position j für Position i. Der Softmax wird zeilenweise angewandt, sodass die Attention-Gewichte α_{ij} für jedes i eine Wahrscheinlichkeitsverteilung über j bilden:

$$\alpha_{ij} = \frac{\exp\left(S_{ij}/\sqrt{d_k}\right)}{\sum_{j'=1}^{T} \exp\left(S_{ij'}/\sqrt{d_k}\right)}, \qquad \text{Attention}(Q, K, V)_i = \sum_{j=1}^{T} \alpha_{ij}\, V_j. \tag{2.24}$$

Die Skalierung mit $1/\sqrt{d_k}$ verhindert, dass der Softmax bei großen Dimensionen in Sättigungsbereiche mit verschwindenden Gradienten gerät [57].

Multi-Head Attention führt h solcher Operationen mit eigenen Projektionen parallel aus, konkateniert deren Ausgaben und projiziert sie mit W_O zurück auf die Modelldimension; die einzelnen Köpfe können so unterschiedliche Beziehungstypen erfassen. Die in dieser Arbeit verwendeten Modelle nutzen die Variante Grouped-Query Attention, bei der sich mehrere Anfrageköpfe einen Satz von Schlüssel- und Wertköpfen teilen [28, 24].

Der Rechen- und Speicheraufwand der Self-Attention wächst mit $\mathcal{O}(T^2 d)$, da die Matrix S quadratisch in der Sequenzlänge ist. Dies ist für die vorliegende Arbeit unmittelbar relevant, weil die gemeinsame Serialisierung von Frage, Musterlösung, Antwort und sämtlichen Rubriken zu längeren Sequenzen führt als die paarweise Kodierung – ein Aufwand, der jedoch dadurch mehr als aufgewogen wird, dass nur ein statt K_i Vorwärtspässe erforderlich sind (vgl. Abschnitt 2.5).

Kodierung von Positionsinformation

Die Operation (2.23) ist permutationsäquivariant: Eine Umordnung der Eingabepositionen führt zu einer entsprechend umgeordneten Ausgabe, ohne dass die Reihenfolge selbst in die Berechnung einginge. Positionsinformation muss daher explizit eingebracht werden. Das ursprüngliche Modell addiert sinusförmige Positionskodierungen auf die Einbettungen [57], BERT verwendet gelernte absolute Positionseinbettungen [13].

Die in dieser Arbeit eingesetzten Decoder-Modelle nutzen dagegen Rotary Position Embedding (RoPE) [51]. RoPE kodiert die Position nicht additiv, sondern rotiert Anfrage- und Schlüsselvektoren positionsabhängig, sodass das Attention-Logit zweier Positionen nur von ihrem *relativen* Abstand abhängt. Für die vorliegende Arbeit ist allein diese Eigenschaft von Bedeutung: Da RoPE keine Richtungsannahme enthält, bleibt es bei einer Änderung der Attention-Maske unverändert anwendbar, und die in Abschnitt 2.6.2 beschriebene Aufhebung der Kausalität erfordert keine Anpassung der Positionskodierung.

2.6.2 Kausale vs. bidirektionale Attention-Masken

Maskierung als additiver Term

Die Steuerung, welche Positionen einander sehen dürfen, erfolgt über eine additive Maskenmatrix $M \in (\{0\} \cup \{-\infty\})^{T \times T}$, die vor dem Softmax auf die skalierten Logits addiert wird:

$$\text{Attention}(Q, K, V; M) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}} + M\right) V. \tag{2.25}$$

Ein Eintrag $M_{ij} = -\infty$ bewirkt $\exp(\cdot) = 0$ und damit $\alpha_{ij} = 0$: Position i kann Position j nicht beachten. In der Implementierung wird $-\infty$ durch den kleinsten darstellbaren Wert des verwendeten Gleitkommaformats ersetzt.

Zwei Maskentypen sind zu unterscheiden. Die *bidirektionale* Maske schränkt lediglich um Padding-Positionen ein,

$$M_{ij}^{\text{bidir}} = \begin{cases} 0, & \text{falls Position } j \text{ ein gültiges Token ist,} \\ -\infty, & \text{sonst,} \end{cases} \tag{2.26}$$

sodass jede Position jede andere sieht. Dies ist die Maske von Encoder-only-Modellen wie BERT und RoBERTa, deren Vortraining über Masked Language Modeling folgerichtig einen beidseitigen Kontext voraussetzt [13, 36]. Die *kausale* Maske ergänzt die Padding-Bedingung um eine strikte Zukunftssperre,

$$M_{ij}^{\text{kausal}} = \begin{cases} 0, & \text{falls } j \le i \text{ und } j \text{ gültig ist,} \\ -\infty, & \text{sonst,} \end{cases} \tag{2.27}$$

sodass die Attention-Gewichtsmatrix untere Dreiecksgestalt annimmt. Diese Maske ist konstitutiv für Decoder-only-Modelle: Sie stellt sicher, dass die Vorhersage des Tokens an Position $i+1$ ausschließlich auf den Positionen $1, \ldots, i$ beruht, und macht damit das Training auf allen Positionen einer Sequenz parallel möglich. Abbildung 2.7 stellt beide Maskentypen gegenüber.

Konsequenzen für diskriminative Nutzung

Aus (2.27) folgt unmittelbar die für diese Arbeit zentrale Asymmetrie: In einem Decoder-only-Modell ist der Zustand $H[i]$ eine Funktion ausschließlich des Präfixes $1, \ldots, i$. Zwei Konsequenzen ergeben sich daraus.

Erstens ist die Wahl des Poolings festgelegt. Da nur die letzte Position die gesamte Sequenz gesehen hat, ist das Last-Token-Pooling $z = H[T]$ die naheliegende Sequenzrepräsentation, während in Encoder-Modellen die `[CLS]`-Position oder ein Mittelwert über alle Positionen verwendet wird. Ebenso folgt daraus die Wahl des *letzten* Tokens eines Rubrik-Spans als Pooling-Anker in (2.16): Nur an dieser Position ist der gesamte Span in die Repräsentation eingegangen.

Zweitens ist die kausale Maske für eine reine Verstehensaufgabe eine unnötige Einschränkung. Für die Bewertung einer Schülerantwort ist die Kausalitätsbedingung nicht sachlich moti-

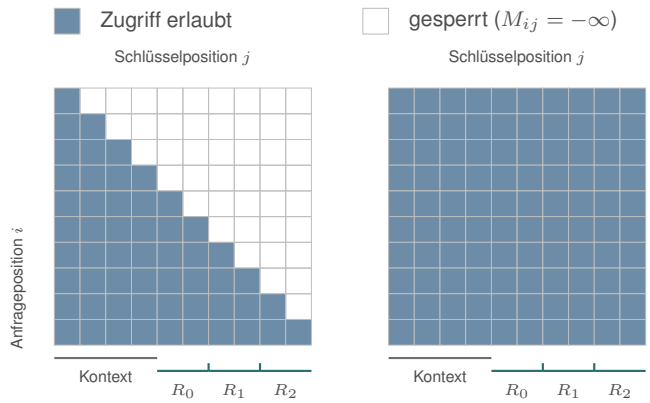


Abbildung 2.7: Kausale **(a)** und bidirektionale **(b)** Attention-Maske für eine Sequenz aus Kontextblock und drei Rubrikblöcken; gefüllte Zellen bezeichnen zugelassene Zugriffe.

viert; das Modell soll die Eingabe verstehen, nicht fortsetzen. Tokens der Antwort können unter kausaler Maske die nachfolgenden Rubriktexte nicht berücksichtigen, obwohl gerade diese Information für die Beurteilung relevant wäre. Genau diese Beobachtung motiviert die Arbeiten zur Umwidmung von LLMs als Encoder [3, 34, 42].

Aufhebung der Kausalität

Der einfachste Eingriff besteht darin, M^{kausal} durch M^{bidir} zu ersetzen und damit die Zukunftssperre aufzuheben. Da die Maske ein rein additiver Term in (2.25) ist, erfordert dieser Eingriff keine Änderung der Gewichte, der Projektionen oder der Positionskodierung: Die skalierte Punktprodukt-Attention und RoPE bleiben unverändert, lediglich die Menge der zugelassenen Schlüsselpositionen wird erweitert.

Der Eingriff ist allerdings nicht folgenlos. Das Modell wurde ausschließlich unter kausaler Maske vortrainiert; die abrupte Erweiterung des sichtbaren Kontexts stellt eine Verschiebung gegenüber der Vortrainingsverteilung dar. BehnamGhader u. a. [3] begegnen dem mit einem zusätzlichen maskierten Weitertrainieren, das dem Modell die Nutzung des beidseitigen Kontexts erst beibringt. Lin u. a. [34] untersuchen den trainingsfreien Fall und identifizieren dabei den *Attention-Sink* als Kernproblem: Autoregressive Modelle konzentrieren einen erheblichen Teil ihrer Attention-Masse auf die ersten Positionen der Sequenz, die als Ablage für überschüssige Aufmerksamkeit dienen [58]. Wird die Maske aufgehoben, verändert sich die Normierung des Softmax in (2.24) für alle Positionen, was diesen Mechanismus stört [34].

Vor diesem Hintergrund ist eine *anteilige* Aufhebung der Kausalität naheliegend, bei der nur die obersten n_{bidir} der L Schichten bidirektional rechnen, während die unteren Schichten kausal

bleiben. Mit Schichtindizes $\ell = 1, \ldots, L$ gilt

$$M^{(\ell)} = \begin{cases} M^{\text{bidir}}, & \text{falls } \ell > L - n_{\text{bidir}}, \\ M^{\text{kausal}}, & \text{sonst}, \end{cases} \qquad n_{\text{bidir}} \in \{0, \ldots, L\}. \tag{2.28}$$

Die Zahl n_{bidir} interpoliert zwischen dem unveränderten Decoder ($n_{\text{bidir}} = 0$) und einem vollständig bidirektionalen Modell ($n_{\text{bidir}} = L$). Zweckmäßig wird sie über einen Anteil ρ der Schichtzahl angegeben; die in dieser Arbeit verwendete Umrechnung, die abrundet und Werte ab 1 als absolute Schichtzahl liest, ist in Abschnitt 4.3.2 angegeben. Die Intuition hinter dieser Konstruktion ist, dass untere Schichten überwiegend lokale, lexikalische und syntaktische Merkmale extrahieren und damit näher am Vortrainingsverhalten bleiben sollen, während obere Schichten aufgabenspezifische Aggregation leisten und dort von einem vollständigen Kontext profitieren können. Die systematische Untersuchung von ρ ist ein Kernbeitrag dieser Arbeit; die konkrete Umsetzung wird in Kapitel 4 beschrieben, die Ergebnisse in Kapitel 5 berichtet. Abbildung 2.8 zeigt die resultierende Schichtaufteilung für die untersuchten Anteile.

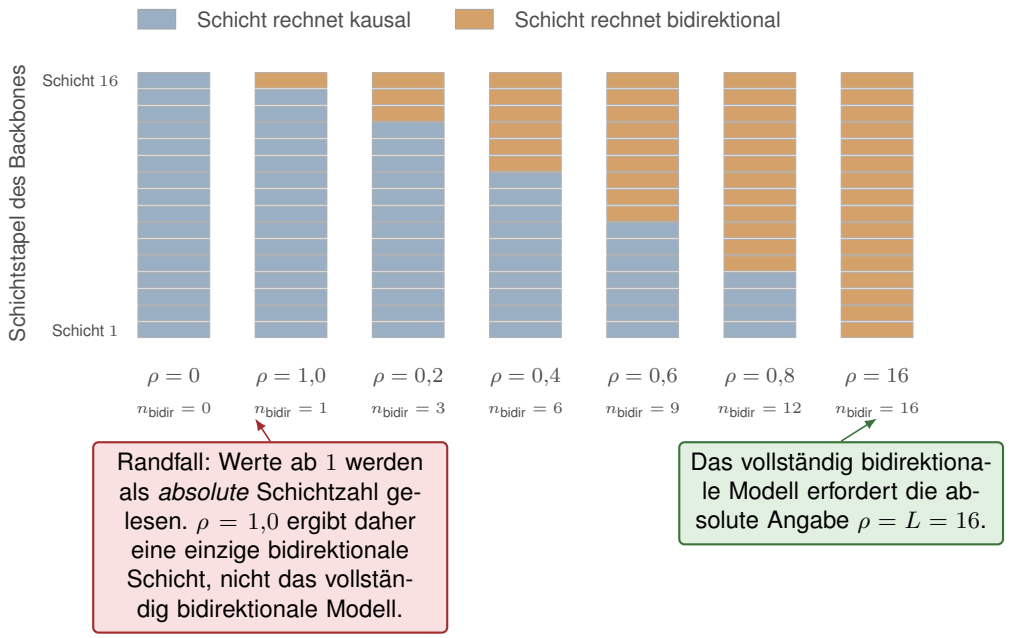


Abbildung 2.8: Anteilige Aufhebung der Kausalität am Beispiel von Llama-3.2-1B ($L = 16$): Die bidirektionalen Schichten bilden stets die oberste Gruppe. $\rho = 1{,}0$ bezeichnet genau eine Schicht (vgl. (4.15)).

2.7 Parameter-effizientes Finetuning (LoRA)

Ein vollständiges Finetuning aller Backbone-Parameter wäre bei der Zahl der in Kapitel 5 untersuchten Konfigurationen weder speicher- noch rechenökonomisch vertretbar. Parametereffiziente Verfahren frieren daher den Großteil der Parameter ein und trainieren nur eine kleine Zahl zusätzlicher Parameter [26, 32].

LoRA [27] parametrisiert die Gewichtsänderung einer eingefrorenen Matrix $W_0 \in \mathbb{R}^{d\times k}$ als Produkt zweier Matrizen niedrigen Rangs $B \in \mathbb{R}^{d\times r}$ und $A \in \mathbb{R}^{r\times k}$ mit $r \ll \min(d, k)$. Der Vorwärtspass der adaptierten Schicht lautet

$$h = W_0 x + \frac{\alpha}{r} BAx, \tag{2.29}$$

wobei der Skalierungsfaktor α/r die effektive Lernrate vom gewählten Rang entkoppelt. Da B mit Nullen initialisiert wird, entspricht das adaptierte Modell zu Trainingsbeginn exakt dem vortrainierten. Die in dieser Arbeit gewählte Konfiguration wird in Abschnitt 4.6 dokumentiert.

Die in Kapitel 4 eingeführten Fusions- und Scoring-Komponenten sind nicht Teil des vortrainierten Backbones. Sie werden zufällig initialisiert und vollständig trainiert, da die Low-Rank-Adaption ausschließlich auf das Sprachmodell angewandt wird.

2.8 Fusionsmechanismen im Rubrik-Antwort-Alignment

Die in Abschnitt 2.5 eingeführte Fusionsfunktion g aus (2.18) ist der Punkt, an dem sich die rubrik-geleiteten Architekturen im ASAG voneinander unterscheiden. Der vorliegende Abschnitt ordnet die in dieser Arbeit verglichenen Mechanismen in diese Linie ein.

Ähnlichkeitsbasierte Verfahren

Die einfachste Form der Verknüpfung verzichtet auf gelernte Parameter und bewertet über ein Ähnlichkeitsmaß. Bexte, Horbach und Zesch [4] kodieren Schülerantwort und Ankerantworten der einzelnen Bewertungsstufen getrennt und vergeben die Stufe mit der höchsten Kosinusähnlichkeit. Die Fusion ist hier also eine feste Funktion $g(u, v) = \cos(u, v)$ ohne trainierbare Komponente. Der Vorteil liegt in der unmittelbaren Übertragbarkeit auf neue Stufenmengen, der Nachteil darin, dass die Passung zwischen Antwort und Kriterium auf eine einzige skalare Größe reduziert wird und keine merkmalsweise Gewichtung möglich ist.

Paarweise Klassifikation

Ein zweiter Ansatz expandiert jede Instanz in Antwort-Rubrik-Paare und lässt ein Modell für jedes Paar entscheiden, ob die Antwort das jeweilige Kriterium erfüllt [50]. Die Fusion findet hier nicht auf der Ebene extrahierter Vektoren statt, sondern implizit innerhalb des Encoders, der beide Texte gemeinsam verarbeitet. Das erlaubt beliebig komplexe Interaktionen, erkauft dies aber mit K Vorwärtspässen je Instanz (Abschnitt 2.5) und verhindert, dass das Modell die Kriterien einer Aufgabe in Beziehung zueinander sieht.

Bilineares Alignment

Gombert u. a. [22] kodieren Antwort und Rubriken gemeinsam und richten die Repräsentation des *Antwort*-Spans über eine bilineare Form

$$g_{\text{bl}}(u, v) = u^\top \mathcal{W} v + b, \qquad \mathcal{W} \in \mathbb{R}^{d \times d}, \tag{2.30}$$

an den Repräsentationen der einzelnen Rubrik-Spans aus. Die bilineare Form erfasst sämtliche paarweisen Merkmalsinteraktionen zwischen beiden Vektoren und ist damit ausdrucksstärker als eine lineare Abbildung über der Konkatenation. Der Preis sind d^2 zusätzliche Parameter, die bei großen Modelldimensionen ins Gewicht fallen und die Überanpassungsneigung erhöhen. Diese Arbeit ist der unmittelbare methodische Bezugspunkt der vorliegenden Untersuchung: Sie etabliert das Prinzip, Rubriken als Spans in einer gemeinsam kodierten Sequenz zu behandeln, wählt als Bezugsgröße jedoch den Antwort-Span statt der Sequenzrepräsentation.

Konkatenative und multiplikative Fusion

Die in dieser Arbeit verglichenen Mechanismen setzen an genau dieser Stelle an und variieren die Konstruktion von v_k bei gleichbleibender übriger Architektur. CONCAT verknüpft beide Repräsentationen rein additiv im nachgeschalteten linearen Kopf, DIFF verwendet allein ihre komponentenweise Differenz, CONDIFF vereint beides, GATE führt eine multiplikative Konditionierung der Kontextrepräsentation durch die Rubrik ein. Die formale Spezifikation erfolgt in Abschnitt 4.2.

Der Vergleich dieser vier Varianten ist im ASAG-Kontext deshalb aufschlussreich, weil sie sich systematisch in der Zahl zusätzlicher, vollständig zu trainierender Parameter unterscheiden – von keinen (CONCAT, DIFF, CONDIFF) bis zu d^2 (GATE) – und damit erlauben, den Beitrag zusätzlicher Fusionskapazität von dem der Repräsentationsqualität des Backbones zu trennen. Eine systematische Gegenüberstellung dieser Varianten in Verbindung mit der Sequenzrepräsentation als Bezugsgröße und über mehrere Backbone-Größen hinweg liegt nach Kenntnisstand dieser Arbeit im ASAG bislang nicht vor; sie bildet den ersten Kernbeitrag der vorliegenden Untersuchung.

3 Datensätze

Die vorliegende Arbeit evaluiert das in Kapitel 4 beschriebene RUSPAN-System auf drei öffentlich verfügbaren ASAG-Benchmarks: ASAP-SAS, Beetle und SciEntsBank. Dieses Kapitel beschreibt Struktur, Statistik und Label-Skala jedes Benchmarks (Abschnitte 3.1 bis 3.3), dokumentiert die Herkunft der Rubriktexte und Musterlösungen (Abschnitt 3.4) und begründet abschließend die Auswahl dieser drei Datensätze für die vergleichende Evaluation (Abschnitt 3.5). Alle berichteten Kennzahlen wurden aus den in dieser Arbeit tatsächlich verwendeten Trainings- und Testdateien berechnet, nicht aus den ursprünglichen Wettbewerbs- bzw. Korpusbeschreibungen, da die konkreten Splits von der jeweiligen Originalveröffentlichung geringfügig abweichen können.

3.1 ASAP-SAS: Struktur, Statistik, Label-Skala

Herkunft und Format

Das Automated Student Assessment Prize – Short Answer Scoring (ASAP-SAS) ist ein von der Hewlett Foundation in Zusammenarbeit mit Kaggle im Jahr 2012 ausgerichteter Wettbewerb zur automatisierten Bewertung kurzer, konstruierter Schülerantworten [54, 2]. An ihm beteiligten sich sowohl öffentliche Teilnehmende als auch kommerzielle Anbieter von Scoring-Systemen; eine Auswertung der Ergebnisse gibt Shermis [49]. Der Datensatz umfasst zehn unabhängige Aufgaben (*items*) aus den Fächern Naturwissenschaften (*Science*), Biologie und Englisch/Sprachkunde (*English*, *English Language Arts*), bearbeitet von Schülerinnen und Schülern der achten beziehungsweise zehnten Klassenstufe. Jede Instanz besteht aus der Frage q, der Schülerantwort a sowie einer vom Aufgabenersteller vergebenen ganzzahligen Bewertungsstufe y. ASAP-SAS enthält – anders als Beetle und SciEntsBank – von den Aufgabenerstellern verfasste, aufgabenspezifische Bewertungsrichtlinien (*general_scoring_rubrics*), jedoch keine Musterlösung s; Letztere wird für die vorliegende Arbeit sprachmodellgestützt ergänzt (Abschnitt 3.4).

Variable Label-Skala

Ein struktureller Sonderfall von ASAP-SAS gegenüber den beiden anderen Benchmarks ist die je Aufgabe unterschiedliche Bewertungsskala: Vier der zehn Aufgaben verwenden eine vierstufige Skala $\{0, 1, 2, 3\}$, die übrigen sechs eine dreistufige Skala $\{0, 1, 2\}$. Tabelle 3.1 listet

Fach, Klassenstufe, Label-Skala sowie Instanzzahlen je Aufgabe auf. Diese Variabilität ist der unmittelbare empirische Anlass für die in Abschnitt 2.1 eingeführte rubrik-konditionierte Aufgabenformulierung (2.5): Ein Modell mit festem Klassifikationskopf gemäß (2.4) kann nicht ohne Weiteres über alle zehn Aufgaben hinweg gemeinsam trainiert werden, da die Ausgabedimension zwischen 4 und 3 wechselt.

Die Stufen sind ungleich verteilt. Über alle Aufgaben des Trainingssplits entfallen $39{,}5\,\%$ der Antworten auf Stufe 0, $32{,}7\,\%$ auf Stufe 1, $23{,}4\,\%$ auf Stufe 2 und $4{,}3\,\%$ auf Stufe 3. Innerhalb einzelner Aufgaben ist das Ungleichgewicht teils ausgeprägt: Bei den Biology-Items 5 und 6 erhalten $77{,}5\,\%$ beziehungsweise $84{,}3\,\%$ der Antworten die Stufe 0, bei Item 4 entfallen nur $7{,}7\,\%$ auf die höchste Stufe. Die Science-Items 1 und 2 sind dagegen vergleichsweise ausgeglichen.

Tabelle 3.1: ASAP-SAS: Aufgabenübersicht mit Fach, Klassenstufe, Label-Skala und Instanzzahlen (berechnet aus `train.csv` / `test_ua.csv`).

Item	Fach	Klasse	Label-Skala	Train n	Test n (UA)
1	Science	10	$\{0,1,2,3\}$	1 672	557
2	Science	10	$\{0,1,2,3\}$	1 278	426
3	English Language Arts	10	$\{0,1,2\}$	1 808	406
4	English Language Arts	10	$\{0,1,2\}$	1 657	295
5	Biology	10	$\{0,1,2,3\}$	1 795	598
6	Biology	10	$\{0,1,2,3\}$	1 797	599
7	English	10	$\{0,1,2\}$	1 799	599
8	English	10	$\{0,1,2\}$	1 799	599
9	English	10	$\{0,1,2\}$	1 798	599
10	Science	8	$\{0,1,2\}$	1 640	546
Gesamt				**17 043**	**5 224**

Antwortlänge und Splits

Die Schülerantworten sind im Mittel $42{,}3$ Wörter lang (Median 39, Maximum 325 Wörter im Trainingssplit) und damit deutlich länger als die Antworten in Beetle und SciEntsBank (vgl. Abschnitte 3.2 und 3.3). Dies spiegelt den Aufgabentyp wider: Mehrere Items verlangen die Nennung mehrerer Teilaspekte (z. B. die Beschreibung mehrerer Schritte eines biologischen Prozesses), was die Bewertungsskala mit bis zu vier Stufen erklärt – die Stufe kodiert dabei häufig die Anzahl korrekt genannter Teilaspekte. Für ASAP-SAS liegt in dieser Arbeit ausschließlich der Unseen-Answers-Split (UA) vor (vgl. Abschnitt 2.1): Die Testantworten stammen zu denselben zehn Aufgaben wie das Training, sodass ASAP-SAS keine Aussage über die Generalisierung auf neue Fragen erlaubt, wohl aber die Bewertungskonvention einer variablen, aufgabenspezifischen Skala testet.

3.2 Beetle: Domäne und Test-Splits

Herkunft und Domäne

Der Beetle-Korpus entstand im Rahmen der Evaluation des BEETLE-II-Tutorendialogsystems und enthält Schülerantworten auf Erklärungs- und Definitionsfragen aus dem Bereich elementarer Elektrizitätslehre und Elektronik (Stromkreise, Spannung, Kurzschlüsse). Er wurde zusammen mit SciEntsBank im Rahmen von SemEval-2013 Task 7 als gemeinsamer Benchmark für die automatisierte Bewertung von Schülerantworten veröffentlicht [16]. Anders als ASAP-SAS liegt für Beetle eine native Musterlösung s vor; zusammen mit den generierten Rubriktexten (Abschnitt 3.4) besteht jede Instanz damit vollständig aus dem Tupel $(q, s, a, \mathcal{R})$ gemäß (2.2).

Aufgabenstruktur und Label-Skala

Der Datensatz umfasst 56 Fragen, die sich in drei thematische Gruppen mit den Präfixen `FF` (23 Fragen), `PC` (21 Fragen) und `SC` (12 Fragen) gliedern. Inhaltlich betreffen die `FF`-Fragen überwiegend Spannungsmessungen an einzelnen Anschlussklemmen, während unter den `SC`-Fragen mehrfach explizit nach Kurzschlüssen (*short circuits*) gefragt wird. Für jede Frage liegt eine einheitliche, dreistufige ordinale Bewertungsskala vor, deren Stufen inhaltlich *Incorrect*, *Partially Correct* und *Correct* entsprechen und in den Rubriktexten explizit so benannt werden. Im Trainingssplit entfallen $34{,}4\,\%$ der Antworten auf *Incorrect*, $23{,}3\,\%$ auf *Partially Correct* und $42{,}2\,\%$ auf *Correct*; die mittlere Stufe ist damit die seltenste.

Test-Splits

Beetle stellt zwei Testsplits bereit (Tabelle 3.2). Der Unseen-Answers-Split (UA) verwendet dieselben 47 Fragen wie das Training, jedoch disjunkte Schülerantworten. Der Unseen-Questions-Split (UQ) enthält 9 Fragen, die im Training nicht vorkommen; eine Prüfung der Fragen-IDs bestätigt, dass die Schnittmenge zwischen Trainings- und UQ-Fragen leer ist. Damit erlaubt Beetle – im Unterschied zu ASAP-SAS – eine Aussage über die Generalisierung auf neue, aber domänengleiche Fragen.

Tabelle 3.2: Beetle: Instanzzahlen und Fragenzahlen je Split (berechnet aus den bereitgestellten CSV-Dateien).

Split	Instanzen n	Fragen	Bezug zu Training
Train	3 941	47	—
Test (UA)	439	47	dieselben Fragen, neue Antworten
Test (UQ)	819	9	neue, disjunkte Fragen

Die Schülerantworten sind mit durchschnittlich $9{,}8$ Wörtern (Median 9) deutlich kürzer als in ASAP-SAS, was der Aufgabenstellung entspricht: Die Fragen verlangen typischerweise eine

ein- bis zweisätzige Begründung eines beobachteten Phänomens (z. B. einer Spannungsmessung) und nicht die Aufzählung mehrerer Teilaspekte.

3.3 SciEntsBank: Domäne und Test-Splits

Herkunft und Domäne

SciEntsBank wurde gemeinsam mit Beetle im Rahmen von SemEval-2013 Task 7 veröffentlicht [16] und deckt im Unterschied zu dessen eng gefasster Domäne Elektrizitätslehre ein breites Spektrum naturwissenschaftlicher Themen ab. Die in dieser Arbeit verwendete Fassung umfasst 200 Fragen-IDs, hinter denen 196 verschiedene Fragen stehen: Vier Fragen tragen im Trainingssplit eine um das Suffix `p` erweiterte ID (etwa `PS.26p` statt `PS.26`), bei identischer Frage und Musterlösung. Anhand ihrer ID-Präfixe gliedern sich die Fragen in 15 Themenblöcke (u. a. `ME`, `WA`, `MX`, `PS`, `SE`, `HB`, `EM`, `LF`, `VB`, `FN`, `MS`, `ST`, `EV`, `II`, `LP` mit zwischen 3 und 25 Fragen je Block). Wie bei Beetle liegen für jede Instanz Frage, Musterlösung und Rubriktexte vor.

Label-Skala

SciEntsBank verwendet in seiner ursprünglichen SemEval-Fassung ein fünfstufiges nominales Bewertungsschema (*correct*, *partially_correct_incomplete*, *contradictory*, *irrelevant*, *non_domain*), das – wie in Abschnitt 2.2 diskutiert – keine Ordinalstruktur aufweist. Die vorliegende Arbeit verwendet stattdessen, wie in der jüngeren ASAG-Literatur üblich, eine reduzierte Fassung mit den drei ordinalen Stufen *incorrect*, *partially correct* und *correct*. Von den 196 Fragen sind 167 mit dieser vollständigen dreistufigen Skala annotiert; die verbleibenden 29 Fragen liegen nur zweistufig vor (*incorrect* vs. *correct*, ohne mittlere Stufe). Diese Heterogenität der Stufenzahl *innerhalb* eines einzelnen Benchmarks ist ein weiterer empirischer Beleg für die Notwendigkeit der variablen Kandidatenmenge $\mathcal{Y}_i$ aus Formel (2.5). Im Trainingssplit verteilen sich die Antworten zu $32{,}9\,\%$ auf *incorrect*, $26{,}6\,\%$ auf *partially correct* und $40{,}4\,\%$ auf *correct*.

Test-Splits

SciEntsBank stellt als einziger der drei verwendeten Benchmarks alle drei in Abschnitt 2.1 eingeführten Generalisierungsbedingungen bereit (Tabelle 3.3): Unseen Answers (UA), Unseen Questions (UQ) und Unseen Domains (UD). Eine Prüfung der Fragen-ID-Präfixe bestätigt die intendierte Struktur der Splits: Die 46 Fragen des UD-Splits stammen ausschließlich aus den drei Themenblöcken `WA`, `HB` und `EV`, die im Trainingssplit *vollständig* fehlen – der UD-Split testet damit tatsächlich den Transfer auf gänzlich neue thematische Bereiche und nicht nur auf neue Einzelfragen. Der Trainingssplit deckt die übrigen zwölf Themenblöcke ab. Der UQ-Split umfasst 15 Fragen aus elf dieser zwölf Themenblöcke, jedoch ohne Überschneidung der konkreten Fragen-IDs. Der UA-Split schließlich enthält zusätzliche, disjunkte Testantworten zu allen 135 Trainingsfragen; bei den vier oben genannten Fragen weicht lediglich die ID um das Suffix `p` ab.

Tabelle 3.3: SciEntsBank: Instanzzahlen und Fragenzahlen je Split (berechnet aus den bereitgestellten CSV-Dateien).

Split	Instanzen n	Fragen	Bezug zu Training
Train	4 969	135	—
Test (UA)	540	135	dieselben Fragen, neue Antworten
Test (UQ)	733	15	neue Fragen, bekannte Themenblöcke
Test (UD)	4 562	46	neue Fragen aus ungesehenen Themenblöcken

Die Schülerantworten sind mit durchschnittlich $11{,}4$ Wörtern (UD) bis $12{,}6$ Wörtern (Training) ähnlich kurz wie in Beetle. Aufgrund der großen Zahl an Fragen und Themenblöcken sowie der Verfügbarkeit des UD-Splits ist SciEntsBank unter den drei verwendeten Benchmarks derjenige mit der größten thematischen Diversität und der anspruchsvollsten Generalisierungsbedingung.

3.4 Herkunft der Rubriktexte und Musterlösungen

Keiner der drei verwendeten Benchmarks stellt sämtliche Felder des Tupels (2.2) nativ bereit. Da die vorliegende Arbeit die Rubriktexte zum zentralen Gegenstand macht, ist ihre Herkunft ausdrücklich festzuhalten.

ASAP-SAS enthält von den Aufgabenerstellenden verfasste, aufgabenspezifische Bewertungsrichtlinien, aber keine Musterlösung. Letztere wurde sprachmodellgestützt allein aus der Aufgabenstellung erzeugt.

Beetle und SciEntsBank enthalten umgekehrt native Musterlösungen, aber keine Bewertungsrichtlinien. Die in dieser Arbeit verwendeten Rubriktexte wurden für beide Benchmarks mit `gpt-4o-mini` erzeugt. Als Eingabe dienten dabei die Aufgabenstellung, die verfügbaren Referenzantworten sowie bis zu zehn Beispiel-Schülerantworten je Bewertungsstufe.

Diese Herkunft ist für die Interpretation der Ergebnisse wesentlich. Die erzeugten Texte sind keine von der Aufgabenbeschreibung unabhängige Informationsquelle, sondern eine aus ihr abgeleitete Umformulierung, die deren Inhalt erkennbar mit aufnimmt. Für die SciEntsBank-Frage *What is the difference between a rock and a mineral?* etwa hält die Beschreibung der höchsten Stufe fest, korrekte Antworten unterschieden zutreffend zwischen Gestein und Mineral und stellten dar, dass Gestein aus mehreren Mineralen bestehe, ein Mineral dagegen aus einer einzigen Substanz – also genau den Inhalt der zugehörigen Musterlösung. Abschnitt 5.3.2 zeigt, dass sich diese Nähe empirisch niederschlägt: Rubriktexte und Aufgabenkontext erweisen sich dort als weitgehend austauschbar.

Zwei Einschränkungen sind festzuhalten. Erstens sind die für die Erzeugung verwendeten Arbeitsabläufe nicht Bestandteil der bereitgestellten Codebasis; die Prompts und die genaue Auswahl der Beispielantworten konnten daher nicht eingesehen werden. Zweitens und daraus folgend lässt sich nicht überprüfen, aus welchem Split die herangezogenen Beispiel-Schülerantworten stammen. Wurden ausschließlich Trainingsantworten verwendet, ist das Vorgehen unbedenklich. Wären dagegen auch Testantworten eingeflossen, so enthielten die Ru-

briktexte Information über die Testmenge, und die rubrik-konditionierten Ergebnisse wären insbesondere auf dem UA-Split optimistisch verzerrt. Diese Frage konnte im Rahmen der vorliegenden Arbeit nicht geklärt werden und ist bei der Bewertung der Absolutwerte zu berücksichtigen; die in Kapitel 5 geführten Vergleiche *zwischen* Konfigurationen sind davon nicht betroffen, da sämtliche Bedingungen dieselben Rubriktexte verwenden.

3.5 Vergleich der Benchmarks und Auswahlbegründung

Abbildung 3.1 stellt Umfang und Split-Struktur der drei Benchmarks im Größenvergleich dar; Tabelle 3.4 ergänzt die qualitativen Merkmale. Die Auswahl ist nicht redundant, sondern gezielt komplementär in drei Hinsichten.

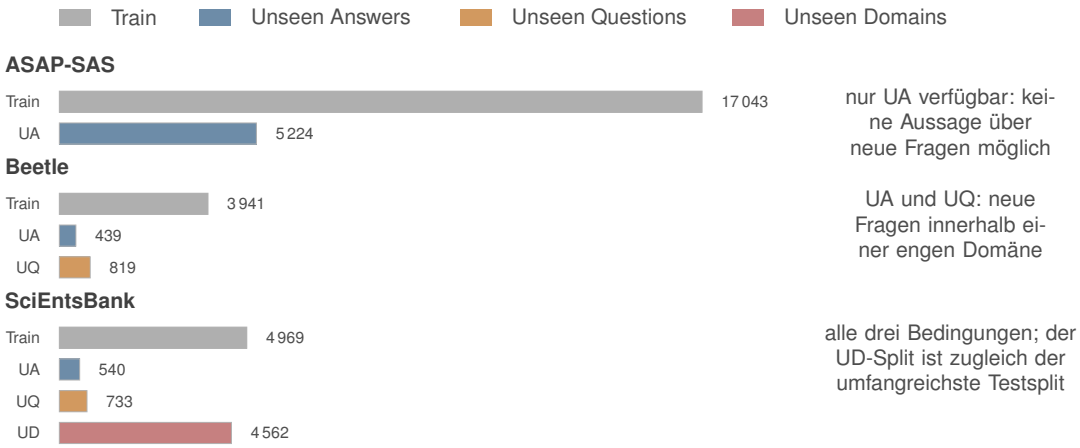


Abbildung 3.1: Umfang der Trainings- und Testsplits der drei Benchmarks; die Balkenlängen sind proportional zur Instanzzahl. ASAP-SAS stellt ausschließlich die UA-Bedingung bereit, der größte Testsplit ist SciEntsBank UD.

Tabelle 3.4: Gegenüberstellung der drei verwendeten ASAG-Benchmarks.

	ASAP-SAS	**Beetle**	**SciEntsBank**
Domäne	Naturwiss. / Sprache, 10 Einzelaufgaben	Elektrizitätslehre (eng, 1 Domäne)	breites naturwiss. Spektrum (15 Themen)
Native Rubriken	ja (aufgabenspez.)	nein (generiert)	nein (generiert)
Native Musterlösung	nein (generiert)	ja	ja
Label-Skala	variabel, 3–4-stufig, je Aufgabe fest	einheitlich, 3-stufig ordinal	einheitlich, überw. 3-stufig ordinal
Verfügbare Splits	UA	UA, UQ	UA, UQ, UD
Antwortlänge (Median)	39 Wörter	9 Wörter	11 Wörter
Trainingsumfang	17 043	3 941	4 969

Variabilität der Label-Skala. ASAP-SAS ist unter den drei Benchmarks der einzige mit einer zwischen Einzelaufgaben wechselnden Stufenzahl und stellt damit den unmittelbaren empiri-

schen Testfall für die in Abschnitt 2.1 motivierte rubrik-konditionierte Formulierung (2.5) dar, unter der ein Modell mit festem Klassifikationskopf nicht anwendbar ist. Beetle und SciEntsBank besitzen dagegen überwiegend eine einheitliche, dreistufige Skala und dienen so als Kontrollfälle, in denen der Vorteil der variablen Formulierung nicht aus einer unterschiedlichen Stufenzahl, sondern ausschließlich aus der semantischen Rubrik-Konditionierung selbst resultieren muss.

Verfügbarkeit von Generalisierungssplits. Nur SciEntsBank stellt mit dem UD-Split eine echte Domänentransfer-Bedingung bereit; Beetle erlaubt mit UQ immerhin den Test auf neue Fragen innerhalb derselben engen Domäne, während ASAP-SAS ausschließlich die UA-Bedingung zulässt. Diese Abstufung erlaubt es, die in Kapitel 5 berichteten Ergebnisse nach Generalisierungsanforderung gestaffelt zu interpretieren, anstatt sich auf eine einzelne, womöglich durch lexikalische Überlappung begünstigte Testbedingung zu verlassen.

Antwortlänge und Domänenbreite. ASAP-SAS unterscheidet sich von Beetle und SciEntsBank auch strukturell: Die Antworten sind im Mittel drei- bis viermal so lang, die Aufgaben stammen aus unterschiedlichen Schulfächern statt aus einer einzelnen naturwissenschaftlichen Domäne, und die Zahl der Trainingsinstanzen ist deutlich größer. Beetle deckt mit seiner engen Fokussierung auf Elektrizitätslehre das gegenteilige Extrem ab – eine einzelne, in sich konsistente technische Domäne mit kurzen, präzisen Antworten –, während SciEntsBank mit 15 Themenblöcken eine mittlere Domänenbreite bei ebenfalls kurzen Antworten bietet. Die drei Benchmarks unterscheiden sich damit systematisch in Antwortlänge, Domänenbreite und Aufgabenfach, wodurch überprüft werden kann, ob die in Kapitel 4 entwickelte Architektur robust über diese Variationsachsen hinweg funktioniert oder ob ihre Wirksamkeit an bestimmte strukturelle Eigenschaften eines Benchmarks gebunden ist.

Weitere im RUSPAN-Softwareprojekt verfügbare Benchmarks – insbesondere ein deutschsprachiger Datensatz (ALICE), ein portugiesischsprachiger Datensatz (PT-ASAG) sowie iStudio – werden im Rahmen dieser Arbeit nicht ausgewertet, da der Fokus auf dem monolingualen, englischsprachigen Vergleich der Fusionsmechanismen und der bidirektionalen Attention liegt. Ihre Auswertung wird in Kapitel 7 als mögliche Erweiterung angesprochen.

4 Methodik: Das RUSPAN-System

Dieses Kapitel entwickelt das in dieser Arbeit untersuchte System. Abschnitt 4.1 beschreibt die Gesamtarchitektur, das Eingabeformat und die Extraktion der Span-Repräsentationen. Abschnitt 4.2 spezifiziert die vier verglichenen Fusionsmechanismen CONDIFF, CONCAT, DIFF und GATE. Abschnitt 4.3 entwickelt die anteilige Aufhebung der kausalen Attention-Maske. Abschnitt 4.4 stellt die verwendeten Backbone-Modelle vor, Abschnitt 4.5 spezifiziert die für die Ablationsexperimente benötigten Varianten, und Abschnitt 4.6 dokumentiert die Trainingskonfiguration.

Die in Kapitel 2 eingeführte Notation wird durchgängig weitergeführt: $H_i \in \mathbb{R}^{T \times d}$ bezeichnet die Zustandsmatrix der letzten Encoder-Schicht, z_i die Sequenzrepräsentation, $r_{i,k}$ die Repräsentation des k-ten Rubrik-Spans und g die Fusionsfunktion. Der Instanzindex i wird im Folgenden weggelassen, wo er nicht zur Unterscheidung benötigt wird.

4.1 Systemarchitektur: Span-Alignment-Modell

Überblick

Das System realisiert die in Abschnitt 2.5 skizzierte Architekturfamilie in vier Verarbeitungsschritten:

1. **Serialisierung.** Die textuellen Felder einer Instanz werden zu einer einzigen Zeichenkette zusammengesetzt. Dabei werden die Zeichenpositionen der Antwort und jedes Rubrik-Spans mitgeführt.
2. **Kodierung.** Die Sequenz wird in *einem* Vorwärtspass durch das Sprachmodell verarbeitet; das Ergebnis ist die Zustandsmatrix $H \in \mathbb{R}^{T \times d}$.
3. **Span-Pooling.** Aus H werden die Sequenzrepräsentation z und für jede Bewertungsstufe k die Rubrik-Repräsentation r_k extrahiert.
4. **Alignment und Scoring.** Jedes Paar (z, r_k) wird über die Fusionsfunktion g verknüpft und durch einen gemeinsamen Scoring-Kopf auf einen Skalar s_k abgebildet. Über die Skalare wird eine Verteilung gebildet und listwise, das heißt über alle Kandidatenstufen einer Instanz gemeinsam, optimiert (Gleichung (4.12)).

Der entscheidende Unterschied zu einem Klassifikator mit festem Ausgabekopf liegt in Schritt 4: Der Scoring-Kopf bildet auf *einen* Skalar je Kandidatenstufe ab, nicht auf einen Vektor fester

Länge. Die Zahl der Ausgaben ergibt sich damit zur Laufzeit aus der Zahl der Rubrik-Spans in der Eingabe und nicht aus der Architektur. Abbildung 4.1 zeigt die vollständige Verarbeitungskette.

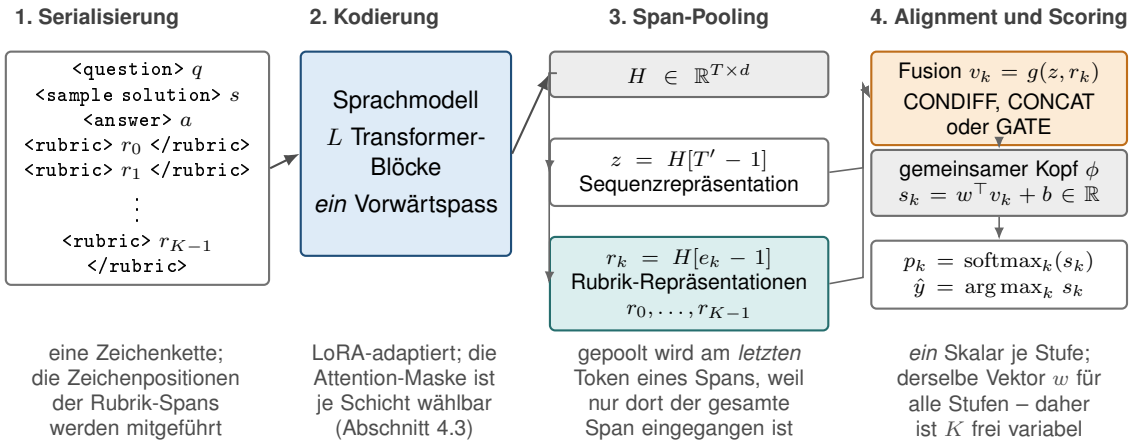


Abbildung 4.1: Verarbeitungskette des Span-Alignment-Modells: Serialisierung, Kodierung in einem Vorwärtspass, Pooling von z und r_k, Fusion und ein Skalar je Kandidatenstufe.

4.1.1 Eingabeformat

Serialisierung mit Feldmarkierungen

Die Felder einer Instanz werden mit XML-artigen Marken versehen und zeilenweise konkateniert. Für eine Instanz mit K Bewertungsstufen entsteht die Zeichenkette

<question> q </question>
<sample solution> s </sample solution>
<answer> a </answer>
<rubric> r_0 </rubric>
<rubric> r_1 </rubric>
⋮
<rubric> r_{K-1} </rubric>
[Instruktion]

Die Marken erfüllen zwei Funktionen. Erstens strukturieren sie die Eingabe für das Sprachmodell, das aus dem Vortraining mit XML-artiger Auszeichnung vertraut ist. Zweitens – und für die Architektur wesentlich – liefern die schließenden Marken `</rubric>` eindeutige, im Zeichenstrom lokalisierbare Endpositionen der Rubrik-Spans, an denen später gepoolt wird.

Die Reihenfolge ist nicht beliebig: Die Rubriken stehen *nach* allen übrigen Feldern und damit insbesondere nach der Schülerantwort. Unter kausaler Attention (Abschnitt 2.6.2) folgt daraus, dass jede Rubrik-Repräsentation die vorausgehende Eingabe einschließlich der Schülerantwort gesehen hat – die Rubrik-Repräsentation ist also nicht die Einbettung eines isolierten Textes, sondern eine *kontextualisierte* Repräsentation der Bewertungsstufe angesichts der konkret

vorliegenden Antwort. Diese Eigenschaft ist der eigentliche Mechanismus, über den die Architektur Antwort und Kriterium in Beziehung setzt.

Die Kandidatenstufen werden in aufsteigender Reihenfolge der Bewertungsstufe serialisiert. Die niedrigste Stufe steht damit stets an erster, die höchste an letzter Position.

Optionale Bestandteile

Sowohl der Aufgabenkontext (Frage und Musterlösung) als auch die abschließende Instruktion sind konfigurierbar und können weggelassen werden. Für die vorliegende Arbeit ist diese Konfiguration ausdrücklich festzuhalten: **Sämtliche Hauptläufe wurden ohne Aufgabenkontext und ohne abschließende Instruktion durchgeführt** (`add_context` $=$ `False`, `add_suffix` $=$ `False`). Die einzige Ausnahme bildet das in Abschnitt 4.5.3 beschriebene Kontext-Experiment, das diese Festlegung gezielt aufhebt. Die tatsächlich verarbeitete Eingabe besteht damit ausschließlich aus der Schülerantwort und den K Rubriktexten:

<answer> a </answer>
<rubric> r_0 </rubric>
$\vdots$
<rubric> r_{K-1} </rubric>

Der Einfluss dieser Festlegung ist keine bloße Formalie, sondern für die Interpretation der Ergebnisse wesentlich. Ohne Frage und Musterlösung muss die Sequenzrepräsentation z die gesamte Bewertungsgrundlage aus der Antwort und den Rubriktexten rekonstruieren; das Modell erfährt insbesondere nicht, *worauf* die vorliegende Antwort überhaupt antwortet. Die Rubriktexte sind damit die einzige aufgabenbezogene Information in der Eingabe – ein Umstand, der die in Abschnitt 5.3.2 berichtete Ablation besonders scharf macht: Wird auch sie entfernt, verbleibt allein der Antworttext.

Tokenisierung

Die serialisierte Zeichenkette wird mit dem Tokenizer des jeweiligen Backbones kodiert. Die maximale Sequenzlänge beträgt 2048 Token; längere Eingaben werden rechtsseitig abgeschnitten. Die Auffüllung kürzerer Sequenzen innerhalb eines Batches erfolgt ebenfalls rechtsseitig (*right padding*); als Füll-Token dient bei den Decoder-Modellen das EOS-Token. Diese Festlegung ist für das Pooling relevant und wird in Abschnitt 4.1.2 wieder aufgegriffen.

4.1.2 Span-Extraktion und Pooling

Abbildung von Zeichen- auf Token-Positionen

Die Serialisierung liefert die Spans zunächst als Zeichenintervalle. Da die Tokenisierung Zeichenpositionen nicht längentreu auf Token-Positionen abbildet, werden die Intervalle über das vom Tokenizer bereitgestellte *offset mapping* übersetzt. Für ein Zeichenintervall $[c_{\text{start}}, c_{\text{end}})$

wird die Token-Startposition als dasjenige Token bestimmt, dessen Zeichenintervall c_{start} enthält, und die Token-Endposition analog als das erste Token, dessen Intervall bei c_{end} endet oder darüber hinausreicht. Die resultierenden Token-Spans folgen der Konvention halboffener Intervalle

$$\text{Span}_k = [\, b_k,\ e_k \,), \qquad b_k, e_k \in \{0, \ldots, T\}, \tag{4.1}$$

das heißt e_k ist die Position *nach* dem letzten Token des Spans.

Rubrik-Repräsentationen

Für jede Bewertungsstufe k wird die Repräsentation als Zustand des *letzten* Tokens des zugehörigen Spans gebildet:

$$r_k = H\big[e_k - 1\big] \in \mathbb{R}^d. \tag{4.2}$$

Die Wahl der Endposition folgt unmittelbar aus der Kausalität: Unter der Maske (2.27) ist $H[j]$ eine Funktion aller Positionen $\leq j$; nur an der Endposition des Spans ist der gesamte Rubriktext in die Repräsentation eingegangen. Konkret fällt diese Position auf ein Token der schließenden Marke `</rubric>`, was den zusätzlichen Vorteil hat, dass der Pooling-Anker für alle Stufen und alle Benchmarks strukturell identisch ist.

Alternativ unterstützt die Implementierung eine Mittelung über alle Token des Spans,

$$r_k^{\text{mean}} = \frac{1}{e_k - b_k} \sum_{j=b_k}^{e_k-1} H[j], \tag{4.3}$$

die in den hier berichteten Experimenten jedoch nicht verwendet wird.

Sequenzrepräsentation

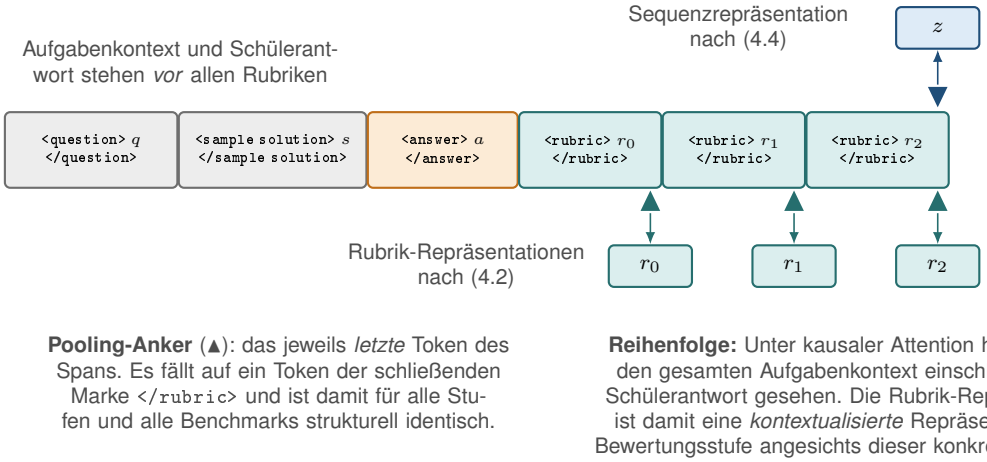
Die Sequenzrepräsentation wird als Zustand des letzten *gültigen* Tokens der Sequenz gebildet. Bezeichnet $m \in \{0,1\}^T$ die Padding-Maske und $T' = \sum_j m_j$ die tatsächliche Sequenzlänge – das Symbol L bleibt der Zahl der Transformer-Schichten vorbehalten –, so gilt bei rechtsseitiger Auffüllung und ab 0 gezählten Positionen

$$z = H\big[T' - 1\big] \in \mathbb{R}^d. \tag{4.4}$$

Vor dem Pooling werden die Zustände an Padding-Positionen auf null gesetzt und ein Dropout mit Rate $0{,}1$ angewandt. Da die Rubriken am Ende der Sequenz stehen, hat z unter kausaler Attention die gesamte Eingabe einschließlich *aller* Rubriktexte gesehen. z ist damit keine reine Antwortrepräsentation, sondern eine Zusammenfassung der gesamten Bewertungssituation. Abbildung 4.2 zeigt Serialisierung, Span-Grenzen und Pooling-Anker im Zusammenhang.

Abgrenzung zur Antwort-Span-Repräsentation

Die Implementierung extrahiert zusätzlich eine Repräsentation des Antwort-Spans nach demselben Verfahren wie (4.2). Diese wird für die in dieser Arbeit untersuchten Varianten jedoch



Pooling-Anker (▲): das jeweils *letzte* Token des Spans. Es fällt auf ein Token der schließenden Marke `</rubric>` und ist damit für alle Stufen und alle Benchmarks strukturell identisch.

Reihenfolge: Unter kausaler Attention hat jedes r_k den gesamten Aufgabenkontext einschließlich der Schülerantwort gesehen. Die Rubrik-Repräsentation ist damit eine *kontextualisierte* Repräsentation der Bewertungsstufe angesichts dieser konkreten Antwort.

Abbildung 4.2: Serialisierung einer Instanz mit drei Bewertungsstufen. Gepoolt wird am letzten Token jedes Rubrik-Spans (r_k) und der gesamten Sequenz (z); z hat damit auch sämtliche Rubriktexte gesehen.

nicht als Kontext verwendet: Sämtliche berichteten Fusionsmechanismen (Abschnitt 4.2) verknüpfen die Rubrik-Repräsentation mit der *Sequenz*-Repräsentation z, nicht mit der Antwort-Repräsentation. Die Alternative – Alignment von Antwort- und Rubrik-Span – entspricht dem Ansatz von Gombert u. a. [22] und dient in dieser Arbeit als konzeptioneller Bezugspunkt.

Umgang mit variabler Stufenzahl

Da die Zahl der Bewertungsstufen K_i zwischen Instanzen variiert (vgl. Kapitel 3), werden die Instanzen eines Batches auf die maximale vorkommende Stufenzahl $K_{\max}$ aufgefüllt. Eine Gültigkeitsmaske $m^{\text{rub}} \in \{0,1\}^{B\times K_{\max}}$ markiert die realen Stufen. Die Scores der Auffüllpositionen werden vor der Normalisierung auf $-\infty$ gesetzt und tragen damit weder zur Verteilung noch zum Gradienten bei.

4.2 Fusionsmechanismen

Die Fusionsfunktion g aus (2.18) verknüpft die Sequenzrepräsentation $z \in \mathbb{R}^d$ mit einer Rubrik-Repräsentation $r_k \in \mathbb{R}^d$ zu einem Vektor v_k, den ein gemeinsamer, für alle Stufen identischer linearer Scoring-Kopf auf einen Skalar abbildet:

$$s_k = w^\top \operatorname{Dropout}(v_k) + b, \qquad w \in \mathbb{R}^{d_g},\ b \in \mathbb{R}, \tag{4.5}$$

wobei d_g die von der jeweiligen Fusionsfunktion erzeugte Dimension ist und die Dropout-Rate $0{,}1$ beträgt. Dass *derselbe* Vektor w für alle Stufen verwendet wird, ist die architektonische Bedingung dafür, dass die Zahl der Stufen frei variieren kann: Der Kopf lernt kein stufenspezifisches Muster, sondern eine allgemeine Passungsbewertung zwischen Bewertungssituation und Kriterienbeschreibung.

Die vier verglichenen Mechanismen unterscheiden sich ausschließlich in der Konstruktion von v_k und damit in der Art der modellierten Interaktion.

4.2.1 CONDIFF: Conditional-Difference-Fusion

CONDIFF konkateniert beide Repräsentationen und ergänzt ihre komponentenweise Differenz:

$$v_k^{\text{CONDIFF}} = \left[\, z \parallel r_k \parallel (z - r_k) \,\right] \in \mathbb{R}^{3d}, \qquad d_g = 3d. \tag{4.6}$$

Der Differenzterm ist der eigentliche Gegenstand der Variante. Ein linearer Kopf über der reinen Konkatenation berechnet $w_z^\top z + w_r^\top r_k$, also eine additive Verrechnung zweier unabhängig gewichteter Beiträge. Ein solcher Ausdruck kann Übereinstimmung zwischen z und r_k nur indirekt darstellen. Der Differenzterm stellt dagegen die komponentenweise Abweichung explizit bereit: Ist die Bewertungssituation in denjenigen Dimensionen, die das Kriterium beschreibt, mit der Rubrik verträglich, so liegen die entsprechenden Komponenten von $z - r_k$ nahe null. Der Kopf kann damit Passung als Nähe zum Nullvektor auswerten, statt sie aus zwei separaten Termen rekonstruieren zu müssen. Diese Konstruktion überträgt das aus der Satzpaarmodellierung bekannte heuristische Matching [40, 12, 9, 44] auf das Paar aus Sequenz- und Rubrik-Repräsentation.

Bemerkenswert ist, dass der Differenzterm keine zusätzlichen Parameter im Fusionsschritt selbst einführt – er ist eine parameterfreie Transformation. Der Mehraufwand entsteht ausschließlich im Scoring-Kopf, dessen Eingabedimension von $2d$ auf $3d$ wächst, was d zusätzliche Parameter bedeutet.

4.2.2 CONCAT: Einfache Konkatenation als Baseline

CONCAT verzichtet auf den Differenzterm und konkateniert lediglich:

$$v_k^{\text{CONCAT}} = \left[\, z \parallel r_k \,\right] \in \mathbb{R}^{2d}, \qquad d_g = 2d. \tag{4.7}$$

CONCAT ist als *ablative* Baseline konzipiert: Sie ist mit CONDIFF in allen Komponenten identisch – gleiche Span-Extraktion, gleiches Pooling, gleicher Kopf-Typ, gleiche Verlustfunktion – und unterscheidet sich ausschließlich durch das Fehlen von $(z - r_k)$. Ein Leistungsunterschied zwischen beiden Varianten ist daher dem Differenzterm zurechenbar und nicht auf konfundierende Architekturunterschiede zurückzuführen. Umgekehrt zeigt ein ausbleibender Unterschied an, dass der Kopf die Vergleichsoperation auch ohne explizite Bereitstellung hinreichend gut aus der Konkatenation lernen kann.

4.2.3 DIFF: Differenz als alleinige Eingabe

DIFF bildet das Gegenstück zu CONCAT: Statt der beiden Repräsentationen erhält der Kopf allein ihre komponentenweise Differenz,

$$v_k^{\text{DIFF}} = z - r_k \in \mathbb{R}^d, \qquad d_g = d. \tag{4.8}$$

Zusammen mit CONCAT zerlegt DIFF die Konstruktion von CONDIFF in ihre beiden Bestandteile: CONDIFF (4.6) enthält genau die Komponenten von CONCAT (4.7) und DIFF (4.8) zugleich. Die drei Varianten erlauben damit eine vollständige Zurechnung. Ein Vorteil von CONDIFF gegenüber CONCAT ist dem Differenzterm zuzuschreiben; erreicht DIFF allein dasselbe Niveau wie CONDIFF, tragen die unveränderten Einzelrepräsentationen keine zusätzliche verwertbare Information. Wie CONCAT und CONDIFF ist DIFF im Fusionsschritt parameterfrei; der Kopf ist mit $d_g = d$ sogar kleiner als bei beiden.

4.2.4 GATE: Gated Fusion

GATE ersetzt die konkatenative durch eine multiplikative Verknüpfung. Aus der Rubrik-Repräsentation wird ein komponentenweises Gate berechnet, das die Sequenzrepräsentation moduliert; eine Residualverbindung und eine Layer-Normalisierung stabilisieren das Ergebnis:

$$\gamma_k = \sigma\big(W_g\, r_k + b_g\big) \in (0,1)^d, \tag{4.9}$$

$$v_k^{\mathsf{GATE}} = \mathrm{LayerNorm}\big(z + z \odot \gamma_k\big) \in \mathbb{R}^d, \qquad d_g = d, \tag{4.10}$$

mit $W_g \in \mathbb{R}^{d\times d}$, σ als logistischer Funktion und $\odot$ als komponentenweisem Produkt.

Die Konstruktion ist wie folgt zu lesen. Das Gate γ_k hängt *ausschließlich* von der Rubrik ab und wirkt als kriteriumsspezifischer Merkmalsfilter: Für jede Dimension der Sequenzrepräsentation entscheidet die Rubrik, wie stark diese Dimension in die Bewertung dieser Stufe eingeht. Merkmale, die für das betrachtete Kriterium irrelevant sind, können unterdrückt werden. Der Residualterm z in (4.10) stellt sicher, dass die ungefilterte Sequenzinformation erhalten bleibt und das Gate nur eine additive Verstärkung beisteuert; wegen $\gamma_k \in (0,1)^d$ wirkt der Ausdruck $z + z \odot \gamma_k$ als komponentenweise Skalierung von z mit Faktoren in $(1,2)$. Die Layer-Normalisierung fängt die dadurch entstehende Skalenverschiebung ab.

Anders als CONDIFF, CONCAT und DIFF führt GATE zusätzliche Parameter im Fusionsschritt ein: die Gate-Projektion W_g mit d^2 Parametern sowie die Normalisierungsparameter. Bei $d = 4096$ (Mistral-7B) sind dies allein für W_g rund $1{,}7 \cdot 10^7$ zusätzliche, vollständig zu trainierende Parameter. Da die Fusionsmodule nicht Teil des LoRA-adaptierten Backbones sind, sondern von Grund auf trainiert werden (Abschnitt 4.6), ist GATE damit die parameterreichste der vier Varianten und potenziell anfälliger für Überanpassung – ein Aspekt, der bei der Interpretation der Ergebnisse in Kapitel 5 zu berücksichtigen ist.

Übersicht

Abbildung 4.3 stellt drei der vier Mechanismen schematisch gegenüber – DIFF entspricht dem Differenzzweig von CONDIFF und wird dort nicht eigens gezeigt –, Tabelle 4.1 fasst die Kennzahlen aller vier zusammen.

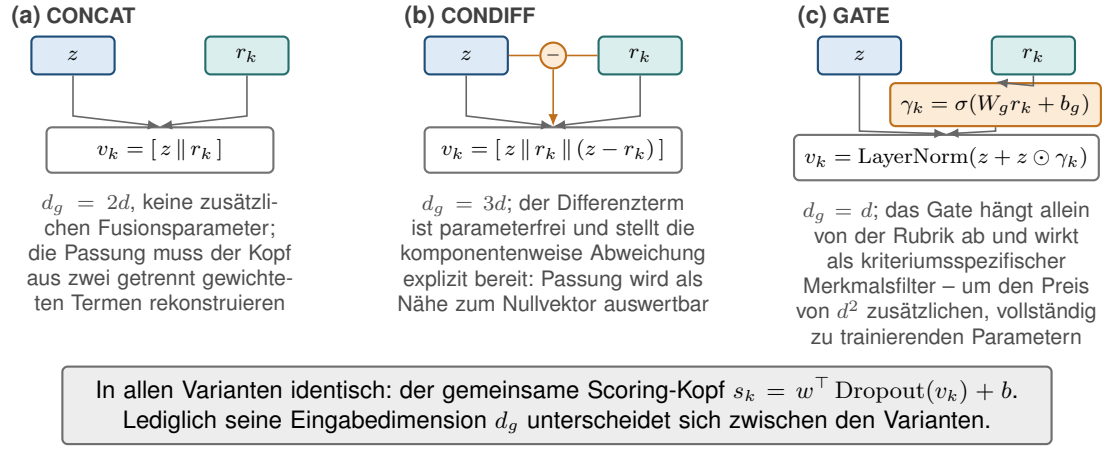


Abbildung 4.3: Konstruktion von v_k in CONCAT **(a)**, CONDIFF **(b)** und GATE **(c)**. DIFF (4.8) entspricht dem orangefarbenen Zweig in **(b)**.

Tabelle 4.1: Die vier verglichenen Fusionsmechanismen. d bezeichnet die Modelldimension, d_g die Eingabedimension des Scoring-Kopfs.

Variante	**Konstruktion von v_k**	d_g	**Zusätzl. Parameter**
CONCAT	$[z \,\|\, r_k]$	$2d$	—
DIFF	$z - r_k$	d	—
CONDIFF	$[z \,\|\, r_k \,\|\, (z - r_k)]$	$3d$	—
GATE	$\mathrm{LayerNorm}(z + z \odot \sigma(W_g r_k + b_g))$	d	$W_g \in \mathbb{R}^{d \times d}$, LayerNorm

Trainingsziel

Unabhängig vom Fusionsmechanismus werden die Skalare s_k über die gültigen Kandidatenstufen normalisiert:

$$p_k = \frac{\exp(s_k)}{\sum_{k' \in \mathcal{Y}_i} \exp(s_{k'})}, \tag{4.11}$$

und über die Trainingsmenge wird der Kreuzentropieverlust bezüglich der Referenzstufe y_i minimiert:

$$\mathcal{L} = -\frac{1}{N} \sum_{i=1}^{N} \log p_{i,y_i}. \tag{4.12}$$

Diese Formulierung ist *listwise*: Sie bewertet alle Kandidatenstufen einer Instanz gemeinsam und in Konkurrenz zueinander, statt jede Antwort-Rubrik-Paarung isoliert als binäre Entscheidung zu behandeln. Der Gradient drückt den Score der korrekten Stufe nach oben und die Scores der übrigen Stufen *derselben Instanz* nach unten; das Modell lernt damit eine relative Rangordnung zwischen den Kriterien einer konkreten Aufgabe. Formal ist (4.12) identisch mit dem Kreuzentropieverlust eines Klassifikators, jedoch über eine instanzabhängige Kandidatenmenge statt über einen festen Labelraum. Die Vorhersage erfolgt als Argmax über die Kandidatenstufen gemäß (2.5).

4.3 Bidirektionale Attention in Decoder-only-Modellen

4.3.1 Motivation

Die in Abschnitt 2.6.2 entwickelte Beobachtung wird hier auf die konkrete Architektur angewandt. Unter kausaler Maske gilt für die Repräsentationen aus (4.2) und (4.4) eine Asymmetrie, die sich aus der Serialisierungsreihenfolge ergibt:

- Die Tokens der **Schülerantwort** stehen vor allen Rubriken. Sie können daher *keine* Rubrik sehen. Die Antwort wird also kodiert, ohne dass das Modell weiß, gegen welche Kriterien sie zu prüfen ist.
- Die Repräsentation r_k der k**-ten Rubrik** sieht den Kontext, die Antwort und alle *vorangehenden* Rubriken $r_0, \ldots, r_{k-1}$, nicht aber die nachfolgenden. Die Repräsentationen der Stufen sind damit untereinander asymmetrisch konditioniert: Die erste Stufe wird ohne Kenntnis der Alternativen kodiert, die letzte mit vollständiger Kenntnis.

Beide Asymmetrien sind sachlich nicht motiviert. Für die Bewertungsaufgabe ist die zeitliche Ordnung der Felder ein Artefakt der Serialisierung, kein inhaltliches Merkmal: Eine menschliche Bewertungskraft liest Kriterien und Antwort in beliebiger Reihenfolge und wechselt zwischen beiden. Die Aufhebung der Kausalität stellt genau diese wechselseitige Sichtbarkeit her – die Antwort-Tokens können die Kriterien einbeziehen, und alle Stufen werden unter gleichen Sichtbarkeitsbedingungen kodiert.

Dem steht der in Abschnitt 2.6.2 diskutierte Einwand gegenüber: Das Backbone wurde ausschließlich unter kausaler Maske vortrainiert. Eine vollständige Aufhebung stellt eine Abweichung von der Vortrainingsverteilung dar und kann etablierte Mechanismen wie den Attention-Sink [58] stören [34]. Statt sich zwischen beiden Extremen zu entscheiden, behandelt diese Arbeit den Grad der Aufhebung als kontinuierlich steuerbaren Parameter.

4.3.2 Umsetzung: Anteilige Aufhebung der kausalen Maske

Schichtweise Maskenwahl

Sei L die Zahl der Transformer-Schichten des Backbones und $n_{\text{bidir}} \in \{0, \ldots, L\}$ die Zahl der bidirektional rechnenden Schichten. Die bidirektionalen Schichten werden stets als *oberste* zusammenhängende Gruppe gewählt; die Schichtindizes werden hier, abweichend von (2.28), entsprechend der Implementierung ab 0 gezählt:

$$\mathcal{B} = \left\{ \ell \;:\; L - n_{\text{bidir}} \leq \ell < L \right\}, \tag{4.13}$$

und die in Schicht ℓ verwendete Maske ist

$$M^{(\ell)} = \begin{cases} M^{\text{bidir}}, & \ell \in \mathcal{B}, \\ M^{\text{kausal}}, & \text{sonst}, \end{cases} \tag{4.14}$$

mit M^{bidir} und M^{kausal} gemäß (2.26) und (2.27). Die Wahl der obersten Schichten folgt der Überlegung, dass untere Schichten überwiegend lokale lexikalische und syntaktische Merkmale extrahieren und daher näher an den Vortrainingsbedingungen bleiben sollten, während die aufgabenspezifische Aggregation in den oberen Schichten stattfindet und dort von vollständiger Sichtbarkeit profitieren kann.

Eingriffstiefe

Der Eingriff beschränkt sich auf den additiven Maskenterm in (2.25). Unverändert bleiben insbesondere:

- sämtliche Gewichte des Backbones einschließlich der Projektionen W_Q, W_K, W_V, W_O,
- die Positionskodierung: RoPE wird unverändert angewandt, die Positionsindizes bleiben die ursprünglichen. Dies ist möglich, weil RoPE nur relative Positionen kodiert und keine Richtungsannahme enthält (Abschnitt 2.6.1),
- die Berechnungsvorschrift der skalierten Punktprodukt-Attention selbst.

Konkret wird für die betroffenen Schichten lediglich die Maskenmatrix ausgetauscht: Statt der unteren Dreiecksstruktur wird eine reine Padding-Maske übergeben, die alle gültigen Positionen wechselseitig sichtbar macht. Zusätzlich wird das Kausalitäts-Flag der betroffenen Attention-Module deaktiviert, damit effiziente Attention-Implementierungen nicht ihrerseits eine kausale Maske ergänzen. Der Eingriff ist damit minimal und erlaubt eine saubere Zuschreibung beobachteter Effekte.

Parametrisierung über einen Anteil

Da die drei Backbones unterschiedlich viele Schichten besitzen (Abschnitt 4.4), wird n_{bidir} nicht absolut, sondern über einen Anteil ρ spezifiziert. Die Umrechnung erfolgt nach

$$n_{\text{bidir}}(\rho) = \begin{cases} 0, & \rho = 0, \\ \max\big(1,\ \lfloor \rho \cdot L \rfloor\big), & 0 < \rho < 1, \\ \rho, & \rho \geq 1 \text{ und } \rho \in \mathbb{N}, \end{cases} \tag{4.15}$$

das heißt Werte im offenen Intervall $(0, 1)$ werden als Anteil der Schichtzahl interpretiert und abgerundet, während Werte ab 1 als absolute Schichtzahl gelesen werden. Tabelle 4.2 gibt die resultierenden Schichtzahlen für die untersuchten Anteile und Backbones an; Abbildung 2.8 veranschaulicht die Aufteilung am Beispiel von Llama-3.2-1B.

Auf die Randfälle sei ausdrücklich hingewiesen. Für $\rho = 0$ ist das Modell mit dem unveränderten Decoder identisch; diese Bedingung entspricht den Läufen ohne Bidir-Kennzeichnung. Die Untergrenze $\max(1, \cdot)$ in (4.15) stellt sicher, dass ein von null verschiedener Anteil stets mindestens eine Schicht umfasst. Der Wert $\rho = 1$ fällt gemäß (4.15) bereits in den Zweig der absoluten Angabe und bezeichnet daher *eine* Schicht, nicht das vollständig bidirektionale Modell; für Letzteres ist $\rho = L$ zu setzen.

Tabelle 4.2: Aus dem Anteil ρ resultierende Zahl bidirektionaler Schichten n_{bidir} je Backbone nach Vorschrift (4.15). Die Zeilen sind nach der tatsächlichen Zahl bidirektionaler Schichten geordnet, nicht nach dem nominellen Wert von ρ. Die vollständig bidirektionale Bedingung $\rho = L$ liegt für Llama-3.2-1B und -3B vor, für Mistral-7B nicht; unter drei Zufallssaaten liegt sie für beide Llama-Größen vor.

ρ	**Llama-3.2-1B** ($L = 16$)	**Llama-3.2-3B** ($L = 28$)	**Mistral-7B** ($L = 32$)
$1{,}0$	1	1	1
$0{,}2$	3	5	6
$0{,}4$	6	11	12
$0{,}6$	9	16	19
$0{,}8$	12	22	25
$\rho = L$	16	28	32

Verhältnis zum Fusionsmechanismus

Die Variation von ρ ist orthogonal zur Wahl des Fusionsmechanismus. Um beide Effekte getrennt beurteilen zu können, wird der Fusionsmechanismus in allen Läufen mit variiertem ρ auf CONDIFF festgehalten. Unterschiede zwischen diesen Läufen sind damit ausschließlich der Attention-Maske zuzuschreiben.

4.4 Verwendete Backbone-Modelle

Die Architektur ist backbone-agnostisch: Sie setzt lediglich voraus, dass das Modell eine Zustandsmatrix $H \in \mathbb{R}^{T \times d}$ liefert und dass Token-Spans in dieser Matrix lokalisierbar sind. Untersucht werden drei Decoder-only-Modelle unterschiedlicher Größe sowie zwei Encoder-Modelle als Vergleichsbasis.

4.4.1 Llama-3.2-1B/3B

Die beiden kleineren Backbones stammen aus der Llama-3.2-Familie. Sie folgen der für Llama 3 beschriebenen Architektur [24]; ihre Modellkonfiguration weist dieselben Kennwerte aus, darunter acht Key-Value-Köpfe und die RoPE-Basis $500\,000$. Es handelt sich um Decoder-only-Transformer mit Pre-Norm-Aufbau, RMS-Normalisierung [60], SwiGLU-Feed-Forward-Schichten [48], Grouped-Query Attention und RoPE als Positionskodierung [51]. Die 1B-Variante besitzt 16 Schichten bei einer Modelldimension von $d = 2048$, die 3B-Variante 28 Schichten bei $d = 3072$.

Der Größenunterschied zwischen beiden Varianten ist für diese Arbeit von eigenem Interesse: Er erlaubt es zu prüfen, ob die Wirksamkeit der Fusionsmechanismen und der bidirektionalen Attention von der Kapazität des Backbones abhängt. Insbesondere ist zu erwarten, dass ein parameterreicher Fusionsmechanismus wie GATE bei kleineren Backbones relativ stärker ins

Gewicht fällt, da das Verhältnis zwischen neu trainierten Fusionsparametern und adaptierten Backbone-Parametern günstiger ausfällt.

4.4.2 Mistral-7B

Als größtes Backbone dient Mistral-7B-v0.1 [28] mit 32 Schichten und einer Modelldimension von $d = 4096$. Das Modell verwendet ebenfalls Pre-Norm, RMS-Normalisierung, SwiGLU und RoPE, ergänzt um Grouped-Query Attention und Sliding-Window Attention zur Effizienzsteigerung bei langen Sequenzen.

Die Einbindung erfolgt über dieselbe Erweiterung wie bei Llama: Die schichtweise Maskenwahl nach (4.14) ist für beide Modellfamilien identisch implementiert, sodass die Bidir-Bedingungen über alle drei Decoder-Backbones hinweg vergleichbar sind.

4.4.3 BERT/RoBERTa als Encoder-Baseline

Als Vergleichsbasis dienen BERT-base-uncased [13] und RoBERTa-base [36]. Beide sind Encoder-only-Modelle mit 12 Schichten und $d = 768$, die bereits im Vortraining vollständig bidirektional rechnen. Sie erlauben damit die Beantwortung einer naheliegenden Frage: Wenn bidirektionale Sichtbarkeit für die Aufgabe vorteilhaft ist, wie schneidet dann ein Modell ab, das diese Eigenschaft von Grund auf besitzt – allerdings bei geringerer Kapazität und ohne das Weltwissen großer Sprachmodelle?

Die Span-Alignment-Architektur wird für die Encoder-Baselines unverändert übernommen; angepasst wird lediglich die Serialisierung. Da die Encoder-Tokenizer keine XML-artigen Marken als strukturelle Trenner vortrainiert haben, werden die Felder stattdessen durch das modelleigene `[SEP]`-Token getrennt, und der Rubrik-Span wird so festgelegt, dass er das nachfolgende `[SEP]`-Token einschließt. Der Pooling-Anker nach (4.2) fällt damit auf dieses Trennzeichen, das die strukturelle Rolle der schließenden Marke `</rubric>` übernimmt. Die Fusionsmechanismen, der Scoring-Kopf und die Verlustfunktion bleiben identisch, sodass der Vergleich zwischen Encoder- und Decoder-Backbones die Architektur konstant hält.

4.5 Varianten für die Ablationsexperimente

Neben den vier Fusionsmechanismen und der Variation der Attention-Maske werden in Kapitel 5 fünf weitere Konfigurationen ausgewertet. Vier davon dienen nicht der Verbesserung des Systems, sondern der Zurechnung beobachteter Leistung auf einzelne Bestandteile; die fünfte prüft die Übertragbarkeit eines trainierten Modells zwischen Benchmarks. Dieser Abschnitt spezifiziert sie.

4.5.1 Fester Klassifikationskopf als Baseline

Die grundlegendste Vergleichsbedingung verzichtet vollständig auf das Span-Alignment. Die Eingabe wird unverändert serialisiert und kodiert, und auch die Sequenzrepräsentation z wird

nach (4.4) gebildet; die Rubrik-Repräsentationen r_k werden jedoch nicht in die Bewertung einbezogen. Stattdessen bildet eine einzelne lineare Abbildung

$$\big(s_0, \ldots, s_{C-1}\big)^\top = W_{\text{cls}}\, \mathrm{Dropout}(z) + b_{\text{cls}}, \qquad W_{\text{cls}} \in \mathbb{R}^{C \times d}, \tag{4.16}$$

die Sequenzrepräsentation direkt auf C Logits ab, und optimiert wird der gewöhnliche Kreuzentropieverlust über den festen Labelraum. Diese Variante entspricht damit exakt der klassischen Formulierung (2.4) aus Abschnitt 2.1.

Zwei Eigenschaften sind für die Auswertung wesentlich. Erstens *sieht* das Modell die Rubriktexte weiterhin – sie sind Teil der serialisierten Eingabe und gehen über die kausale Attention in z ein; sie werden lediglich nicht als Spans ausgelesen. Ein Vergleich dieser Variante mit dem Span-Alignment misst daher den Beitrag der expliziten Span-Extraktion, nicht den der Rubrikinformation (Abschnitt 5.3.1). Zweitens setzt (4.16) eine über alle Instanzen konstante Stufenzahl C voraus. Die Variante ist deshalb auf ASAP-SAS nicht anwendbar, dessen Stufenzahl je Aufgabe zwischen drei und vier wechselt (Kapitel 3) – ein unmittelbarer praktischer Beleg für die in Abschnitt 2.1 gegebene Begründung der rubrik-konditionierten Formulierung.

4.5.2 Ablation der Rubriktexte

Für die Ablation werden sämtliche Rubriktexte vor der Serialisierung aus der Instanz entfernt. Die Eingabe besteht dann nur noch aus denjenigen Feldern, die nach der Konfiguration des Aufgabenkontexts verbleiben. Da die Rubrik-Spans dadurch entfallen, ist diese Bedingung ausschließlich mit dem festen Klassifikationskopf aus Abschnitt 4.5.1 kombinierbar; die Implementierung erzwingt dies. Alle übrigen Bestandteile – Backbone, LoRA-Konfiguration, Pooling, Kopf, Verlustfunktion, sämtliche Hyperparameter – bleiben unverändert, sodass ein beobachteter Unterschied allein dem Vorhandensein der Rubriktexte zurechenbar ist.

4.5.3 Variation des Aufgabenkontexts

Wie in Abschnitt 4.1.1 dokumentiert, enthalten die Hauptläufe dieser Arbeit weder Frage noch Musterlösung. Um den Beitrag der Rubriktexte von dem der Aufgabenbeschreibung zu trennen, wird diese Festlegung in einem eigenen Experiment aufgehoben: Frage und Musterlösung werden der Serialisierung vorangestellt, alles Übrige bleibt unverändert. In Verbindung mit der Ablation aus Abschnitt 4.5.2 ergibt sich ein vollständiges 2×2-Schema über die Verfügbarkeit beider Informationsquellen, das in Abschnitt 5.3.2 ausgewertet wird.

4.5.4 Antwort-Span als Bezugsgröße der Fusion

Die in Abschnitt 4.2 spezifizierten Mechanismen verwenden durchgängig die Sequenzrepräsentation z als Bezugsgröße. Zur Prüfung dieser Entwurfsentscheidung wird eine Variante untersucht, die stattdessen die Repräsentation des Antwort-Spans heranzieht. Diese wird nach demselben Verfahren wie die Rubrik-Repräsentationen gebildet, also als Zustand des letzten Tokens des Antwort-Spans,

$$t = H\big[e_{\text{ans}} - 1\big] \in \mathbb{R}^d, \tag{4.17}$$

und tritt in der Fusion an die Stelle von z:

$$v_k^{\text{t-concat}} = \left[\, t \parallel r_k \,\right] \in \mathbb{R}^{2d}. \tag{4.18}$$

Die Variante ist damit die exakte Entsprechung von CONCAT (4.7) mit ausgetauschter Bezugsgröße; jeder Unterschied ist allein dieser Vertauschung zuzuschreiben. Inhaltlich unterscheiden sich beide Größen darin, welchen Kontext sie gesehen haben: Unter kausaler Maske steht t *vor* allen Rubriktexten und kennt diese nicht, während z am Sequenzende steht und sämtliche Stufen gesehen hat. Diese Variante entspricht zugleich dem Ansatz von Gombert u. a. [22], die das Alignment am Antwort-Span verankern; ihre Auswertung erfolgt in Abschnitt 5.4.2.

4.5.5 Übertragung zwischen Benchmarks

In allen bisher beschriebenen Konfigurationen werden Training und Test auf demselben Benchmark durchgeführt. Die Transfervariante trennt beides: Training und Modellauswahl erfolgen ausschließlich auf ASAP-SAS, getestet wird ohne weiteres Training auf sämtlichen Testsplits von Beetle und SciEntsBank. Architektur, Fusion (CONDIFF), Maske (kausal) und sämtliche Hyperparameter entsprechen den Hauptläufen. Zur Testzeit enthält jede Instanz die Rubriktexte des Zielbenchmarks; dank der variablen Kandidatenmenge (Abschnitt 4.1.2) bewertet das Modell sie ohne Anpassung des Scoring-Kopfs gegen deren Stufen. Mit dem festen Klassifikationskopf aus Abschnitt 4.5.1 ist diese Variante nicht durchführbar, da bereits das Training auf ASAP-SAS eine konstante Stufenzahl ausschließt; die Implementierung lehnt die Kombination ab. Die Auswertung erfolgt in Abschnitt 5.3.4.

4.6 Trainingskonfiguration

Parameter-effizientes Finetuning

Die Backbones werden nicht vollständig, sondern mittels LoRA [27] adaptiert (vgl. Abschnitt 2.7). Die Konfiguration verwendet Rang $r = 64$ und Skalierungsfaktor $\alpha = 64$, woraus nach (2.29) ein effektiver Skalierungsfaktor $\alpha/r = 1$ folgt. Die LoRA-Dropout-Rate beträgt $0{,}1$; Bias-Terme werden nicht adaptiert. Adapter werden auf *sämtliche* linearen Module der Transformer-Blöcke angewandt, das heißt bei den Llama- und Mistral-Backbones auf die vier Attention-Projektionen W_Q, W_K, W_V, W_O sowie auf die drei Projektionen der SwiGLU-Feed-Forward-Schicht.

Von der LoRA-Adaption ausgenommen sind die architektureigenen Komponenten – die Gate-Projektion und Layer-Normalisierung der GATE-Variante sowie der Scoring-Kopf (4.5). Diese sind nicht Teil des vortrainierten Backbones, werden zufällig initialisiert und vollständig trainiert.

Optimierung

Tabelle 4.3 fasst die Trainingskonfiguration zusammen. Optimiert wird mit AdamW; bei den Decoder-Backbones kommt eine speichereffiziente, seitenweise ausgelagerte Variante in 32-

Bit-Genauigkeit zum Einsatz, bei den Encoder-Baselines die Standardimplementierung. Die Lernrate folgt einem Kosinus-Zeitplan mit kurzer Aufwärmphase. Die Decoder-Backbones rechnen in Training und Inferenz in `bfloat16` und verwenden zusätzlich Gradient Checkpointing, um den Speicherbedarf der Aktivierungen zu senken; die Encoder-Baselines rechnen in 32-Bit-Gleitkommagenauigkeit.

Tabelle 4.3: Trainingskonfiguration der Decoder-Backbones. Die Werte entsprechen der in den ausgewerteten Decoder-Läufen verwendeten Konfiguration; die Abweichungen der Encoder-Baselines beschreibt der folgende Unterabschnitt.

Parameter	**Wert**
LoRA-Rang r / Skalierung α	64 / 64
LoRA-Dropout	$0{,}1$
LoRA-Zielmodule	alle linearen Module
Batchgröße (pro Gerät)	4
Gradientenakkumulation	4
Effektive Batchgröße	16
Maximale Epochenzahl	5
Lernrate	$5 \cdot 10^{-5}$
Lernraten-Zeitplan	Kosinus
Aufwärmanteil	$0{,}01$
Gewichtsverfall	$0{,}01$
Adam-ε	10^{-8}
Gradienten-Clipping (Norm)	$1{,}0$
Dropout (Fusion / Scoring-Kopf)	$0{,}1$
Numerisches Format	`bfloat16`
Maximale Sequenzlänge	2048 Token
Aufgabenkontext (Frage, Musterlösung)	nicht enthalten
Abschließende Instruktion	nicht enthalten
Zufallssaaten	$114\,514$ (Referenz), 1, 2

Abweichende Konfiguration der Encoder-Baselines

Die Encoder-Backbones werden nicht in derselben Konfiguration trainiert wie die Decoder-Modelle. Da BERT und RoBERTa eine maximale Kontextlänge von 512 Token besitzen, ist die für die Decoder verwendete Grenze von $2\,048$ Token dort nicht anwendbar; entsprechend wird auf 512 Token gekürzt. Ferner werden die Encoder über zehn statt fünf Epochen trainiert und ohne LoRA einem vollständigen Finetuning unterzogen, da die Zahl ihrer Parameter dies ohne weiteres zulässt. Sie rechnen in 32-Bit-Gleitkommagenauigkeit, mit einer Batchgröße von 16 und ohne Gradientenakkumulation.

Für die Encoder-Hauptläufe ist diese Konfiguration allerdings nicht durch Dateien belegt: Sie stammen aus einer frühen Trainingswelle, von der ausschließlich die Vorhersagen erhalten sind; insbesondere ihre Lernrate lässt sich nicht nachweisen. Da BERT auf SciEntsBank auf

allen drei Splits nur Werte auf Zufallsniveau erreicht (Tabelle 5.9), wurde für beide Encoder ergänzend eine Lernratenvariation trainiert, deren Konfiguration vollständig dokumentiert ist. Ihre Konfigurationsdateien weisen zehn Epochen, vollständiges Finetuning ohne LoRA, 32-Bit-Gleitkommagenauigkeit und eine Batchgröße von 16 ohne Gradientenakkumulation aus, bei einem BERT-Lauf eine Batchgröße von 32. Dass die Hauptläufe ebenso konfiguriert waren, ist plausibel, aber nicht belegt. Tabelle 4.4 gibt die Ergebnisse wieder.

Tabelle 4.4: Lernratenvariation der Encoder-Baselines mit CONDIFF-Fusion, QWK. Einzelläufe, Zufallssaat $114\,514$. Die BERT-Läufe verwenden Batchgröße 16 bei $1 \cdot 10^{-5}$ und $2 \cdot 10^{-5}$ sowie 32 bei $3 \cdot 10^{-5}$, die RoBERTa-Läufe durchgängig 16. Die letzte Spalte gibt den Hauptlauf aus Tabelle 5.9 wieder, dessen Lernrate nicht dokumentiert ist.

Modell	Benchmark	Split	$1 \cdot 10^{-5}$	$2 \cdot 10^{-5}$	$3 \cdot 10^{-5}$	$5 \cdot 10^{-5}$	Hauptlauf
RoBERTa-base	Beetle	UA	0,665	**0,768**	—	0,688	0,694
		UQ	**0,362**	0,337	—	0,288	0,289
	SciEntsBank	UA	**0,634**	$-0{,}054$	—	0,049	0,633
BERT-base	SciEntsBank	UA	0,006	0,009	$-0{,}026$	—	0,052

Die Variation dient allein der Absicherung der Encoder-Baselines und bildet keine eigene Untersuchungsachse. Für die Auswertung sind zwei Ergebnisse maßgeblich. Erstens bleibt BERT auf SciEntsBank bei jeder geprüften Lernrate auf Zufallsniveau ($-0{,}026$ bis $0{,}009$ QWK). Der Ausfall ist damit kein bloßes Lernratenproblem; seine Ursache lässt sich mit den vorliegenden Daten nicht bestimmen, und die BERT-Zeile für SciEntsBank in Tabelle 5.9 wird von jeder inhaltlichen Deutung ausgenommen. Zweitens ist die RoBERTa-Leistung der Hauptläufe nicht wesentlich unterschätzt: Auf SciEntsBank-UA erreicht die beste Rate mit $0{,}634$ praktisch den Wert des Hauptlaufs ($0{,}633$), und auf Beetle-UQ bleibt RoBERTa bei allen drei Raten zwischen $0{,}288$ und $0{,}362$ QWK. Der in Abschnitt 5.3.3 berichtete Einbruch auf dem Transfersplit ist folglich nicht an eine bestimmte Lernrate gebunden.

Zugleich zeigt die Variation, dass die Encoder empfindlich auf die Lernrate reagieren. RoBERTa scheitert auf SciEntsBank bei $2 \cdot 10^{-5}$ und $5 \cdot 10^{-5}$ ($-0{,}054$ und $0{,}049$ QWK), und auf Beetle-UA streuen die Werte zwischen $0{,}665$ und $0{,}768$. Da jede Zelle auf einem einzelnen Lauf beruht und diese Spannweite unter der größten in Abschnitt 5.2 beobachteten Saat-Spannweite liegt, lassen sich Lernrateneinfluss und Saatrauschen dort nicht trennen. Für die Decoder-Backbones wird die Lernrate in Abschnitt 5.4.4 behandelt, wo sie den Vergleich der Modellgrößen konfundiert.

Diese Unterschiede sind bei der Interpretation des Encoder-Decoder-Vergleichs zu berücksichtigen: Der Vergleich hält die *Architektur* konstant – Serialisierung, Span-Pooling, Fusionsmechanismus, Scoring-Kopf und Verlustfunktion sind identisch –, nicht jedoch sämtliche Optimierungsbedingungen.

Modellauswahl und Validierung

Da die drei verwendeten Benchmarks keinen offiziellen Entwicklungssplit bereitstellen, werden $10\,\%$ des Trainingssplits zufällig als Validierungsmenge abgetrennt; die Aufteilung erfolgt mit

fester Zufallssaat und ist damit über alle Läufe hinweg identisch. Nach jeder Epoche wird auf dieser Menge evaluiert. Als Auswahlkriterium dient die Accuracy; der Prüfpunkt mit dem höchsten Wert wird am Ende des Trainings geladen und für die Testevaluation verwendet. Ergänzend beendet ein Early-Stopping-Kriterium das Training, wenn sich die Validierungsleistung über drei aufeinanderfolgende Epochen nicht verbessert.

Dass die Modellauswahl über Accuracy und nicht über die primär berichteten Metriken QWK oder Macro-F_1 erfolgt, ist eine Eigenschaft der verwendeten Konfiguration. Sie ist bei der Interpretation der Ergebnisse zu berücksichtigen, denn unter unbalancierten Labelverteilungen (vgl. Kapitel 3) kann die Accuracy Prüfpunkte bevorzugen, die auf häufigen Stufen stark und auf seltenen Stufen schwach abschneiden.

Evaluationsprotokoll

Die Testevaluation erfolgt auf den in Kapitel 3 beschriebenen Splits. Berichtet werden die in Abschnitt 2.2 definierten Metriken: Quadratic Weighted Kappa mit quadratischer Gewichtungsmatrix (2.12), Macro-F_1 (2.9) und Accuracy (2.7). Die Berechnung erfolgt über alle Testinstanzen eines Splits gemeinsam. Zusätzlich werden die Metriken je Aufgabe getrennt berechnet und protokolliert, was insbesondere für ASAP-SAS mit seinen zehn heterogenen Aufgaben eine differenzierte Auswertung erlaubt (vgl. Kapitel 5).

Die Erhebung erfolgt in zwei Stufen. In der ersten Stufe wurde jede Konfiguration einmal mit der Referenzsaat $114\,514$ trainiert; diese Läufe decken den gesamten Untersuchungsraum ab und dienen der Übersicht. In der zweiten Stufe wurden diejenigen Konfigurationen, auf denen die inhaltlichen Aussagen dieser Arbeit beruhen, zusätzlich mit den Saaten 1 und 2 wiederholt. Über sämtliche Benchmarks, Backbones, Varianten und Splits hinweg liegen dadurch 93 Zellen mit je drei Läufen vor, ohne die Transferläufe. Eine Gruppe wurde zur Prüfung der Rauschgrenze auf acht Saaten erweitert (Abschnitt 5.2).

Diese Zweiteilung schlägt auf die Auswertung durch: Einzelläufe werden in Kapitel 5 ausschließlich dokumentarisch berichtet, während jede inhaltliche Aussage auf Mittelwerten über drei Saaten beruht und gegen die in Abschnitt 5.2 bestimmte Rauschgrenze geprüft wird. Wo möglich stammen die drei Läufe einer Gruppe aus derselben Softwareumgebung, da ein Umgebungswechsel eine eigene, von der Zufallssaat unabhängige Störgröße darstellt (Abschnitt 5.2).

5 Experimente und Ergebnisse

Dieses Kapitel berichtet die empirischen Ergebnisse entlang der beiden Forschungsfragen. Abschnitt 5.1 beschreibt das experimentelle Design, Abschnitt 5.2 bestimmt die Rauschgrenze, an der anschließend jeder berichtete Unterschied gemessen wird. Abschnitt 5.3 beantwortet RQ1 und vergleicht das Span-Alignment mit einem festen Klassifikationskopf, mit Bedingungen ohne Rubriktext oder Aufgabeninformation und mit Encoder-Modellen und prüft die Übertragung eines trainierten Modells auf andere Benchmarks. Abschnitt 5.4 beantwortet RQ2 und untersucht die Ausgestaltung des Alignments, die Attention-Maske und die Backbone-Größe. Abschnitt 5.5 sichert die Befunde durch eine aufgabenweise Auswertung, die Diagnose instabiler Läufe und eine Prüfung unter Macro-F_1 ab, Abschnitt 5.6 fasst sie zusammen.

Sofern nicht anders angegeben, sind sämtliche Zahlen kaufmännisch auf drei Nachkommastellen gerundet; Differenzen werden aus den ungerundeten Werten gebildet. Die Rohwerte liegen den Auswertungsdateien der jeweiligen Läufe bei.

5.1 Experimentelles Design

Untersuchte Bedingungen

Untersucht werden fünf Variationsachsen. Die ersten vier betreffen die Architektur, die fünfte das Backbone:

1. **Verfügbarkeit des Rubriktexts.** Der Kontrast zwischen einem Modell, dem die Rubriktexte als Eingabe zur Verfügung stehen, und einem sonst identischen Modell, dem sie entzogen werden (Abschnitt 5.3.2).
2. **Fusionsmechanismus** bei unveränderter kausaler Attention: CONDIFF, CONCAT, DIFF und GATE (Abschnitt 4.2); DIFF wurde ausschließlich auf Llama-3.2-3B untersucht.
3. **Bezugsgröße der Fusion**: die Sequenzrepräsentation z gegenüber der Repräsentation des Antwort-Spans (Abschnitt 5.4.2).
4. **Attention-Maske** bei fest auf CONDIFF gesetztem Fusionsmechanismus: die Anteile $\rho \in \{0{,}2;\ 0{,}4;\ 0{,}6;\ 0{,}8;\ 1{,}0\}$ sowie die vollständig bidirektionale Bedingung $n_{\text{bidir}} = L$ (Abschnitt 4.3.2).
5. **Backbone**: Llama-3.2-1B, Llama-3.2-3B und Mistral-7B als Decoder-Modelle sowie BERT-base-uncased und RoBERTa-base als Encoder-Vergleichsbasis (Abschnitt 4.4).

Die erste Achse dient gemeinsam mit dem Vergleich gegenüber dem festen Klassifikationskopf (Abschnitt 4.5.1), den Encoder-Modellen und einem Transferexperiment, in dem ausschließlich auf ASAP-SAS trainiert und auf Beetle und SciEntsBank getestet wird (Abschnitt 4.5.5), der Beantwortung von RQ1, die Achsen zwei bis vier sowie der Vergleich der Decoder-Backbones der Beantwortung von RQ2.

Da die Läufe mit variierter Maske durchgängig CONDIFF verwenden, ist der Lauf mit CONDIFF und unveränderter kausaler Maske zugleich die Referenzbedingung $\rho = 0$ für die vierte Achse. Fusions- und Maskeneffekte sind damit gegeneinander abgrenzbar.

Nicht als eigene Bedingungen trainiert wurden paarweise Verfahren im Sinne des Rubric Retrieval (Abschnitt 2.5) und die generative Bewertung durch Prompting (Abschnitt 2.4). Die Fragestellung betrifft Varianten innerhalb der Span-Alignment-Architektur; als Vergleichsbasis außerhalb dieser Architektur dienen der feste Klassifikationskopf (Abschnitt 4.5.1) und die Encoder-Modelle.

Interpretation des Anteilsparameters

Für die vierte Achse ist die in Abschnitt 4.3.2 beschriebene Umrechnungsvorschrift (4.15) von zentraler Bedeutung. Da Werte ab 1 als absolute Schichtzahl gelesen werden, entspricht die Bedingung $\rho = 1{,}0$ *einer einzigen* bidirektionalen Schicht und nicht dem vollständig bidirektionalen Modell; Letzteres erfordert die Angabe $\rho = L$. Abbildung 2.8 und Tabelle 4.2 in Kapitel 4 geben die resultierenden Schichtzahlen an.

Die Bedingungen bilden daher *keine* monoton ansteigende Reihe in ihrer nominellen Bezeichnung. Geordnet nach dem tatsächlichen Grad der Bidirektionalität ergibt sich

$$\rho = 0 \;\prec\; \rho = 1{,}0 \;\prec\; \rho = 0{,}2 \;\prec\; \rho = 0{,}4 \;\prec\; \rho = 0{,}6 \;\prec\; \rho = 0{,}8 \;\prec\; \rho = L, \tag{5.1}$$

das heißt die nominell als „vollständig“ erscheinende Bedingung $\rho = 1{,}0$ liegt dem kausalen Ausgangsmodell am nächsten. Sämtliche Ergebnistabellen dieses Kapitels sind daher nach der tatsächlichen Schichtzahl n_{bidir} sortiert und geben diese explizit an.

Vollständigkeit der Auswertung

Die Auswertung ist nicht in allen Zellen vollständig. Für Mistral-7B liegen auf Beetle und SciEntsBank die Fusionsvarianten CONDIFF, CONCAT und GATE unter drei Zufallssaaten vor, die Variation der Attention-Maske dagegen nur mit den Anteilen $\rho = 0{,}2$, $\rho = 0{,}6$ und $\rho = 1{,}0$ als Einzelläufe; die Anteile $\rho = 0{,}4$ und $\rho = 0{,}8$ sowie die vollständig bidirektionale Bedingung wurden für dieses Backbone auf diesen beiden Benchmarks nicht ausgeführt. Auf ASAP-SAS liegen für Mistral-7B sämtliche Maskenbedingungen einschließlich der vollständig bidirektionalen als Einzelläufe vor, ebenso ein Transferlauf (Abschnitt 5.3.4). Für BERT liegt auf Beetle nur der UA-Split vor. Die vollständig bidirektionale Bedingung und ihre kausale CONDIFF-Referenz liegen für beide Llama-Größen auf allen drei Benchmarks unter drei Zufallssaaten vor. CONDIFF mit Llama-3.2-1B auf Beetle wurde zusätzlich unter fünf weiteren Saaten wiederholt, um die Verlässlichkeit der Rauschgrenze zu prüfen (Abschnitt 5.2). Die Variation der

Bezugsgröße und die Fusionsvariante DIFF wurden unter drei Saaten nur auf Llama-3.2-3B untersucht, jeweils auf Beetle und SciEntsBank; die Ablation des Rubriktexts wurde auf beiden Llama-Größen wiederholt. Die Lernratenvariation der Encoder umfasst RoBERTa auf Beetle und SciEntsBank sowie BERT auf SciEntsBank. Fehlende Zellen sind in den Tabellen mit „—“ gekennzeichnet.

Die Einzelläufe der Bezugsgrößen-Variante auf Llama-3.2-1B werden nicht in eigenen Tabellen geführt, da sie mit einer Zufallssaat keine Interpretation tragen. Dasselbe gilt für t-concat auf ASAP-SAS ($0{,}814$ und $0{,}837$ QWK für Llama-3.2-1B und -3B gegenüber $0{,}828$ und $0{,}842$ für CONCAT).

Wo mehrere Zufallssaaten vorliegen, wird der Mittelwert über die Saaten berichtet und die Spannweite mitgeführt. Wo nur ein Lauf vorliegt, ist dies im Tabellenkopf vermerkt; solche Werte dienen der Dokumentation, nicht der Interpretation.

5.2 Rauschgrenze: Streuung zwischen Läufen

Bevor einzelne Konfigurationen verglichen werden, ist die in Abschnitt 2.2 eingeführte Rauschgrenze empirisch zu bestimmen. Andernfalls ließe sich nicht entscheiden, ob ein beobachteter Unterschied auf die untersuchte Variation oder auf die stochastischen Anteile des Trainings zurückgeht.

Reproduzierbarkeit bei identischer Zufallssaat

Ein erster Befund betrifft die Wiederholbarkeit selbst, und er fällt eindeutiger aus als erwartet. Zwei Konfigurationen wurden unter identischer Zufallssaat, identischen Hyperparametern und identischer Softwareumgebung ein zweites Mal ausgeführt. Die resultierenden Vorhersagedateien sind *byteweise identisch* mit denen der ersten Ausführung; sämtliche vier Messwerte (zwei Konfigurationen $\times$ zwei Splits) stimmen exakt überein. Innerhalb einer festen Umgebung ist das Training in diesem Aufbau also vollständig deterministisch: Die in Abschnitt 2.2 als mögliche Störquelle genannte nicht-assoziative Gleitkommaaddition auf dem Grafikprozessor schlägt hier nicht durch.

Dieser Befund korrigiert eine naheliegende Fehldeutung. In den Daten existiert ein weiteres Paar von Läufen mit derselben Zufallssaat, das *nicht* übereinstimmt: Für CONDIFF mit Llama-3.2-1B auf Beetle ergab die Wiederholung $0{,}718$ statt $0{,}696$ QWK auf UA und $0{,}472$ statt $0{,}532$ auf UQ. Dieses Paar stammt jedoch aus zwei verschiedenen Softwareumgebungen und misst damit nicht die Wiederholbarkeit, sondern den im folgenden Unterabschnitt behandelten Umgebungseinfluss.

Die praktische Konsequenz ist günstig: Die weiter unten bestimmte Spannweite über mehrere Zufallssaaten ist ein reiner Saat-Effekt und nicht zusätzlich mit Wiederholungsrauschen überlagert.

Höhe der Rauschgrenze

Zur Bestimmung der Streuung wurden Konfigurationen unter je drei Zufallssaaten wiederholt. Über sämtliche Benchmarks, Backbones, Varianten und Splits hinweg liegen dadurch 93 Zellen aus 39 Gruppen mit drei Läufen vor. Nicht einbezogen sind die Transferläufe (Abschnitt 5.3.4), deren Vorhersagen nahezu konstant sind und deren Spannweite daher nichts über die Streuung eines funktionierenden Trainings aussagt. Tabelle 5.1 fasst die Verteilung der Spannweiten (2.14) zusammen.

Tabelle 5.1: Spannweite Δ des QWK über drei Zufallssaaten, aggregiert über 93 Zellen.

Kennwert	**Spannweite Δ (QWK)**
Median	0,036
Mittelwert	0,037
1. Quartil	0,020
3. Quartil	0,049
Minimum	0,004
Maximum	0,118
Anteil der Zellen mit $\Delta \leq 0{,}05$	$76\,\%$

Die typische Spannweite beträgt rund $0{,}036$ QWK, gut drei Viertel aller Zellen liegen bei höchstens $0{,}05$. Der Maximalwert von $0{,}118$ entfällt auf GATE mit Llama-3.2-1B auf dem Beetle-UQ-Split. Bemerkenswert ist die Breite der Verteilung selbst: Sie reicht von $0{,}004$ bis $0{,}118$, sodass eine pauschale Schwelle nicht ausreicht. Im Folgenden wird daher zweistufig geprüft – gegen den Median $0{,}036$ als Orientierung und, wo drei Saaten vorliegen, gegen die tatsächliche Spannweite der betroffenen Zellen.

Einfluss der Softwareumgebung

Läufe aus unterschiedlichen Softwareumgebungen sind dagegen nicht ohne Weiteres vergleichbar; das im vorigen Unterabschnitt genannte CONDIFF-Paar weicht bei identischer Saat um bis zu $0{,}060$ QWK ab. Nicht alle Gruppen mit drei Zufallssaaten konnten innerhalb einer einzigen Umgebung gebildet werden: In 21 der 39 Gruppen stammt der Lauf mit der Saat $114\,514$ aus einer anderen Umgebung als die beiden weiteren Läufe. In diesen Gruppen ist der Umgebungsbeitrag in der ausgewiesenen Spannweite enthalten. Für Vergleiche ohne nachweisbaren Unterschied wirkt das konservativ, da eine vergrößerte Spannweite die Auswertungsregel strenger macht. Für die Vergleiche mit Befund wurde zusätzlich geprüft, ob die Richtung auch innerhalb einer einzigen Umgebung besteht; das ist durchgängig der Fall. Da dabei jeweils nur ein Lauf einer Bedingung eingeht, bestätigt diese Prüfung die Richtung, nicht die Höhe der Effekte.

Auswertungsregel

Aus den vorstehenden Befunden folgt die Regel, nach der dieses Kapitel durchgängig verfährt. Ein Unterschied zwischen zwei Konfigurationen wird nur dann als Effekt bezeichnet, wenn die Differenz der Mittelwerte die größere der beiden Spannweiten übersteigt. Liegt sie darunter, überlappen die Spannweiten aber nicht, wird dies als schwacher Hinweis vermerkt und nicht als Ergebnis behauptet. Überlappen die Spannweiten, gilt der Unterschied als nicht nachweisbar. Abbildung 2.4 stellt diese Regel schematisch dar.

Verlässlichkeit von drei Saaten

Drei Läufe erlauben nur eine grobe Schätzung der Streuung, und die Spannweite einer kleinen Stichprobe unterschätzt die Streuung der zugrunde liegenden Verteilung systematisch. Um abzuschätzen, wie stark, wurde eine Gruppe – CONDIFF mit Llama-3.2-1B auf Beetle – um fünf weitere Saaten (3 bis 7) auf insgesamt acht Läufe erweitert. Die zusätzlichen Läufe stammen aus derselben Umgebung wie die Läufe mit den Saaten 1 und 2. Tabelle 5.2 stellt die Streuung über alle acht Läufe der Streuung gegenüber, die sich für die 56 möglichen Dreiergruppen aus diesen acht Läufen ergibt.

Tabelle 5.2: Beetle, Llama-3.2-1B, CONDIFF: Streuung des QWK über acht Zufallssaaten und über die 56 daraus bildbaren Dreiergruppen. *Ursprünglich* bezeichnet die Gruppe aus den Saaten $114\,514$, 1 und 2, die den übrigen Tabellen dieses Kapitels zugrunde liegt.

	acht Läufe			**Spannweite über drei Läufe**			
Split	Mittel	Spannw.	Std.-abw.	ursprünglich	Median	Min.	Max.
UA	0,732	0,079	0,025	0,023	0,039	0,013	0,079
UQ	0,525	0,073	0,024	0,073	0,034	0,003	0,073

Die Erweiterung führt zu zwei Befunden. Erstens bestätigt sie die Höhe der Rauschgrenze als typischen Wert: Die Spannweite der Dreiergruppen beträgt im Median $0{,}039$ (UA) und $0{,}034$ QWK (UQ) und liegt damit nahe am globalen Median von $0{,}036$. Zweitens zeigt sie, wie weit eine einzelne Dreiergruppe davon abweichen kann. Auf UA reicht die Spannweite der Dreiergruppen von $0{,}013$ bis $0{,}079$. Die ursprüngliche Gruppe lag mit $0{,}023$ im unteren Bereich, über alle acht Läufe beträgt die Spannweite mehr als das Dreifache. Allein der Lauf mit der Saat 6 erreicht $0{,}781$ QWK und liegt damit $0{,}040$ über dem besten der drei ursprünglichen Läufe. Auf UQ war die ursprüngliche Gruppe dagegen bereits die breiteste mögliche.

Eine enge Spannweite über drei Saaten ist demnach kein verlässlicher Beleg für eine enge Streuung. Befunde, die die Auswertungsregel nur bestehen, weil die betroffenen Zellen ungewöhnlich eng streuen, sind entsprechend vorsichtig zu lesen. Für die Paarvergleiche, an denen diese Gruppe beteiligt ist, wurde die Auswertungsregel daher mit allen acht Läufen wiederholt (Tabelle 5.3).

Unter QWK ändert sich ein Urteil: Der Gewinn des kleineren Backbones durch vollständig bidirektionale Attention auf Beetle-UA, der die Regel mit drei Saaten knapp bestand, ist mit acht Saaten nicht mehr nachweisbar (Abschnitt 5.4.3). Der Vorsprung des Span-Alignments vor dem

Tabelle 5.3: Paarvergleiche mit CONDIFF, Llama-3.2-1B, Beetle: Urteil mit den drei ursprünglichen und mit allen acht Saaten der CONDIFF-Bedingung, QWK. Die jeweils andere Bedingung beruht auf drei Saaten. Δ wie in den Ergebnistabellen der jeweiligen Abschnitte; „—“ bedeutet nicht nachweisbar.

		drei Saaten		acht Saaten	
Vergleich	**Split**	Δ	Urteil	Δ	Urteil
Span-Alignment gegen festen Kopf	UA	$+0{,}088$	Effekt	$+0{,}092$	Effekt
	UQ	$+0{,}054$	—	$+0{,}069$	—
bidirektional gegen kausal	UA	$+0{,}036$	Effekt	$+0{,}033$	—
	UQ	$-0{,}016$	—	$-0{,}032$	—
CONDIFF gegen CONCAT	UA	$+0{,}005$	—	$+0{,}008$	—
	UQ	$+0{,}006$	—	$+0{,}022$	—
CONDIFF gegen GATE	UA	$+0{,}033$	—	$+0{,}036$	—
	UQ	$+0{,}038$	—	$+0{,}054$	—

festen Kopf auf Beetle-UA bleibt dagegen bestehen und übersteigt auch die Spannweite über acht Läufe (Abschnitt 5.3.1). Unter Macro-F_1 entfallen mit acht Saaten zwei weitere Urteile, der Gewinn durch bidirektionale Attention auf UA und ein schwacher Hinweis zugunsten von CONDIFF gegenüber CONCAT auf UA; die übrigen Macro-F_1-Urteile dieser Vergleiche bleiben unverändert. Die Ergebnistabellen berichten für diese Gruppe weiterhin die drei ursprünglichen Saaten, damit alle Gruppen auf derselben Zahl von Läufen beruhen; wo das Urteil mit acht Saaten abweicht, ist dies an der jeweiligen Stelle vermerkt.

5.3 RQ1: Span-Alignment gegenüber den Vergleichsbedingungen

Die erste Forschungsfrage lautet, ob das Span-Alignment die Vergleichsbedingungen übertrifft. Geprüft wird dies gegenüber drei Vergleichsbasen: einem Klassifikator mit festem Ausgabekopf, der dieselbe Eingabe erhält (Abschnitt 5.3.1), Modellen, denen die Rubriktexte oder jede aufgabenbezogene Information entzogen ist (Abschnitt 5.3.2), sowie den Encoder-Modellen BERT und RoBERTa (Abschnitt 5.3.3). Abschnitt 5.3.4 prüft abschließend eine Eigenschaft, die allein dem Span-Alignment zukommt: die Anwendung eines trainierten Modells auf einen anderen Benchmark mit anderen Rubriken.

5.3.1 Span-Alignment gegenüber einem festen Klassifikationskopf

Die naheliegendste Vergleichsbasis ist ein Modell, das die Rubriktexte zwar in der Eingabe sieht, sie aber nicht als Spans extrahiert, sondern die Bewertung über einen festen Kopf mit C Ausgaben aus der Sequenzrepräsentation ableitet (Abschnitt 4.5.1). Der Unterschied zum Span-Alignment liegt damit ausschließlich im Scoring-Mechanismus. Beide Bedingungen enthalten wie alle Hauptläufe keinen Aufgabenkontext; der feste Kopf entspricht der Bedingung

„ohne Kontext, mit Rubriktext“ aus Abschnitt 5.3.2.

Tabelle 5.4: Span-Alignment (CONDIFF) gegenüber festem Klassifikationskopf, beide mit Rubriktexten und ohne Aufgabenkontext. Mittelwerte über drei Zufallssaaten, Spannweiten in Klammern. *Über Spannweite* bedeutet, dass die Differenz die größere der beiden zellspezifischen Spannweiten übersteigt. Fett: höherer Wert je Zeile.

Benchmark	Backbone	Split	Span	fester Kopf	Δ	Urteil
Beetle	Llama-3.2-1B	UA	**0,729** (0,023)	0,641 (0,055)	$+0{,}088$	über Spannweite
		UQ	**0,509** (0,073)	0,456 (0,068)	$+0{,}054$	im Rauschen
	Llama-3.2-3B	UA	**0,730** (0,041)	0,722 (0,081)	$+0{,}008$	im Rauschen
		UQ	**0,544** (0,044)	0,517 (0,089)	$+0{,}027$	im Rauschen
SciEntsBank	Llama-3.2-1B	UA	**0,702** (0,007)	0,682 (0,007)	$+0{,}021$	über Spannweite
		UQ	0,544 (0,058)	**0,555** (0,051)	$-0{,}011$	im Rauschen
		UD	**0,560** (0,026)	0,534 (0,016)	$+0{,}026$	über Spannweite (knapp)
	Llama-3.2-3B	UA	0,734 (0,047)	**0,746** (0,028)	$-0{,}011$	im Rauschen
		UQ	0,576 (0,009)	**0,580** (0,076)	$-0{,}004$	im Rauschen
		UD	0,617 (0,028)	**0,641** (0,026)	$-0{,}024$	im Rauschen

Tabelle 5.4 zeigt ein nach Benchmark und Backbone unterschiedliches Bild. Der deutlichste Befund betrifft Beetle: Mit Llama-3.2-1B liegt das Span-Alignment auf UA um $0{,}088$ QWK vor dem festen Kopf. Die Spannweiten der beiden Bedingungen sind disjunkt, und die Differenz übersteigt nicht nur beide Spannweiten, sondern auch den globalen Median von $0{,}036$ QWK deutlich. Beide Gruppen stammen zudem aus derselben Softwareumgebung (Abschnitt 5.2). Der Befund besteht auch, wenn die Span-Bedingung auf acht Saaten erweitert wird: Die Differenz beträgt dann $+0{,}092$ und übersteigt auch die Spannweite über alle acht Läufe ($0{,}079$). Auf Beetle-UQ liegt das Span-Alignment nominell um $0{,}054$ QWK vorn; da die Spannweiten überlappen, ist der Unterschied unter QWK nicht nachweisbar. Unter Macro-F_1 bestehen dagegen beide Beetle-Vorteile als Effekt (Abschnitt 5.5.3).

Auf SciEntsBank fallen die Unterschiede kleiner aus. Beim kleineren Backbone liegt das Span-Alignment auf UA und UD vorn; die Vorteile betragen $0{,}021$ und $0{,}026$ QWK. Beide liegen *unterhalb* des globalen Medians der Saat-Spannweite und sind allein deshalb nachweisbar, weil die betroffenen Zellen ungewöhnlich eng streuen ($0{,}007$ auf UA). Auf UD ist die Entscheidung zudem denkbar knapp: Die Differenz übersteigt die maßgebliche Spannweite nur um $0{,}0003$ QWK. Beim größeren Backbone liegen alle drei Differenzen im Rauschen, und alle drei sind nominell negativ.

Beim größeren Backbone verschwindet der Vorteil auch auf Beetle. Das Span-Alignment liegt dort nominell um $0{,}008$ (UA) und $0{,}027$ QWK (UQ) vorn; beide Differenzen liegen im Rauschen. Auffällig ist die hohe Streuung des festen Kopfs mit Spannweiten von $0{,}081$ und $0{,}089$, mehr als das Doppelte des globalen Medians. Ein Unterschied in der Größenordnung des Befunds beim kleineren Backbone wäre damit gleichwohl nachweisbar gewesen. Unter Macro-F_1 fällt das Urteil gleich aus.

Der Kontrast zwischen beiden Modellgrößen ist mit Vorsicht zu lesen. Beide Llama-Varianten wurden bei $5 \cdot 10^{-5}$ statt bei der für sie vorgesehenen Rate $2 \cdot 10^{-4}$ trainiert (Abschnitt 5.4.4); ob sie dadurch in gleichem Maß beeinträchtigt sind, lässt sich mit je einem Lauf bei der Re-

ferenzrate nicht klären. Der Vergleich *innerhalb* jeder Modellgröße bleibt davon unberührt, die Aussage über das Verhältnis beider Größen zueinander nicht.

Bei der Deutung ist entscheidend, dass beide Bedingungen die Rubriktexte in der Eingabe enthalten. Der Vergleich misst also nicht den Wert der Rubrikinformation – dieser ist Gegenstand von Abschnitt 5.3.2 und beträgt ein Vielfaches –, sondern lediglich den Wert ihrer expliziten Extraktion als Span. Dieser Zusatznutzen ist beim kleineren Backbone auf Beetle deutlich, auf SciEntsBank klein und beim größeren Backbone auf keinem der beiden Benchmarks nachweisbar. Letzteres legt die Lesart nahe, ein hinreichend großes Sprachmodell verdichte die relevante Rubrikinformation bereits in der Sequenzrepräsentation, sodass das gezielte Auslesen der einzelnen Stufen keinen weiteren Beitrag liefere. Dass der Vorteil auf beiden Benchmarks zugleich entfällt, stützt diese Lesart; mit zwei Modellgrößen und der oben genannten Einschränkung zur Lernrate ist sie gleichwohl nicht zu sichern.

Der Wert der Span-Architektur liegt damit zum einen in ihrer strukturellen Eigenschaft, mit einer zur Laufzeit variablen Stufenzahl umgehen zu können (Abschnitt 4.1) – eine Eigenschaft, die dem festen Kopf grundsätzlich fehlt und die auf Benchmarks wie ASAP-SAS mit wechselnder Skalenlänge erst die gemeinsame Modellierung aller Aufgaben ermöglicht. Ob diese Eigenschaft auch eine Übertragung zwischen Benchmarks ermöglicht, prüft Abschnitt 5.3.4. Zum anderen zeigt sich unter bestimmten Bedingungen, auf Beetle mit dem kleineren Backbone, auch ein deutlicher Genauigkeitsvorteil; ein über Benchmarks und Backbones hinweg verlässlicher Vorteil ist dagegen nicht belegt.

5.3.2 Der Beitrag aufgabenbezogener Information

Die zweite Vergleichsbasis betrifft nicht die Architektur, sondern die Eingabe: Welchen Beitrag leisten die Rubriktexte, und was geschieht, wenn dem Modell jede aufgabenbezogene Information fehlt? Zur Beantwortung wird eine Ablation im Sinne von Abschnitt 2.2 durchgeführt: Aus einer funktionierenden Konfiguration wird gezielt eine Informationsquelle entfernt, während Serialisierung, Backbone, Pooling, Scoring-Kopf, Verlustfunktion und sämtliche Hyperparameter unverändert bleiben.

Die Architektur ist in allen Bedingungen dieses Abschnitts dieselbe, auch in denen ohne Rubriktext: der feste Klassifikationskopf aus Abschnitt 4.5.1. Das Decoder-Backbone (Llama-3.2-1B beziehungsweise -3B mit LoRA) kodiert die serialisierte Eingabe, die Sequenzrepräsentation z wird nach (4.4) als Zustand des letzten gültigen Tokens gebildet, und eine einzelne lineare Abbildung bildet z auf die Logits des festen Labelraums ab. Rubrik-Repräsentationen r_k und Fusionsfunktion werden in keiner Bedingung verwendet. Die Bedingungen unterscheiden sich allein darin, welche Felder vor der Serialisierung in der Eingabe verbleiben (Abschnitte 4.5.2 und 4.5.3); in der Bedingung *mit* Rubriktext sind die Rubriktexte Teil der Eingabe und wirken ausschließlich über z. Der Vergleich ist damit nicht durch die Fusionsarchitektur konfundiert.

Entscheidend für die Anlage des Experiments ist die in Abschnitt 4.1.1 dokumentierte Festlegung, dass die Hauptläufe dieser Arbeit *weder Frage noch Musterlösung* enthalten. Die Rubriktexte sind dort die einzige aufgabenbezogene Information; ihr Entzug lässt allein den Antworttext übrig. Eine Ablation unter dieser Bedingung kann daher nicht zwischen dem spezifischen Beitrag der Kriterienbeschreibung und dem allgemeinen Beitrag *irgendeiner* Aufgabeninforma-

tion unterscheiden. Um beides zu trennen, wird die Ablation hier in einem vollständigen 2×2-Schema durchgeführt, das zusätzlich die Verfügbarkeit von Frage und Musterlösung variiert.

Das vollständige Schema

Tabelle 5.5: SciEntsBank, Llama-3.2-1B, fester Klassifikationskopf: Verfügbarkeit von Aufgabenkontext (Frage und Musterlösung) und Rubriktext im vollständigen 2×2-Schema. Mittelwerte über drei Zufallssaaten, Spannweiten in Klammern.

Kontext	Rubriktext	UA	UQ	UD
ja	ja	0,769 (0,024)	**0,630** (0,026)	**0,617** (0,016)
ja	nein	**0,782** (0,041)	0,615 (0,022)	0,611 (0,038)
nein	ja	0,682 (0,007)	0,555 (0,051)	0,534 (0,016)
nein	nein	0,447 (0,055)	0,035 (0,023)	0,172 (0,038)

Tabelle 5.5 führt zu einem klar strukturierten Befund, der die naheliegende Deutung der einfachen Ablation korrigiert.

Aufgabenbezogene Information ist unverzichtbar. Fehlt sie vollständig, bricht die Leistung zusammen: auf UQ von $0{,}555$ auf $0{,}035$ QWK, auf UD von $0{,}534$ auf $0{,}172$. Der Effekt beträgt $+0{,}235$ / $+0{,}520$ / $+0{,}361$ und übersteigt die Rauschgrenze um das Sechs- bis Vierzehnfache; die Spannweiten der beiden Bedingungen überlappen in keiner der drei Zellen.

Der Rubriktext trägt jedoch nichts bei, sobald Frage und Musterlösung vorliegen. Die Differenz zwischen den beiden oberen Zeilen beträgt $-0{,}012$ / $+0{,}015$ / $+0{,}006$ QWK. Alle drei Werte liegen unterhalb der Rauschgrenze, und in allen drei Fällen überlappen die Spannweiten. Nach der in Abschnitt 5.2 formulierten Regel ist ein Beitrag des Rubriktexts unter dieser Bedingung nicht nachweisbar. Unter Macro-F_1 gilt dies nur eingeschränkt: Dort trägt der Rubriktext bei vorhandenem Kontext auf UD nachweisbar bei (Abschnitt 5.5.3).

Frage und Musterlösung sind dem Rubriktext sogar überlegen. Der Vergleich der zweiten mit der dritten Zeile – Kontext ohne Rubrik gegen Rubrik ohne Kontext – ergibt $+0{,}100$ / $+0{,}060$ / $+0{,}077$ QWK zugunsten des Kontexts. Alle drei Werte übersteigen die Rauschgrenze. Umgekehrt bringt das Hinzufügen des Kontexts zu einer bereits vorhandenen Rubrik $+0{,}088$ / $+0{,}075$ / $+0{,}083$ QWK, ebenfalls durchgängig oberhalb der Rauschgrenze. Auf UA bestehen beide Befunde auch unter Macro-F_1. Auf den Transfersplits beruht der Vorsprung des Kontexts dagegen vor allem darauf, dass grobe Fehlbewertungen seltener werden; unter Macro-F_1 ist er dort nicht oder nur als schwacher Hinweis nachweisbar (Abschnitt 5.5.3).

Bemerkenswert ist schließlich, dass die beste Einzelkonfiguration dieses Schemas – Kontext ohne Rubriktext – auf dem UA-Split mit $0{,}782$ QWK im Mittel und $0{,}799$ im besten Lauf den höchsten SciEntsBank-Wert der gesamten Arbeit erreicht, oberhalb sämtlicher Läufe mit Llama-3.2-3B und Mistral-7B. Ein $1{,}2$-Milliarden-Modell mit Frage, Musterlösung und Antwort liegt damit vor allen größeren Backbones. Diese wurden allerdings nie mit Aufgabenkontext trainiert, sodass der Vergleich keine Aussage über die Modellgröße zulässt.

Konsequenz für die Deutung

Der in der einfachen Ablation gemessene Effekt von bis zu $0{,}52$ QWK ist demnach *nicht* als Beitrag der Kriterienbeschreibung zu lesen, sondern als Beitrag aufgabenbezogener Information überhaupt. Rubriktext einerseits sowie Frage und Musterlösung andererseits erweisen sich als weitgehend austauschbare Träger derselben Information – mit einem Vorteil für Letztere, der sich unter QWK auf allen Splits, unter Macro-F_1 nur auf UA zeigt. Dieser Befund ist konsistent mit der Herkunft der Rubriktexte: Für Beetle und SciEntsBank liegen keine originalen Bewertungsrichtlinien vor, die verwendeten Texte wurden sprachmodellgestützt aus Frage und Musterlösung erzeugt (Kapitel 3) und nehmen deren Inhalt erkennbar mit auf. Für die SciEntsBank-Frage *What is the difference between a rock and a mineral?* etwa hält die Beschreibung der höchsten Stufe fest, korrekte Antworten unterschieden zutreffend zwischen Gestein und Mineral und stellten dar, dass Gestein aus mehreren Mineralen bestehe, ein Mineral dagegen aus einer einzigen Substanz – also genau der Inhalt der zugehörigen Musterlösung.

Damit ist die Prämisse der rubrik-konditionierten Formulierung (2.5) empirisch eingeschränkt. Ihr Nutzen liegt nach diesen Daten nicht darin, dass Kriterienbeschreibungen eine der Aufgabenbeschreibung überlegene Informationsquelle wären. Er liegt in der strukturellen Eigenschaft, mit einer zur Laufzeit variablen Stufenzahl umgehen zu können (Abschnitt 4.1) und auf ungesehene Rubriksätze übertragbar zu sein – Eigenschaften, die ein fester Klassifikationskopf grundsätzlich nicht besitzt und die sich in einem Genauigkeitsvergleich auf festen Labelräumen auch nicht zeigen können.

Zwei Präzisierungen zum Zusammenbruch

Der Zusammenbruch ohne jede Aufgabeninformation ist kein degenerierter Klassifikator. Es wäre denkbar, dass das Modell auf die Vorhersage einer einzigen Stufe zusammenfällt und das niedrige QWK lediglich diesen Kollaps abbildet. Eine Prüfung der Vorhersagedateien widerlegt dies für alle sechs Läufe ohne jede Aufgabeninformation, die drei der untersten Tabellenzeile sowie die drei entsprechenden Läufe mit Llama-3.2-3B (Tabelle 5.6): Jeder von ihnen sagt sämtliche drei Stufen vorher, und der Anteil der häufigsten vorhergesagten Stufe übersteigt in keinem Fall $54\,\%$.

Auf den Transfersplits liegt die Leistung dann auf oder unter dem Zufallsniveau. Ohne jede Aufgabeninformation erreichen die Modelle auf dem UQ-Split eine Accuracy zwischen $0{,}381$ und $0{,}416$ gegenüber einer Mehrheitsschranke von $0{,}411$; in fünf der sechs Läufe liegt sie *unter* dieser Schranke. Auf UD ergibt sich mit $0{,}353$ bis $0{,}440$ gegenüber einer Schranke von $0{,}420$ dasselbe Bild. Auf UA dagegen bleibt die Accuracy mit $0{,}574$ bis $0{,}611$ deutlich über der dortigen Schranke von $0{,}431$. Der Kontrast ist aufschlussreich: Ohne Aufgabeninformation kann das Modell die Bewertungskonvention bekannter Fragen weiterhin teilweise reproduzieren – offenbar über sprachliche Regelmäßigkeiten der Antworten –, während es auf neuen Fragen und Domänen jede Grundlage verliert. Damit ist empirisch belegt, was in Abschnitt 2.1 als methodisches Argument eingeführt wurde: UA und UQ messen verschiedene Fähigkeiten.

Modellgröße und die Ablation

Die einfache Ablation ohne Kontext wurde zusätzlich auf Llama-3.2-3B durchgeführt (Tabelle 5.6). Der Effekt bleibt dort unverändert groß; auf UD fällt er mit $0{,}440$ gegenüber $0{,}361$ QWK nominell größer aus. Ob diese Zunahme mehr ist als Rauschen, lässt sich nicht entscheiden: Beide Modellgrößen wurden bei derselben, für sie nicht vorgesehenen Lernrate trainiert (Abschnitt 5.4.4). Sicher ist allein das Vorzeichen des Vergleichs *innerhalb* jeder Größe: Zusätzliche Modellkapazität kompensiert fehlende Aufgabeninformation nicht; ohne sie liegen beide Modellgrößen gleichermaßen am Boden.

Tabelle 5.6: SciEntsBank: Ablation der Rubriktexte ohne Aufgabenkontext, über zwei Modellgrößen. Mittelwerte über drei Zufallssaaten, Spannweiten in Klammern. *Lücke* bezeichnet den Abstand zwischen dem schlechtesten Lauf mit und dem besten Lauf ohne Rubriktext.

Backbone	Split	mit Rubriktext	ohne	Effekt	Lücke
Llama-3.2-1B	UA	0,682 (0,007)	0,447 (0,055)	$+0{,}235$	0,206
	UQ	0,555 (0,051)	0,035 (0,023)	$+0{,}520$	0,485
	UD	0,534 (0,016)	0,172 (0,038)	$+0{,}361$	0,338
Llama-3.2-3B	UA	0,746 (0,028)	0,491 (0,025)	$+0{,}255$	0,236
	UQ	0,580 (0,076)	0,052 (0,063)	$+0{,}528$	0,454
	UD	0,641 (0,026)	0,201 (0,029)	$+0{,}440$	0,406

Eine Ausnahme auf Beetle

Auf Beetle fällt die Ablation ohne Kontext anders aus als auf SciEntsBank (Tabelle 5.7). Auch dieser Vergleich beruht auf je drei Zufallssaaten derselben Umgebung.

Tabelle 5.7: Beetle, Llama-3.2-1B, fester Klassifikationskopf, ohne Aufgabenkontext: Ablation der Rubriktexte. Mittelwerte über drei Zufallssaaten, Spannweiten in Klammern.

Split	mit Rubriktext	ohne	Effekt	Urteil
UA	0,641 (0,055)	0,587 (0,011)	$+0{,}054$	Spannweiten disjunkt
UQ	0,456 (0,068)	0,457 (0,037)	$-0{,}001$	im Rauschen

Auf UA liegen alle drei Läufe mit Rubriktext über allen drei Läufen ohne; die Differenz von $0{,}054$ QWK bleibt allerdings knapp unter der Spannweite der rubrikhaltigen Bedingung und gilt nach der Auswertungsregel daher als Hinweis, nicht als gesicherter Effekt. Unter Macro-F_1 besteht derselbe Vergleich die Regel als Effekt ($+0{,}040$). Auf UQ ist der Unterschied mit $-0{,}001$ QWK exakt null, und beide Bedingungen liegen mit einer Accuracy von $0{,}581$ bis $0{,}611$ beziehungsweise $0{,}586$ bis $0{,}602$ klar über der Mehrheitsschranke von $0{,}420$.

Auf Beetle generalisiert das Modell also auch ohne jede Aufgabeninformation auf ungesehene Fragen, während es auf SciEntsBank vollständig scheitert. Eine plausible Erklärung liegt in der Domänenstruktur: Beetle umfasst 47 Trainingsfragen aus einer einzigen, eng umgrenzten

Domäne (Elektrizitätslehre), deren neun UQ-Fragen inhaltlich sehr nahe an den Trainingsfragen liegen. SciEntsBank verteilt 135 Trainingsfragen über zwölf Themenblöcke (Kapitel 3). Je enger die Domäne, desto eher lässt sich eine Bewertungskonvention allein aus dem Antworttext von einer Frage auf die nächste übertragen.

Das Schema auf dem zweiten Benchmark

Um zu prüfen, ob der Befund zur Austauschbarkeit beider Informationsquellen auf SciEntsBank beschränkt ist, wurde das 2×2-Schema auf Beetle wiederholt. Die beiden Bedingungen mit Aufgabenkontext liegen dort mit je einem Lauf vor und sind daher zurückhaltender zu bewerten als die SciEntsBank-Werte.

Tabelle 5.8: Beetle, Llama-3.2-1B, fester Klassifikationskopf: Verfügbarkeit von Aufgabenkontext und Rubriktext. Sämtliche Werte bei der Zufallssaat $114\,514$, um die Zellen untereinander vergleichbar zu halten. Für die beiden unteren Zeilen liegen zusätzlich drei Saaten vor (Mittelwerte $0{,}641$ / $0{,}456$ beziehungsweise $0{,}587$ / $0{,}457$).

Kontext	Rubriktext	UA	UQ
ja	ja	0,764	0,554
ja	nein	**0,799**	**0,602**
nein	ja	0,669	0,443
nein	nein	0,588	0,445

Tabelle 5.8 bestätigt das Muster von SciEntsBank und verschärft es in einem Punkt. Der Aufgabenkontext wirkt auch hier deutlich: Er bringt $+0{,}095$ / $+0{,}111$ QWK bei vorhandener Rubrik und $+0{,}211$ / $+0{,}157$ ohne sie. Kontext allein übertrifft Rubrik allein um $+0{,}131$ / $+0{,}158$ und damit noch klarer als auf SciEntsBank.

Der Rubriktext dagegen bringt bei vorhandenem Kontext nicht nur nichts, sondern kostet: $-0{,}036$ auf UA und $-0{,}047$ auf UQ. Beide Werte liegen in der Größenordnung der Rauschgrenze und beruhen auf je einem Lauf, sind also nicht als gesicherter Schaden zu lesen. Festzuhalten ist aber, dass das Vorzeichen auf beiden Benchmarks gegen einen zusätzlichen Nutzen der Rubriktexte spricht, sobald die Aufgabe selbst beschrieben ist.

Abbildung 5.1 stellt beide Schemata nebeneinander. Unter QWK ist das Muster auf beiden Benchmarks dasselbe. Die zwei Bedingungen mit Aufgabenkontext sind auf keinem Split sicher voneinander zu unterscheiden; auf Beetle beruhen sie auf Einzelläufen, deren Abstände in der Größenordnung der Rauschgrenze liegen. Die Bedingung mit Rubriktext allein liegt durchgehend darunter, und ohne jede aufgabenbezogene Information bricht die Leistung auf den Transfersplits ein.

Auch auf Beetle ist damit – wie schon auf SciEntsBank – die stärkste der untersuchten kleinen Konfigurationen diejenige *ohne* Rubriktexte. Ein Llama-3.2-1B mit Frage, Musterlösung und Antwort erreicht auf UA $0{,}799$ QWK und übertrifft damit sämtliche Läufe mit Llama-3.2-3B, die allerdings nie mit Aufgabenkontext trainiert wurden. Auf UQ erreicht dieselbe Konfiguration $0{,}602$ QWK und liegt damit praktisch gleichauf mit Mistral-7B, das dort mit Rubriktexten und ohne Kontext im Mittel über drei Saaten $0{,}605$ erzielt – bei etwa dem Sechsfachen an Parametern.

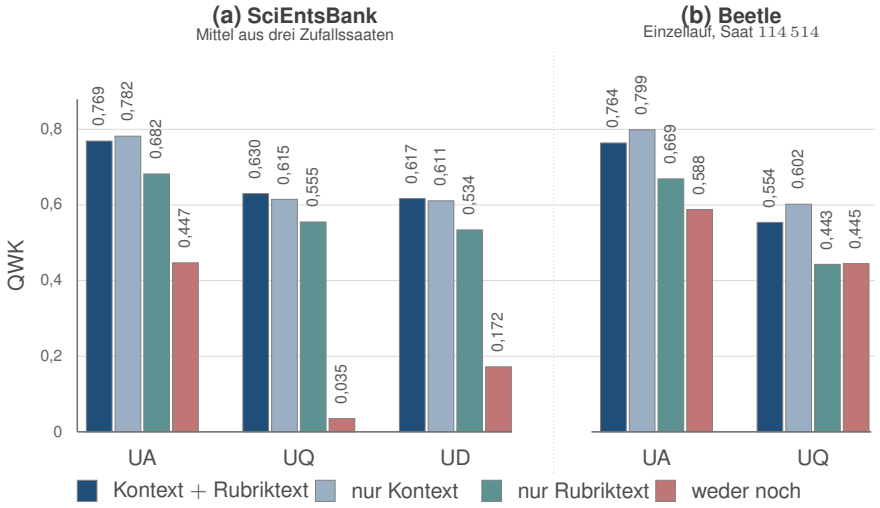


Abbildung 5.1: Verfügbarkeit von Aufgabenkontext und Rubriktext, Llama-3.2-1B mit festem Klassifikationskopf (Werte aus den Tabellen 5.5 und 5.8).

Höher liegt unter den beiden kleinen Backbones auf UQ allein der in Abschnitt 5.4.4 berichtete Lauf mit abweichender Lernrate ($0{,}605$).

Eine Einschränkung bleibt für beide Benchmarks bestehen: Frage und Musterlösung werden in der verwendeten Implementierung gemeinsam zu- oder abgeschaltet. Ob der beobachtete Kontext-Effekt auf die Aufgabenstellung, auf die Musterlösung oder auf beide zurückgeht, lässt sich mit den vorliegenden Läufen nicht entscheiden und bleibt offen (Kapitel 7).

Einordnung

Dieser Abschnitt liefert den mit Abstand größten Effekt dieser Arbeit – und zugleich eine Einschränkung ihrer Ausgangsannahme. Entscheidend ist, *dass* dem Modell aufgabenbezogene Information zur Verfügung steht, nicht, in welcher Form. Wie diese Information anschließend extrahiert und verrechnet wird, ist Gegenstand von RQ2 (Abschnitt 5.4).

5.3.3 Encoder- gegenüber LLM-basierten Ansätzen

Der Vergleich in Tabelle 5.9 erweist die Wahl des Evaluationssplits erneut als entscheidend.

Auf UA-Splits sind Encoder konkurrenzfähig. Auf ASAP-SAS erreicht RoBERTa mit $0{,}821$ QWK nahezu das Niveau von Llama-3.2-1B ($0{,}827$) – bei einem Bruchteil der Parameter und ohne LoRA-Overhead. Auf Beetle-UA liegt RoBERTa mit $0{,}694$ um $0{,}035$ hinter dem Llama-Mittelwert und damit im Bereich der Rauschgrenze. Auf SciEntsBank-UA gilt dies nicht: Dort beträgt der Rückstand $0{,}069$ QWK und übersteigt die Rauschgrenze deutlich. Hätte diese Arbeit nur die UA-Splits von ASAP-SAS und Beetle ausgewertet, wäre der Schluss naheliegend gewesen, dass Decoder-only-LLMs für diese Aufgabe keinen Mehrwert bieten.

Tabelle 5.9: Encoder-Baselines gegenüber Llama-3.2-1B (jeweils CONDIFF, kausal), QWK. Encoder-Werte sind Einzelläufe einer frühen Trainingswelle, von der nur die Vorhersagen erhalten sind; Llama-Werte sind Mittelwerte über drei Zufallssaaten. ‡Lauf mit Ergebnis auf Zufallsniveau, von der Deutung ausgenommen (Abschnitt 4.6).

Benchmark	Split	BERT-base	RoBERTa-base	Llama-3.2-1B
ASAP-SAS	UA	0,788	0,821	0,827
Beetle	UA	0,478	0,694	0,729
	UQ	—	0,289	**0,509**
SciEntsBank	UA	0,052‡	0,633	**0,702**
	UQ	0,061‡	0,451	**0,544**
	UD	$-0{,}004$‡	0,472	**0,560**

Auf Transfersplits bricht der Encoder-Vorteil zusammen. Auf Beetle-UQ fällt RoBERTa auf $0{,}289$ QWK, während Llama-3.2-1B $0{,}509$ hält – ein Abstand von $0{,}221$, also ein Vielfaches der Rauschgrenze. Der Abfall von UA zu UQ beträgt für RoBERTa $0{,}406$, für Llama-3.2-1B lediglich $0{,}220$. Auf SciEntsBank liegt Llama-3.2-1B auf allen drei Splits vorn, mit Abständen von $0{,}069$ bis $0{,}093$.

Das Muster ist mit der in Abschnitt 2.4 referierten Motivation vereinbar: Kann ein Modell die Bewertungskonvention einer bekannten Frage lernen, scheint die Repräsentationsfähigkeit eines mittelgroßen Encoders zu genügen; ist die Frage neu, könnte das im Vortraining erworbene Wissen des größeren Sprachmodells den Ausschlag geben. Belegt ist dieser Mechanismus mit den vorliegenden Läufen nicht, da sich Encoder und Decoder zugleich in Architektur, Parameterzahl, Kontextlänge und Trainingskonfiguration unterscheiden (Abschnitt 4.6).

Die BERT-Werte auf SciEntsBank liegen auf allen drei Splits auf Zufallsniveau. Eine ergänzende Lernratenvariation (Abschnitt 4.6, Tabelle 4.4) behebt diesen Ausfall nicht und bestätigt zugleich, dass die RoBERTa-Werte in Tabelle 5.9 nicht wesentlich unterschätzt sind; der Einbruch von RoBERTa auf Beetle-UQ tritt bei jeder geprüften Lernrate auf.

5.3.4 Übertragung zwischen Benchmarks

Die bisherigen Vergleiche messen die Leistung auf festen Labelräumen. Eine Eigenschaft, die dem Span-Alignment strukturell vorbehalten ist, kann sich dort nicht zeigen: Da die Stufen als Rubrik-Spans in der Eingabe stehen, lässt sich ein trainiertes Modell ohne Anpassung des Ausgabekopfs auf Aufgaben mit anderen Rubriken und anderer Stufenzahl anwenden (Abschnitt 4.1). Ob diese strukturelle Übertragbarkeit zu einer brauchbaren Bewertung führt, prüft das Transferexperiment aus Abschnitt 4.5.5. Llama-3.2-1B und -3B wurden mit CONDIFF und kausaler Attention ausschließlich auf ASAP-SAS trainiert und validiert und anschließend ohne weiteres Training auf den Testsplits von Beetle und SciEntsBank ausgewertet, jeweils mit den Rubriktexten des Zielbenchmarks. Ein fester Klassifikationskopf ist für diesen Aufbau nicht anwendbar, da ASAP-SAS drei- und vierstufige Aufgaben mischt. Als Vergleichsmaßstab dienen die auf dem jeweiligen Zielbenchmark trainierten CONDIFF-Läufe desselben Backbones.

Tabelle 5.10: Übertragung von ASAP-SAS auf Beetle und SciEntsBank (CONDIFF, kausal), QWK. *Transfer*: ausschließlich auf ASAP-SAS trainiert; *In-Domain*: auf dem Zielbenchmark trainiert. Mittelwerte über drei Zufallssaaten, Spannweiten in Klammern.

		Llama-3.2-1B		Llama-3.2-3B	
Benchmark	**Split**	Transfer	In-Domain	Transfer	In-Domain
Beetle	UA	$-0{,}001$ (0,003)	0,729 (0,023)	$-0{,}004$ (0,011)	0,730 (0,041)
	UQ	$0{,}000$ (0,001)	0,509 (0,073)	$-0{,}017$ (0,060)	0,544 (0,044)
SciEntsBank	UA	$0{,}008$ (0,012)	0,702 (0,007)	$0{,}022$ (0,014)	0,734 (0,047)
	UQ	$0{,}005$ (0,014)	0,544 (0,058)	$0{,}008$ (0,005)	0,576 (0,009)
	UD	$0{,}003$ (0,008)	0,560 (0,026)	$0{,}017$ (0,015)	0,617 (0,028)

Die Übertragung scheitert vollständig. Auf allen fünf Splits und beiden Backbones liegt das QWK zwischen $-0{,}017$ und $0{,}022$ und damit auf Zufallsniveau (Tabelle 5.10). Der Abstand zu den In-Domain-Läufen beträgt $0{,}510$ bis $0{,}734$ QWK und übersteigt die Rauschgrenze in jeder Zelle um ein Vielfaches; unter Macro-F_1 besteht er ebenso in allen zehn Zellen als Effekt.

Ursache ist ein Kollaps auf die unterste Stufe. Llama-3.2-1B ordnet in jeder der 15 Auswertungen (drei Saaten, fünf Splits) zwischen $97{,}2$ und $100\,\%$ der Antworten der Stufe *incorrect* zu, Llama-3.2-3B zwischen $80{,}2$ und $97{,}1\,\%$. Die Accuracy der Einzelläufe von $0{,}303$ bis $0{,}374$ entspricht damit annähernd dem Anteil dieser Stufe in den Referenzdaten und liegt durchgängig unter der Mehrheitsschranke von $0{,}401$ bis $0{,}431$, die auf die Stufe *correct* entfällt. Anders als die Modelle ohne jede Aufgabeninformation in Abschnitt 5.3.2, die alle drei Stufen vorhersagen, ist dies ein degenerierter Klassifikator.

Auch das größte Backbone kollabiert. Ein einzelner Transferlauf mit Mistral-7B (Saat $114\,514$) zeigt dasselbe Bild: Das QWK liegt auf den fünf Splits zwischen $0{,}000$ und $0{,}017$, und zwischen $97{,}2$ und $100\,\%$ der Antworten werden der Stufe *incorrect* zugeordnet – ein ebenso vollständiger Kollaps wie bei Llama-3.2-1B. Zusätzliche Modellkapazität behebt das Scheitern der Übertragung demnach nicht; ein mit der Größe abnehmender Kollaps ist über die drei Backbones nicht erkennbar.

Eine naheliegende Erklärung liefert die Antwortlänge. Im Trainingssplit von ASAP-SAS hängt die Stufe stark von der Länge der Antwort ab: Von den Antworten mit höchstens zehn Wörtern erhalten $89{,}8\,\%$ die Stufe 0, von denen mit 11 bis 20 Wörtern $66{,}9\,\%$, von denen mit mehr als 40 Wörtern nur $19{,}3\,\%$. Die Antworten der Zielbenchmarks sind dagegen kurz, mit einer Medianlänge von 9 (Beetle) und 11 Wörtern (SciEntsBank) gegenüber 39 auf ASAP-SAS (Tabelle 3.4); 95 bis $96\,\%$ der Beetle- und 86 bis $89\,\%$ der SciEntsBank-Testantworten umfassen höchstens 20 Wörter. Ein Modell, das auf ASAP-SAS kurze Antworten mit niedrigen Stufen zu verbinden gelernt hat, ordnet auf den Zielbenchmarks nahezu jede Antwort der untersten Stufe zu. Dazu passt, dass die wenigen Antworten, denen die Transfermodelle eine höhere Stufe zuweisen, im Mittel länger sind: $24{,}0$ gegenüber $11{,}1$ Wörtern bei Llama-3.2-1B, $15{,}2$ gegenüber $10{,}9$ Wörtern bei Llama-3.2-3B und $22{,}6$ gegenüber $11{,}0$ Wörtern bei Mistral-7B. Begünstigt wird dieser Zusammenhang durch die Bewertungsrichtlinien von ASAP-SAS, die bei vier der zehn Aufgaben (Items 1, 2, 5 und 6) die Stufe über die Zahl genannter Inhaltselemente festlegen, für Item 5 etwa „Four key elements“ für die höchste Stufe. Länge und Stufe korrelieren dort bereits nach der Richtlinie.

Die Längenerklärung ist eine Hypothese. Sie ist mit den Daten vereinbar, wurde aber nicht kausal geprüft, etwa durch eine Auswertung bei kontrollierter Antwortlänge. Zum Scheitern können ebenso die Unterschiede in Domäne und Bewertungskonvention beitragen sowie die Herkunft der Rubriktexte, die auf ASAP-SAS von den Aufgabenerstellern stammen und auf den Zielbenchmarks sprachmodellgestützt erzeugt wurden (Kapitel 3).

Strukturelle Übertragbarkeit ist keine inhaltliche. Für RQ1 trennt das Experiment zwei Eigenschaften, die in der Motivation der Architektur zusammenfallen. Strukturell gelingt die Übertragung: Dasselbe Modell bewertet ohne jede Anpassung Aufgaben mit drei, vier und auf den Zielbenchmarks erneut drei Stufen; mit festem Kopf ist bereits das gemeinsame Training auf ASAP-SAS ausgeschlossen. Inhaltlich findet dagegen keine Übertragung statt. Die Rubriktexte des Zielbenchmarks werden nicht so genutzt, dass sie die auf ASAP-SAS gelernte Heuristik überstimmen. Die strukturelle Übertragbarkeit ist demnach eine notwendige, aber keine hinreichende Bedingung für eine Bewertung über Benchmarks hinweg.

5.4 RQ2: Anpassung von Decoder-only-Modellen

Die zweite Forschungsfrage lautet, ob und wie sich Decoder-only-Sprachmodelle an das Span-Alignment anpassen lassen. Untersucht werden die Ausgestaltung des Alignments, also der Fusionsmechanismus (Abschnitt 5.4.1) und die Bezugsgröße der Fusion (Abschnitt 5.4.2), ferner die Attention-Maske (Abschnitt 5.4.3) und die Größe des Backbones (Abschnitt 5.4.4).

5.4.1 Fusionsmechanismen

Einzelläufe je Benchmark

Die Tabellen 5.11 und 5.12 dokumentieren die Ergebnisse der Fusionsvarianten, auf ASAP-SAS als Einzelläufe, auf Beetle und SciEntsBank als Mittelwerte über drei Zufallssaaten, dort für alle drei Decoder-Backbones. DIFF wurde ausschließlich auf Llama-3.2-3B untersucht. Die Tabellen dienen der Vollständigkeit; die Interpretation erfolgt anschließend auf Grundlage der Mittelwerte über drei Zufallssaaten.

Tabelle 5.11: ASAP-SAS (UA): Fusionsmechanismen bei kausaler Attention. Einzelläufe, Zufallssaat $114\,514$. Fett: höchster Wert je Spalte innerhalb eines Backbones; die Markierung trifft keine Aussage über die Nachweisbarkeit eines Unterschieds (vgl. Tabelle 5.13).

	Llama-3.2-1B			**Llama-3.2-3B**			**Mistral-7B**		
	QWK	F_1	Acc	QWK	F_1	Acc	QWK	F_1	Acc
CONDIFF	0,818	0,729	0,767	0,838	0,762	0,786	**0,860**	**0,803**	**0,809**
CONCAT	0,828	**0,750**	**0,781**	**0,842**	**0,769**	**0,796**	0,855	0,788	0,800
GATE	**0,829**	**0,750**	0,777	0,841	0,765	0,789	0,858	0,790	0,801

Tabelle 5.12: Beetle und SciEntsBank: Fusionsmechanismen bei kausaler Attention, QWK je Split. Mittelwerte über drei Zufallssaaten; DIFF wurde nur auf Llama-3.2-3B untersucht. Fett: höchster Wert je Spalte innerhalb eines Backbones; die Markierung trifft keine Aussage über die Nachweisbarkeit eines Unterschieds (vgl. Tabelle 5.13).

		Beetle		SciEntsBank		
Backbone	**Fusion**	UA	UQ	UA	UQ	UD
Llama-3.2-1B	CONDIFF	**0,729**	**0,509**	0,702	0,544	0,560
	CONCAT	0,725	0,503	0,698	**0,569**	**0,577**
	GATE	0,696	0,471	**0,718**	0,564	0,559
Llama-3.2-3B	CONDIFF	0,730	0,544	0,734	0,576	0,617
	CONCAT	0,735	0,546	0,720	0,582	0,626
	GATE	**0,757**	0,550	**0,737**	**0,624**	**0,630**
	DIFF	0,740	**0,572**	0,722	0,579	0,623
Mistral-7B	CONDIFF	0,779	**0,605**	0,755	0,639	0,641
	CONCAT	0,772	0,604	0,750	**0,652**	**0,647**
	GATE	**0,781**	0,567	**0,758**	0,632	0,638

Der Unterschied zwischen den Varianten liegt unterhalb der Rauschgrenze

Tabelle 5.13 stellt den Unterschied *zwischen* den Fusionsmechanismen der Streuung *innerhalb* einer Fusionsvariante gegenüber. In allen fünfzehn Konfigurationen aus Benchmark, Backbone und Split übersteigt die Streuung über die Saaten den Abstand zwischen den Varianten, im Extremfall um fast das Sechsfache. Am deutlichsten ist das bei Mistral-7B: Auf den UA-Splits beider Benchmarks liegen die drei Varianten im Mittel nur $0{,}008$ beziehungsweise $0{,}009$ QWK auseinander, bei Saat-Spannweiten von bis zu $0{,}050$. Nach der in Abschnitt 5.2 formulierten Regel ist ein Unterschied zwischen den Fusionsvarianten auf dieser Datengrundlage folglich *nicht als Effekt nachweisbar*.

Vier Paarvergleiche erfüllen allerdings das schwächere Kriterium: GATE gegenüber CONDIFF auf Beetle-UA und auf SciEntsBank-UQ sowie GATE gegenüber DIFF auf Beetle-UA, sämtlich mit Llama-3.2-3B, und CONDIFF gegenüber GATE auf Beetle-UQ mit Mistral-7B. Dort überlappen die Spannweiten der beiden Bedingungen nicht, während die Differenz der Mittelwerte ($0{,}027$, $0{,}049$, $0{,}017$ und $0{,}038$ QWK) jeweils unter der größeren der beiden Spannweiten bleibt. Nach der Auswertungsregel ist dies ein schwacher Hinweis, kein Ergebnis. Der Hinweis bei Mistral-7B weist dabei in die Gegenrichtung der drei übrigen: Dort liegt GATE hinten. Unter Macro-F_1 verschieben sich neun Paarurteile zwischen diesen Kategorien; das Gesamtbild bleibt davon unberührt (Abschnitt 5.5.3).

Die Konsequenz reicht weiter, als es zunächst scheint. Tabelle 5.14 zeigt, welche Variante in welcher Zelle den höchsten Einzelwert erreicht.

Beim kleineren Backbone wechselt die Rangfolge zwischen Benchmarks und Splits ohne erkennbares Muster – genau das zu erwartende Bild, wenn die zugrunde liegenden Unterschiede tatsächlich Null sind und die Reihenfolge allein durch die Zufallssaat bestimmt wird. Bei Llama-3.2-3B liegt dagegen in vier von fünf Zellen GATE vorn; in der fünften, Beetle-UQ, führt

Tabelle 5.13: Unterschied zwischen den Fusionsmechanismen (Spannweite der Mittelwerte von CONDIFF, CONCAT und GATE, bei Llama-3.2-3B zusätzlich DIFF) gegenüber der größten Saat-Spannweite derselben Zellen.

Benchmark	Backbone	Split	zw. Varianten	max. Saat-Δ	Verhältnis
Beetle	Llama-1B	UA	0,033	0,051	$1{,}5\times$
Beetle	Llama-1B	UQ	0,038	0,118	$3{,}1\times$
Beetle	Llama-3B	UA	0,027	0,042	$1{,}6\times$
Beetle	Llama-3B	UQ	0,028	0,048	$1{,}7\times$
Beetle	Mistral-7B	UA	0,008	0,046	$5{,}6\times$
Beetle	Mistral-7B	UQ	0,038	0,058	$1{,}5\times$
SciEntsBank	Llama-1B	UA	0,020	0,039	$1{,}9\times$
SciEntsBank	Llama-1B	UQ	0,025	0,058	$2{,}3\times$
SciEntsBank	Llama-1B	UD	0,017	0,047	$2{,}7\times$
SciEntsBank	Llama-3B	UA	0,016	0,047	$2{,}8\times$
SciEntsBank	Llama-3B	UQ	0,049	0,060	$1{,}2\times$
SciEntsBank	Llama-3B	UD	0,013	0,035	$2{,}7\times$
SciEntsBank	Mistral-7B	UA	0,009	0,050	$5{,}9\times$
SciEntsBank	Mistral-7B	UQ	0,020	0,063	$3{,}2\times$
SciEntsBank	Mistral-7B	UD	0,009	0,037	$3{,}9\times$

DIFF. Dieses Bild ist mit den drei oben genannten disjunkten Spannweiten für dieses Backbone konsistent, die sämtlich GATE betreffen, und es ist zurückhaltend zu bewerten: Keine der Differenzen übersteigt die Spannweite der beteiligten Bedingungen, und die fünf Zellen sind nicht unabhängig voneinander, da sie auf denselben Läufen beruhen und lediglich nach Split getrennt ausgewertet werden.

Festzuhalten bleibt, dass dieser Hinweis der in Abschnitt 4.4.1 formulierten Erwartung *entgegen*läuft: Dort war vermutet worden, ein parameterreicher Mechanismus wie GATE falle bei kleineren Backbones relativ stärker ins Gewicht. Mistral-7B bestätigt das Muster von Llama-3.2-3B jedoch nicht. Dort führt GATE in zwei Zellen, CONCAT in zwei und CONDIFF in einer – wieder das Bild eines zufälligen Wechsels –, und der einzige Hinweis auf diesem Backbone geht zulasten von GATE. Über die drei Backbones liegt GATE in einer, vier und zwei von fünf

Tabelle 5.14: Beste Fusionsvariante je Benchmark, Split und Backbone nach dem Mittelwert über drei Zufallssaaten. Die Rangfolge ist nach Tabelle 5.13 nicht belastbar und wird hier ausschließlich zur Illustration ihrer Beliebigkeit angegeben.

Benchmark	Split	Llama-1B	Llama-3B	Mistral-7B
Beetle	UA	CONDIFF	GATE	GATE
	UQ	CONDIFF	DIFF	CONDIFF
SciEntsBank	UA	GATE	GATE	GATE
	UQ	CONCAT	GATE	CONCAT
	UD	CONCAT	GATE	CONCAT

Zellen vorn; ein mit der Größe des Backbones wachsender Vorteil eines der beiden Mechanismen ist nicht erkennbar. Eine Deutung einzelner Rangfolgen – etwa dass der Differenzterm von CONDIFF der Generalisierung zugutekomme – ist auf dieser Grundlage ebenso wenig zu rechtfertigen. Solche Deutungen wären an Einzelläufen durchaus plausibel gewesen; sie halten der Wiederholung unter mehreren Zufallssaaten nicht stand.

Für die Fragestellung dieser Arbeit ist das ein aussagekräftiges negatives Ergebnis: Der parameterfreie Differenzterm von CONDIFF (4.6) bringt gegenüber der reinen Konkatenation auf keinem der drei Backbones einen nachweisbaren Vorteil, und umgekehrt tragen die unveränderten Einzelrepräsentationen gegenüber dem Differenzterm allein nichts bei: Auf Llama-3.2-3B liegt DIFF (4.8) in vier von fünf Zellen nominell vor CONDIFF, durchweg im Rauschen. Die d^2 zusätzlichen Parameter der Gate-Projektion (4.9) rechtfertigen ihren Aufwand nach der Auswertungsregel ebenfalls nicht. Da CONCAT und DIFF die einfachsten Konstruktionen sind – DIFF mit dem kleinsten Scoring-Kopf –, folgt daraus eine praktische Empfehlung zugunsten einer einfachen Konstruktion; für DIFF stützt sie sich allerdings allein auf Llama-3.2-3B.

5.4.2 Bezugsgröße der Fusion

Die zweite Frage zur Ausgestaltung der Fusion betrifft die Wahl der Kontextrepräsentation in (2.18). Die vorliegende Arbeit verwendet durchgängig die Sequenzrepräsentation z; Gombert u. a. [22] richten stattdessen die Repräsentation des *Antwort*-Spans an den Rubrik-Spans aus. Zur Prüfung wurde die Variante „t-concat“ untersucht, die sich von CONCAT ausschließlich durch die Bezugsgröße unterscheidet: Statt $[\, z \,\|\, r_k \,]$ bildet sie $[\, t \,\|\, r_k \,]$, wobei t die nach demselben Verfahren gepoolte Repräsentation des Antwort-Spans bezeichnet (Abschnitt 4.1.2).

Tabelle 5.15: Bezugsgröße der Fusion auf Llama-3.2-3B: Antwort-Span (t-concat) gegenüber Sequenzrepräsentation (CONCAT, CONDIFF). Mittelwerte über drei Zufallssaaten, Spannweiten in Klammern.

Benchmark	Split	t-concat	CONCAT	CONDIFF	Δ zu CONCAT
Beetle	UA	0,761 (0,006)	0,735 (0,042)	0,730 (0,041)	$+0{,}026$
	UQ	0,552 (0,019)	0,546 (0,046)	0,544 (0,044)	$+0{,}006$
SciEntsBank	UA	0,734 (0,066)	0,720 (0,042)	0,734 (0,047)	$+0{,}013$
	UQ	0,584 (0,059)	0,582 (0,049)	0,576 (0,009)	$+0{,}002$
	UD	0,615 (0,019)	0,626 (0,035)	0,617 (0,028)	$-0{,}011$

Tabelle 5.15 zeigt in vier der fünf Zellen vollständig überlappende Spannweiten bei Differenzen zwischen $0{,}002$ und $0{,}013$ QWK. Die einzige Ausnahme ist Beetle-UA: Dort überlappen die Spannweiten von t-concat und CONCAT nicht, die Lücke beträgt jedoch lediglich $0{,}007$ QWK, und die Differenz der Mittelwerte $(0{,}026)$ bleibt unter der Spannweite von CONCAT $(0{,}042)$. Nach der Auswertungsregel ist dies ein schwacher Hinweis, kein Effekt. Unter Macro-F_1 besteht derselbe Vergleich die Regel knapp als Effekt $(+0{,}014)$; die Differenz bleibt aber klein (Abschnitt 5.5.3).

Dieses Ergebnis verdient eine methodische Anmerkung, weil es die Notwendigkeit der Wiederholung besonders anschaulich belegt. Läge nur der Lauf mit der Zufallssaat $114\,514$ vor, ergäbe

sich ein deutlich anderes Bild: t-concat erreichte dort auf SciEntsBank-UA $0{,}762$ gegenüber einem CONCAT-Bereich von $0{,}701$ bis $0{,}743$ und auf SciEntsBank-UQ $0{,}601$ gegenüber $0{,}550$ bis $0{,}598$ – in beiden Fällen oberhalb sämtlicher Vergleichsläufe. Auch der Lauf mit der Saat 1 liegt mit $0{,}744$ und $0{,}604$ knapp oberhalb dieser Bereiche. Der Lauf mit der Saat 2 fällt dagegen auf $0{,}696$ beziehungsweise $0{,}545$ und damit unter den jeweils schwächsten CONCAT-Lauf. Im Mittel bleibt dadurch ein Vorsprung von nur $0{,}013$ und $0{,}002$ QWK, der vollständig innerhalb der Spannweiten liegt. Zwei von drei Ziehungen hätten als Einzellauf einen Vorteil nahegelegt, den die dritte aufhebt.

Für die Arbeit folgt daraus: Ob als Bezugsgröße der Antwort-Span oder die Sequenzrepräsentation dient, macht keinen Unterschied oberhalb der Rauschgrenze. Das ist insofern bemerkenswert, als beide Repräsentationen unterschiedliche Informationen tragen – t endet vor den Rubriktexten und hat diese unter kausaler Maske nicht gesehen, z steht am Sequenzende und hat sie alle gesehen (Abschnitt 4.1.2). Dass dieser Unterschied folgenlos bleibt, deutet darauf hin, dass die für die Bewertung ausschlaggebende Information bereits in der Antwortrepräsentation enthalten ist und die zusätzliche Kenntnis der übrigen Stufen keinen verwertbaren Beitrag leistet.

5.4.3 Attention-Maske

Die Attention-Maske ist die einzige Variation innerhalb der Span-Alignment-Architektur, deren Wirkung die Rauschgrenze deutlich überschreitet. Sie wird in zwei Schritten ausgewertet: zunächst die anteilige Aufhebung der Kausalität auf Einzelläufen, anschließend die vollständige Aufhebung unter drei Zufallssaaten auf beiden Llama-Größen.

Anteilige Aufhebung

Über die Einzelläufe hinweg zeigt sich *kein* monotoner Zusammenhang zwischen der Zahl bidirektionaler Schichten und der Leistung (Abbildung 5.2). Die stärkste Bedingung ist je nach Zelle die kausale Referenz, eine einzelne bidirektionale Schicht oder eine mittlere Schichtzahl. Da sämtliche Werte dieser beiden Tabellen auf Einzelläufen beruhen und die beobachteten Abstände weit überwiegend unterhalb der Rauschgrenze von $0{,}036$ QWK liegen, sind sie einzeln nicht interpretierbar. Auch die vollständig bidirektionale Bedingung weicht auf ASAP-SAS kaum von der kausalen Referenz ab; unter drei Saaten beträgt die Differenz $+0{,}003$ (Llama-3.2-1B) und $+0{,}001$ QWK (Llama-3.2-3B), im Einzellauf mit Mistral-7B $-0{,}007$.

Eine Beobachtung überschreitet diese Schwelle: Bei Llama-3.2-1B auf Beetle steigt der UA-Wert über den Bereich von null bis zwölf bidirektionalen Schichten um $0{,}053$ QWK, während der UQ-Wert im selben Bereich um $0{,}119$ fällt. Diese gegenläufige Entwicklung ist deutlich genug, um bemerkenswert zu sein, beruht jedoch auf je einem Lauf und bedürfte der Absicherung durch Wiederholung.

Tabelle 5.16: ASAP-SAS (UA): Attention-Maske bei CONDIFF-Fusion, sortiert nach der tatsächlichen Zahl bidirektionaler Schichten n_{bidir}. Einzelläufe, Zufallssaat $114\,514$; für die kausale und die vollständig bidirektionale Bedingung der beiden Llama-Größen liegen zusätzlich drei Saaten vor (Tabellen 5.18 und 5.19). Für Mistral-7B stammt die vollständig bidirektionale Bedingung aus einer anderen Softwareumgebung als die übrigen Läufe dieser Spalte. Fett: höchster Wert je Spalte; die Markierung trifft keine Aussage über die Nachweisbarkeit eines Unterschieds.

	Llama-3.2-1B ($L = 16$)			**Llama-3.2-3B** ($L = 28$)			**Mistral-7B** ($L = 32$)		
ρ	n_{bidir}	QWK	F_1	n_{bidir}	QWK	F_1	n_{bidir}	QWK	F_1
0 (kausal)	0	0,818	0,729	0	0,838	0,762	0	**0,860**	**0,803**
$1{,}0$	1	0,821	0,743	1	**0,843**	**0,773**	1	0,849	0,782
$0{,}2$	3	0,822	0,745	5	0,836	0,764	6	0,851	0,784
$0{,}4$	6	0,822	0,738	11	0,834	0,765	12	0,845	0,783
$0{,}6$	9	0,819	0,744	16	0,834	0,765	19	0,855	0,792
$0{,}8$	12	0,823	0,748	22	0,839	0,767	25	0,847	0,787
L (vollst.)	16	**0,825**	**0,754**	28	0,840	0,770	32	0,853	0,782

Vollständige Aufhebung

Die aussagekräftigere Bedingung ist die vollständige Aufhebung der Kausalität in allen Schichten. Sie wurde für Llama-3.2-3B (28 Schichten) und Llama-3.2-1B (16 Schichten) unter je drei Zufallssaaten ausgeführt und der kausalen CONDIFF-Referenz desselben Backbones gegenübergestellt. Tabelle 5.18 berichtet zunächst das größere Backbone.

Tabelle 5.18 enthält für Llama-3.2-3B den deutlichsten Architektureffekt dieser Arbeit – und zugleich den einzigen, der zwischen Benchmarks das Vorzeichen wechselt.

Auf Beetle schadet die vollständige Aufhebung erheblich. Der Verlust beträgt $0{,}073$ QWK auf UA und $0{,}186$ auf UQ. Auf beiden Splits überlappen die Spannweiten nicht; auf UQ liegt der beste bidirektionale Lauf ($0{,}419$) noch um $0{,}109$ unter dem schlechtesten kausalen ($0{,}528$). Bemerkenswert ist zudem die erhöhte Streuung: Die Spannweite steigt von $0{,}044$ auf $0{,}094$, das Training wird also nicht nur schlechter, sondern auch instabiler.

Auf SciEntsBank nützt sie. Der Gewinn beträgt $0{,}060$ QWK auf UQ – mit disjunkten Spannweiten und einer Lücke von $0{,}043$ – sowie $0{,}032$ auf UA, wo die Spannweiten ebenfalls nicht überlappen, die Differenz der Mittelwerte jedoch unter der Spannweite der kausalen Referenz bleibt. Auf UD ist kein Unterschied nachweisbar.

Auf ASAP-SAS ist sie ohne Wirkung. Mit $0{,}836$ gegenüber $0{,}835$ QWK liegen beide Bedingungen praktisch gleichauf, bei Spannweiten von höchstens $0{,}008$.

Unter Macro-F_1 bestehen die beiden UQ-Befunde, der Verlust auf Beetle und der Gewinn auf SciEntsBank, unverändert als Effekt. Der Verlust auf Beetle-UA und der Hinweis auf SciEntsBank-UA sind dort dagegen nicht nachweisbar (Abschnitt 5.5.3).

Auf dem kleineren Backbone ergibt sich ein anderes Bild. Tabelle 5.19 stellt dieselbe Bedingung für Llama-3.2-1B dar, ebenfalls unter drei Zufallssaaten.

Tabelle 5.17: Beetle und SciEntsBank: Attention-Maske bei CONDIFF-Fusion, QWK je Split, sortiert nach n_{bidir}. Einzelläufe, Zufallssaat $114\,514$. Für Llama-3.2-3B und Mistral-7B liegen dieselben Bedingungen ebenfalls als Einzelläufe vor; sie werden hier nicht aufgeführt, da sie zu keiner Aussage beitragen, die nicht schon aus der vollständigen Aufhebung folgt. Fett: höchster Wert je Spalte; die Markierung trifft keine Aussage über die Nachweisbarkeit eines Unterschieds.

	Beetle, Llama-3.2-1B			**SciEntsBank, Llama-3.2-1B**			
ρ	n_{bidir}	UA	UQ	n_{bidir}	UA	UQ	UD
0 (kausal)	0	0,696	0,532	0	**0,705**	**0,582**	0,572
$1{,}0$	1	0,707	**0,544**	1	0,691	0,547	0,558
$0{,}2$	3	0,711	0,526	3	0,697	0,551	0,555
$0{,}4$	6	0,691	0,472	6	0,683	0,571	0,561
$0{,}6$	9	0,724	0,503	9	0,681	0,533	0,541
$0{,}8$	12	**0,750**	0,413	12	0,704	0,567	**0,589**

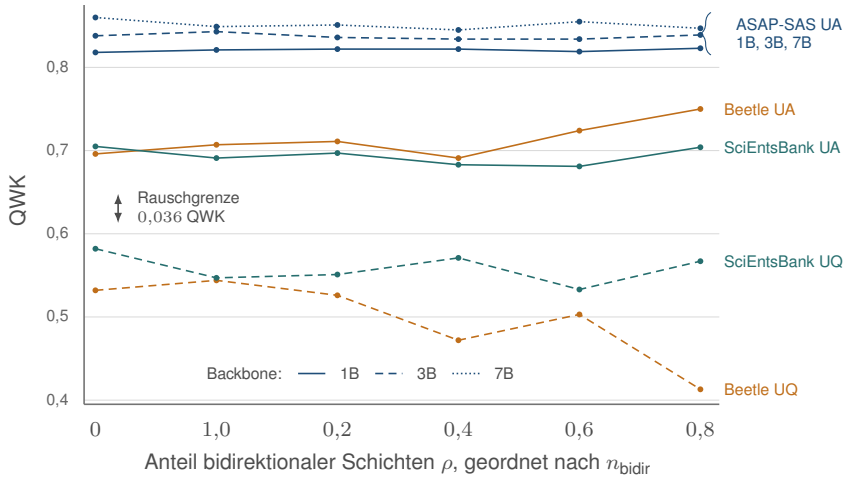


Abbildung 5.2: QWK in Abhängigkeit von der Zahl bidirektionaler Schichten n_{bidir}, CONDIFF, Einzelläufe, mit eingezeichneter Rauschgrenze (Werte aus den Tabellen 5.16 und 5.17).

Tabelle 5.18: Vollständig bidirektionale Attention ($n_{\text{bidir}} = L = 28$) gegenüber kausaler Attention, Llama-3.2-3B, CONDIFF-Fusion. Mittelwerte über drei Zufallssaaten, Spannweiten in Klammern.

Benchmark	**Split**	**bidirektional**	**kausal**	Δ	**Urteil**
ASAP-SAS	UA	0,836 (0,008)	0,835 (0,004)	$+0{,}001$	im Rauschen
Beetle	UA	0,657 (0,061)	0,730 (0,041)	$-0{,}073$	über Rauschgrenze
	UQ	0,358 (0,094)	0,544 (0,044)	$-0{,}186$	weit über Rauschgrenze
SciEntsBank	UA	0,767 (0,024)	0,734 (0,047)	$+0{,}032$	Spannweiten disjunkt
	UQ	0,636 (0,026)	0,576 (0,009)	$+0{,}060$	über Rauschgrenze
	UD	0,625 (0,036)	0,617 (0,028)	$+0{,}008$	im Rauschen

Tabelle 5.19: Vollständig bidirektionale Attention ($n_{\text{bidir}} = L = 16$) gegenüber kausaler Attention, Llama-3.2-1B, CONDIFF-Fusion. Mittelwerte über drei Zufallssaaten, Spannweiten in Klammern. *Über Spannweite* wie in Tabelle 5.4. Mit acht Saaten der kausalen Bedingung ist der Unterschied auf Beetle-UA nicht nachweisbar (Tabelle 5.3).

Benchmark	Split	bidirektional	kausal	Δ	Urteil
ASAP-SAS	UA	0,830 (0,010)	0,827 (0,016)	$+0{,}003$	im Rauschen
Beetle	UA	0,765 (0,017)	0,729 (0,023)	$+0{,}036$	über Spannweite
	UQ	0,493 (0,058)	0,509 (0,073)	$-0{,}016$	im Rauschen
SciEntsBank	UA	0,692 (0,049)	0,702 (0,007)	$-0{,}010$	im Rauschen
	UQ	0,553 (0,087)	0,544 (0,058)	$+0{,}009$	im Rauschen
	UD	0,588 (0,046)	0,560 (0,026)	$+0{,}028$	im Rauschen

Auf ASAP-SAS und SciEntsBank ist beim kleineren Backbone auf keinem Split ein Unterschied nachweisbar; sämtliche Spannweiten überlappen. Aufschlussreich ist dabei die Rolle der einzelnen Saaten: Der Lauf mit der Saat $114\,514$ ist auf allen drei SciEntsBank-Splits der schwächste der drei und hätte als Einzellauf gegenüber der kausalen Referenz derselben Saat einen Verlust von bis zu $0{,}084$ QWK nahegelegt.

Auf Beetle kehrt sich das Vorzeichen nominell um. Auf UA gewinnt das kleinere Backbone mit drei Saaten $0{,}036$ QWK; die Spannweiten sind disjunkt, und die Differenz übersteigt die größere von ihnen $(0{,}023)$, sodass nach der Auswertungsregel ein Effekt vorläge. Er besteht die Regel jedoch nur, weil beide Bedingungen ungewöhnlich eng streuen, und hält der Erweiterung der kausalen Referenz auf acht Saaten nicht stand: Gegenüber deren Spannweite von $0{,}079$ ist die Differenz von dann $+0{,}033$ nicht mehr nachweisbar (Abschnitt 5.2). Auf UQ, wo das größere Backbone $0{,}186$ QWK verliert, ist beim kleineren unter QWK kein Unterschied nachweisbar. Unter Macro-F_1 verliert das kleinere Backbone auf Beetle-UQ dagegen $(-0{,}041)$, und dieser Verlust besteht die Auswertungsregel auch mit acht Saaten $(-0{,}038)$.

Der Kontrast zwischen beiden Benchmarks beim größeren Backbone ist erklärungsbedürftig, da sie dieselbe Aufgabenstruktur, dieselbe dreistufige Skala und dasselbe Backbone verwenden. Eine naheliegende Hypothese knüpft an die Datenstruktur an (Kapitel 3): Beetle umfasst $3\,941$ Trainingsinstanzen zu 47 Fragen aus einer einzigen eng umgrenzten Domäne, SciEntsBank $4\,969$ Instanzen zu 135 Fragen aus zwölf Themenblöcken. Die vollständige Aufhebung der Kausalität entfernt die Bedingung, unter der das Backbone vortrainiert wurde (Abschnitt 2.6.2); das Modell muss die Nutzung des beidseitigen Kontexts im Finetuning erst erlernen. Eine schmale und homogene Datengrundlage böte dafür zu wenig Material, eine breitere genügte. Die Läufe auf ASAP-SAS sprechen gegen diese Erklärung in ihrer einfachen Form: Mit $17\,043$ Trainingsinstanzen bietet ASAP-SAS die mit Abstand breiteste Datengrundlage, und doch ist dort auf keinem der beiden Backbones ein Unterschied nachweisbar. Der Umfang der Trainingsdaten allein bestimmt die Wirkung der Maske demnach nicht. Mit dem kleineren Backbone ist die Richtung des Beetle-Befunds dagegen vereinbar: Nachdem der Gewinn auf UA mit acht Saaten entfällt, zeigt Llama-3.2-1B auf Beetle keinen Vorteil, unter Macro-F_1 sogar einen Verlust auf UQ – dieselbe Richtung wie das größere Backbone, wenn auch deutlich schwächer. Welche Eigenschaft der Benchmarks den Ausschlag gibt, lässt sich mit drei Benchmarks nicht isolieren; eine Variation des Trainingsumfangs bei festgehaltener Maske könnte zumindest den

Beitrag der Datenmenge abgrenzen.

Festzuhalten bleibt in jedem Fall der methodische Kern: Die Wirkung der Attention-Maske ist weder über Benchmarks noch über Backbones hinweg generalisierbar. Eine Empfehlung, Decoder-Modelle für ASAG grundsätzlich bidirektional zu betreiben, lässt sich aus diesen Daten ebenso wenig ableiten wie das Gegenteil.

5.4.4 Effekt der Modellgröße

Tabelle 5.20: Effekt der Backbone-Größe bei CONDIFF und kausaler Attention (QWK). Mittelwerte über drei Zufallssaaten; für Mistral-7B auf ASAP-SAS ein Einzellauf.

Benchmark	Split	Llama-1B	Llama-3B	Mistral-7B
ASAP-SAS	UA	0,827	0,835	0,860
Beetle	UA	0,729	0,730	0,779
	UQ	0,509	0,544	0,605
SciEntsBank	UA	0,702	0,734	0,755
	UQ	0,544	0,576	0,639
	UD	0,560	0,617	0,641

Dem Augenschein nach ist der Größeneffekt der stabilste Befund dieser Arbeit (Tabelle 5.20). Von Llama-3.2-1B zu Mistral-7B beträgt der Gewinn auf Beetle $0{,}050$ QWK auf UA und $0{,}095$ auf UQ, auf SciEntsBank $0{,}053$ / $0{,}095$ / $0{,}082$ und auf ASAP-SAS $0{,}033$; fünf der sechs Zellen lägen damit oberhalb der Rauschgrenze, ASAP-SAS knapp darunter. Eine ergänzende Prüfung zeigt jedoch, dass dieser Eindruck nicht trägt.

Der Vergleich ist mit der Lernrate konfundiert

Sämtliche Decoder-Hauptläufe dieser Arbeit verwenden die Lernrate $5 \cdot 10^{-5}$ (Abschnitt 4.6). Die Referenzimplementierung sieht diesen Wert jedoch erst für Modelle ab sieben Milliarden Parametern vor; für die beiden Llama-Backbones nennt sie $2 \cdot 10^{-4}$. Das größte Backbone wurde also bei seiner vorgesehenen Rate trainiert, die beiden kleineren bei einem Viertel der ihren.

Zur Abschätzung der Folgen wurde CONDIFF auf beiden Llama-Größen zusätzlich bei $2 \cdot 10^{-4}$ trainiert und den drei vorhandenen Läufen bei $5 \cdot 10^{-5}$ gegenübergestellt (Tabelle 5.21).

Der Befund ist zweigeteilt und für die Auswertung dieser Achse entscheidend.

Auf Beetle war das kleinste Backbone erheblich untertrainiert. Bei der Referenzlernrate erreicht es $0{,}779$ QWK auf UA und $0{,}605$ auf UQ – in beiden Fällen oberhalb sämtlicher Läufe bei $5 \cdot 10^{-5}$. Der Zuwachs gegenüber dem Mittelwert beträgt $0{,}050$ beziehungsweise $0{,}096$ QWK. Damit verschwindet der in Tabelle 5.20 ausgewiesene Abstand zwischen Llama-3.2-1B und Mistral-7B auf Beetle vollständig: Er beträgt nun weniger als $0{,}001$ QWK auf UA und $-0{,}001$ auf UQ, das kleinste Backbone liegt also gleichauf mit dem Mittel über drei Mistral-Läufe. Die

Tabelle 5.21: CONDIFF bei der Referenzlernrate $2 \cdot 10^{-4}$ gegenüber den Läufen bei $5 \cdot 10^{-5}$ (Mittelwert und Bereich über drei Zufallssaaten), QWK. Die Läufe bei $2 \cdot 10^{-4}$ beruhen auf je einer Zufallssaat.

Backbone	Benchmark	Split	$2 \cdot 10^{-4}$	$5 \cdot 10^{-5}$	Lage zum Bereich
Llama-3.2-1B	Beetle	UA	**0,779**	0,729 (0,718–0,741)	darüber ($+0{,}038$)
		UQ	**0,605**	0,509 (0,472–0,545)	darüber ($+0{,}060$)
	SciEntsBank	UA	0,679	0,702 (0,698–0,705)	darunter ($-0{,}019$)
		UQ	0,537	0,544 (0,524–0,582)	innerhalb
		UD	0,496	0,560 (0,546–0,572)	darunter ($-0{,}050$)
Llama-3.2-3B	Beetle	UA	**0,775**	0,730 (0,707–0,748)	darüber ($+0{,}027$)
		UQ	0,564	0,544 (0,528–0,573)	innerhalb
	SciEntsBank	UA	0,749	0,734 (0,703–0,750)	innerhalb
		UQ	**0,609**	0,576 (0,571–0,580)	darüber ($+0{,}030$)
		UD	0,564	0,617 (0,605–0,633)	darunter ($-0{,}041$)

Erweiterung auf acht Saaten (Abschnitt 5.2) relativiert den Befund auf UA: Einer der fünf zusätzlichen Läufe bei $5 \cdot 10^{-5}$ erreicht dort $0{,}781$ und liegt damit knapp über dem Lauf bei $2 \cdot 10^{-4}$. Der Zuwachs auf UA ist folglich nicht gesichert. Auf UQ liegt der Lauf bei $2 \cdot 10^{-4}$ auch über allen acht Läufen, um $0{,}060$.

Auf SciEntsBank wirkt dieselbe Änderung entgegengesetzt. Dort liegt der Lauf bei $2 \cdot 10^{-4}$ auf zwei von drei Splits unterhalb des gesamten Bereichs bei $5 \cdot 10^{-5}$, auf UD um $0{,}050$ QWK.

Für Llama-3.2-3B fällt das Bild gemischt aus. Auf Beetle liegt der Lauf bei $2 \cdot 10^{-4}$ auf UA um $0{,}027$ QWK über dem Bereich bei $5 \cdot 10^{-5}$, auf UQ innerhalb. Auf SciEntsBank liegt er auf UQ darüber ($+0{,}030$), auf UD darunter ($-0{,}041$) und auf UA innerhalb. Ein so deutlicher Zuwachs wie beim kleinsten Backbone auf Beetle zeigt sich nicht. Es gibt folglich für keines der beiden Llama-Backbones eine über beide Benchmarks hinweg günstigere Lernrate; sie interagiert mit Datensatz und Backbone.

Konsequenz

Aus beidem folgt, dass Tabelle 5.20 keine Aussage über den Einfluss der Modellgröße erlaubt. Die drei Backbones unterscheiden sich in den vorliegenden Läufen nicht nur in ihrer Größe, sondern zugleich darin, wie weit ihre Lernrate von der für sie vorgesehenen abweicht – und das Ausmaß dieser Abweichung ist auf Beetle groß genug, um den gesamten beobachteten Unterschied zu erklären. Eine belastbare Untersuchung dieser Achse erforderte, jedes Backbone bei seiner jeweils geeigneten Lernrate zu trainieren; das war im Rahmen dieser Arbeit nicht zu leisten.

Die vorliegende Arbeit trifft daher *keine* Aussage über den Effekt der Backbone-Größe. Tabelle 5.20 wird als Dokumentation der durchgeführten Läufe beibehalten und ist ausdrücklich nicht als Größenvergleich zu lesen.

Eine Einschränkung betrifft auch diesen Befund selbst: Er beruht für beide Llama-Größen auf je einem Lauf bei $2 \cdot 10^{-4}$, dessen Abstand zum Bereich bei $5 \cdot 10^{-5}$ in mehreren Zellen in der Größenordnung der Rauschgrenze liegt.

Unberührt bleiben sämtliche Vergleiche *innerhalb* eines Backbones, in denen die Lernrate durchgängig identisch ist – und damit die Befunde zu Fusionsmechanismus, Bezugsgröße und Attention-Maske. Betroffen sind dagegen die wenigen Stellen, an denen dieses Kapitel Effektgrößen *zwischen* zwei Modellgrößen vergleicht: die Zunahme des Ablationseffekts von 1B auf 3B (Abschnitt 5.3.2), das Verschwinden des Span-Vorteils beim größeren Backbone (Abschnitt 5.3.1) sowie die Deutung der aufgabenweisen Unterschiede zwischen Llama-3.2-1B und Mistral-7B (Abschnitt 5.5.1). Alle drei sind dort entsprechend eingeschränkt. Der Befund fügt sich allerdings in ein Muster, das dieses Kapitel wiederholt zeigt: Mehrere zunächst deutlich erscheinende Effekte erweisen sich bei genauerer Prüfung als Eigenschaften der Konfiguration und nicht des untersuchten Gegenstands.

5.5 Ergänzende Analysen

Die folgenden Analysen beantworten keine eigene Forschungsfrage, sichern aber die Befunde zu RQ1 und RQ2 ab: die Auswertung je Aufgabe auf ASAP-SAS (Abschnitt 5.5.1), die Diagnose instabiler Läufe (Abschnitt 5.5.2) und die Prüfung, welche Befunde unter Macro-F_1 bestehen bleiben (Abschnitt 5.5.3).

5.5.1 Ergebnisse je Aufgabe auf ASAP-SAS

Da ASAP-SAS aus zehn inhaltlich und strukturell heterogenen Aufgaben besteht (Kapitel 3), verdeckt der über alle Instanzen aggregierte Wert erhebliche Unterschiede. Tabelle 5.22 schlüsselt das QWK nach Aufgabe auf und vergleicht das kleinste mit dem größten Backbone.

Tabelle 5.22: ASAP-SAS (UA): QWK je Aufgabe für CONDIFF mit kausaler Attention. Einzelläufe. Fett: höherer Wert je Zeile.

Item	Fach	Skala	Llama-1B	Mistral-7B	Differenz
1	Science	$\{0..3\}$	0,829	**0,881**	$+0{,}052$
2	Science	$\{0..3\}$	0,776	**0,898**	$+0{,}122$
5	Biology	$\{0..3\}$	0,832	**0,852**	$+0{,}020$
6	Biology	$\{0..3\}$	0,801	**0,892**	$+0{,}091$
3	English Language Arts	$\{0..2\}$	**0,663**	0,653	$-0{,}011$
4	English Language Arts	$\{0..2\}$	0,728	**0,734**	$+0{,}007$
7	English	$\{0..2\}$	0,702	**0,738**	$+0{,}035$
8	English	$\{0..2\}$	0,625	**0,697**	$+0{,}072$
9	English	$\{0..2\}$	**0,834**	0,832	$-0{,}002$
10	Science	$\{0..2\}$	0,731	**0,772**	$+0{,}041$
Mittel vierstufige Items			0,810	**0,881**	$+0{,}071$
Mittel dreistufige Items			0,714	**0,738**	$+0{,}024$

Die Streuung zwischen Aufgaben übertrifft alle untersuchten Architektureffekte. Beim 1B-Backbone reicht das QWK von $0{,}625$ (Item 8) bis $0{,}834$ (Item 9), beim 7B-Backbone von

$0{,}653$ bis $0{,}898$. Diese Spannweite von rund $0{,}21$ beziehungsweise $0{,}25$ liegt um ein Vielfaches über den Unterschieden zwischen Fusionsmechanismen, Bezugsgrößen oder Attention-Bedingungen auf demselben Benchmark, die höchstens $0{,}015$ QWK erreichen, und in derselben Größenordnung wie der Effekt des Rubriktexts. Sie übertrifft auch den größten Architektureffekt dieser Arbeit, den Verlust von $0{,}186$ QWK durch vollständige Bidirektionalität auf Beetle-UQ, wenn auch nur knapp. Welche Aufgaben ein Benchmark enthält, wirkt sich damit stärker aus als jede der hier untersuchten Architekturvarianten – ein Umstand, der bei der Verallgemeinerung aggregierter Benchmarkwerte zu berücksichtigen ist.

Abbildung 5.3 macht dieses Größenverhältnis sichtbar: Die Spannweite über die zehn Aufgaben ist dort der Rauschgrenze gegenübergestellt, an der sämtliche Architekturvergleiche dieses Kapitels zu messen sind.

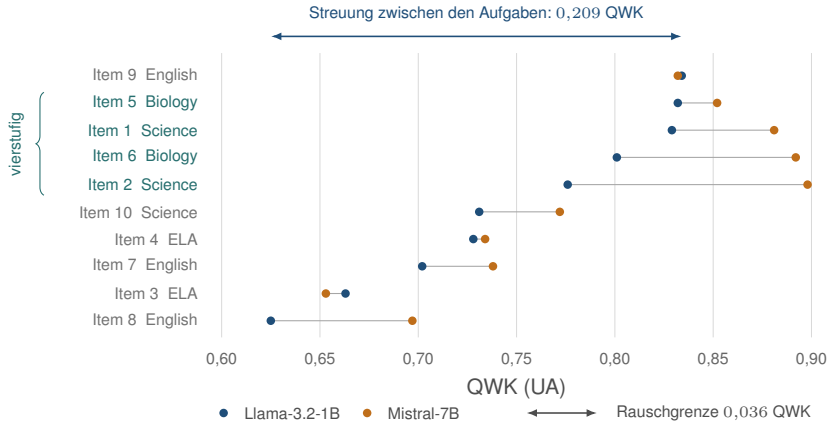


Abbildung 5.3: ASAP-SAS (UA): QWK je Aufgabe für CONDIFF mit kausaler Attention, Einzelläufe (Werte aus Tabelle 5.22).

Der Abstand zwischen beiden Backbones konzentriert sich auf die vierstufigen naturwissenschaftlichen Aufgaben. Auf den vier Items mit Skala $\{0, \ldots, 3\}$ – durchweg Science oder Biology – liegt Mistral-7B im Mittel $0{,}071$ QWK vorn, auf den sechs dreistufigen lediglich $0{,}024$. Auf den beiden Aufgaben aus dem Bereich English Language Arts ist der Abstand praktisch null: $-0{,}011$ auf Item 3 und $+0{,}007$ auf Item 4. Das Muster ließe sich mit der Beschreibung dieser Items in Kapitel 3 verbinden: Die vierstufigen naturwissenschaftlichen Aufgaben verlangen die Identifikation mehrerer inhaltlicher Teilaspekte, wofür Fachwissen erforderlich ist, über das ein größeres Sprachmodell aus dem Vortraining eher verfügt. Als Größeneffekt ist es jedoch nicht zu lesen. Beide Spalten beruhen auf Einzelläufen, und Llama-3.2-1B wurde, wie in Abschnitt 5.4.4 dargelegt, bei einem Viertel seiner Referenzlernrate trainiert, Mistral-7B bei der seinen. Ob die Konzentration auf die vierstufigen Aufgaben bei angepasster Lernrate bestehen bliebe, ist offen.

5.5.2 Instabile Läufe

Drei Läufe liegen deutlich unterhalb ihrer Vergleichsbedingungen (Tabelle 5.23). Die zugehörigen Vorhersagedateien wurden gesondert ausgewertet, um zwischen einem inhaltlichen Effekt

und einer Trainingsinstabilität zu unterscheiden; die beiden Mistral-Läufe wurden zudem wiederholt. Als Referenzpunkte dienen die Accuracy eines trivialen Modells, das stets die häufigste Stufe vorhersagt, sowie das QWK bei zufälliger Permutation der Vorhersagen – also bei unveränderter Randverteilung, aber aufgehobener Zuordnung.

Tabelle 5.23: Diagnose der auffälligen Läufe. $Acc_{Mehrheit}$ ist die Accuracy bei konstanter Vorhersage der häufigsten Stufe, QWK_{perm} das QWK bei einer einzelnen zufälligen Permutation der Vorhersagen. *Wdh.*: Wiederholung mit derselben Zufallssaat in der Softwareumgebung mit transformers 4.57.6.

Lauf	Split	QWK	Acc	$Acc_{Mehrheit}$	QWK_{perm}
Beetle, Mistral, $\rho = 0{,}2$	UA	0,587	0,674	0,401	$-0{,}018$
Beetle, Mistral, $\rho = 0{,}2$, Wdh.	UA	0,778	0,770	0,401	$0{,}044$
Beetle, Mistral, kausal	UA	0,803	0,788	0,401	$0{,}000$
Beetle, Mistral, $\rho = 0{,}2$	UQ	0,210	0,480	0,420	$-0{,}001$
Beetle, Mistral, $\rho = 0{,}2$, Wdh.	UQ	0,593	0,652	0,420	$-0{,}055$
Beetle, Mistral, kausal	UQ	0,606	0,661	0,420	$-0{,}015$
SciEntsBank, Mistral, $\rho = 0{,}6$	UQ	0,378	0,578	0,411	$-0{,}004$
SciEntsBank, Mistral, $\rho = 0{,}6$, Wdh.	UQ	0,657	0,700	0,411	$0{,}030$
SciEntsBank, Mistral, $\rho = 0{,}2$	UQ	0,627	0,690	0,411	$-0{,}005$
SciEntsBank, BERT	UA	0,052	**0,431**	**0,431**	$-0{,}012$
SciEntsBank, RoBERTa	UA	0,633	0,680	0,431	$0{,}005$

Die beiden ursprünglichen Mistral-Läufe sind funktionsfähig, aber schwach. Beide sagen sämtliche Stufen in annähernd korrekter Randverteilung vorher – beim SciEntsBank-Lauf mit $\rho = 0{,}6$ stimmt die Vorhersageverteilung auf dem UD-Split mit $(1733, 1001, 1828)$ nahezu exakt mit der Referenzverteilung $(1659, 986, 1917)$ überein. Ihre Accuracy liegt mit $0{,}674$ beziehungsweise $0{,}578$ deutlich über der Mehrheitsschranke, und ihre Konfusionsmatrizen zeigen eine sinnvolle Diagonalstruktur. Es handelt sich also nicht um abgebrochene Trainingsläufe oder um Modelle, die lediglich die Klassenverteilung reproduzieren, sondern um Modelle, die die Aufgabe gelernt haben – nur erheblich schlechter. Eine Auswertung je Frage zeigt ferner, dass die Verschlechterung breit verteilt ist: Auf Beetle fällt der Lauf mit $\rho = 0{,}2$ bei 28 der 47 Fragen um mehr als $0{,}1$ QWK gegenüber der kausalen Referenz ab und verbessert sich nur bei vier Fragen. Ein einzelnes problematisches Item oder ein Datenartefakt scheidet damit als Erklärung aus.

Die Abstände von bis zu $0{,}22$ QWK auf UA und $0{,}40$ auf UQ liegen weit über der in Abschnitt 5.2 bestimmten Rauschgrenze und auch über der größten dort beobachteten Spannweite ($0{,}118$). Zugleich spricht gegen eine inhaltliche Deutung als Maskeneffekt, dass $\rho = 0{,}6$ mit 19 bidirektionalen Schichten auf demselben Benchmark $0{,}801$ erreicht – mehr als das Dreifache an bidirektionalen Schichten bei nahezu unveränderter Leistung.

Die Wiederholung schließt einen Maskeneffekt aus. Beide Konfigurationen wurden mit derselben Zufallssaat erneut trainiert. Der Beetle-Lauf mit $\rho = 0{,}2$ erreicht nun $0{,}778$ statt $0{,}587$ QWK auf UA und $0{,}593$ statt $0{,}210$ auf UQ, der SciEntsBank-Lauf mit $\rho = 0{,}6$ auf UQ $0{,}657$ statt $0{,}378$; auf UA und UD liegt er mit $0{,}751$ und $0{,}651$ ebenfalls im Bereich der übrigen Mistral-

Läufe. Beide Wiederholungen liegen damit nahe an der kausalen Referenz derselben Saat ($0{,}803$ / $0{,}606$ auf Beetle, $0{,}621$ auf SciEntsBank-UQ), höchstens $0{,}025$ darunter auf Beetle und $0{,}036$ darüber auf SciEntsBank-UQ. Da das Training innerhalb einer Umgebung deterministisch ist (Abschnitt 5.2), lief die Wiederholung zwangsläufig in einer anderen Softwareumgebung als der ursprüngliche Lauf; ob die Abweichung auf die Umgebung oder auf eine im ursprünglichen Lauf zufällig aufgetretene Instabilität zurückgeht, lässt sich daher nicht trennen. Ein Effekt der Maske ist sie jedenfalls nicht. Die beiden ursprünglichen Läufe bleiben von der Deutung ausgenommen.

Der BERT-Lauf auf SciEntsBank ist dagegen ein echter Ausfall. Seine Accuracy beträgt $0{,}431$ und stimmt damit auf drei Nachkommastellen exakt mit der Mehrheitsschranke überein. Die Konfusionsmatrix zeigt, dass 148 von 194 Instanzen der Stufe 0 und 76 von 113 der Stufe 1 der Stufe 2 zugeordnet werden; insgesamt entfallen $77\,\%$ aller Vorhersagen auf die häufigste Stufe, gegenüber $43\,\%$ in der Referenz. Das Modell hat also nichts über die Klassenverteilung hinaus gelernt. Die in Abschnitt 5.3.3 berichtete Lernratenvariation zeigt zudem, dass sich dieser Ausfall durch keine der drei zusätzlich geprüften Lernraten beheben lässt. Der Lauf ist damit als Fehlschlag einzuordnen, dessen Ursache offen bleibt; inhaltlich zu deuten ist er in keinem Fall.

5.5.3 Robustheit gegenüber der Metrik

Sämtliche Urteile zu RQ1 und RQ2 beruhen auf QWK. Da Abschnitt 2.2 Macro-F_1 als zweite Metrik einführt, wurde jeder dort berichtete Paarvergleich mit drei Zufallssaaten unter Macro-F_1 wiederholt, und zwar nach derselben Auswertungsregel, angewandt auf Mittelwerte und Spannweiten des Macro-F_1. Einbezogen sind 114 Vergleiche, wobei jeder Split eines Paarvergleichs einzeln zählt: die Ablations- und Kontextvergleiche aus Abschnitt 5.3.2, Span-Alignment gegenüber festem Kopf auf beiden Llama-Größen, die Transferläufe gegenüber den In-Domain-Läufen, sämtliche Paare von Fusionsvarianten je Backbone einschließlich Mistral-7B, t-concat gegenüber CONCAT sowie die vollständig bidirektionale gegenüber der kausalen Bedingung auf allen drei Benchmarks.

In 94 der 114 Vergleiche fällt das Urteil unter beiden Metriken gleich aus. Tabelle 5.24 listet die 20 abweichenden.

Aufgabeninformation

Der Kernbefund ist metrikunabhängig. Der Einbruch ohne jede Aufgabeninformation besteht unter Macro-F_1 auf beiden Llama-Größen und allen drei SciEntsBank-Splits ebenso als Effekt wie unter QWK. Dasselbe gilt auf UA für den Vorsprung von Kontext allein gegenüber Rubrik allein und für den Zugewinn durch Kontext bei vorhandener Rubrik; Letzterer besteht auch auf UD.

Metrikabhängig ist dagegen das Verhältnis beider Informationsquellen auf den Transfersplits. Unter QWK übertrifft Kontext allein die Rubrik allein auch auf UQ und UD als Effekt. Unter Macro-F_1 liegen beide auf UQ gleichauf ($-0{,}003$), auf UD bleibt ein schwacher Hinweis ($+0{,}014$). Umgekehrt trägt der Rubriktext bei vorhandenem Kontext unter Macro-F_1 etwas bei:

Tabelle 5.24: Paarvergleiche mit drei Zufallssaaten, deren Urteil unter QWK und Macro-F_1 verschieden ausfällt. Δ ist die Differenz der Mittelwerte (erste minus zweite Bedingung); das Urteil folgt der Auswertungsregel aus Abschnitt 5.2, angewandt auf die jeweilige Metrik. „—“ bedeutet nicht nachweisbar. Kontext bezeichnet Frage und Musterlösung.

Abschn.	Vergleich	Split	Δ QWK	Urteil	Δ F_1	Urteil
5.3.1	Beetle 1B: Span-Alignment gegen festen Kopf	UQ	$+0{,}054$	—	$+0{,}044$	Effekt
5.3.2	SciEntsBank 1B: Kontext mit gegen ohne Rubrik	UQ	$+0{,}015$	—	$+0{,}019$	Hinweis
5.3.2	SciEntsBank 1B: Kontext mit gegen ohne Rubrik	UD	$+0{,}006$	—	$+0{,}029$	Effekt
5.3.2	SciEntsBank 1B: nur Kontext gegen nur Rubrik	UQ	$+0{,}060$	Effekt	$-0{,}003$	—
5.3.2	SciEntsBank 1B: nur Kontext gegen nur Rubrik	UD	$+0{,}077$	Effekt	$+0{,}014$	Hinweis
5.3.2	SciEntsBank 1B: Kontext und Rubrik gegen nur Rubrik	UQ	$+0{,}075$	Effekt	$+0{,}017$	—
5.3.2	Beetle 1B: Rubrik gegen weder noch	UA	$+0{,}054$	Hinweis	$+0{,}040$	Effekt
5.4.1	Beetle 1B: CONDIFF gegen CONCAT	UA	$+0{,}005$	—	$+0{,}006$	Hinweis
5.4.1	Beetle 1B: CONDIFF gegen GATE	UQ	$+0{,}038$	—	$+0{,}041$	Hinweis
5.4.1	Beetle 1B: CONCAT gegen GATE	UQ	$+0{,}032$	—	$+0{,}036$	Hinweis
5.4.1	SciEntsBank 1B: CONDIFF gegen CONCAT	UD	$-0{,}017$	—	$-0{,}011$	Hinweis
5.4.1	SciEntsBank 1B: CONCAT gegen GATE	UD	$+0{,}017$	—	$+0{,}019$	Hinweis
5.4.1	Beetle 3B: DIFF gegen GATE	UA	$-0{,}017$	Hinweis	$-0{,}009$	Effekt
5.4.1	SciEntsBank 3B: CONDIFF gegen GATE	UQ	$-0{,}049$	Hinweis	$-0{,}019$	—
5.4.1	SciEntsBank 3B: DIFF gegen GATE	UA	$-0{,}014$	—	$-0{,}012$	Hinweis
5.4.1	Beetle 7B: CONDIFF gegen GATE	UQ	$+0{,}038$	Hinweis	$+0{,}013$	—
5.4.2	Beetle 3B: t-concat gegen CONCAT	UA	$+0{,}026$	Hinweis	$+0{,}014$	Effekt
5.4.3	Beetle 1B: bidirektional gegen kausal	UQ	$-0{,}016$	—	$-0{,}041$	Effekt
5.4.3	Beetle 3B: bidirektional gegen kausal	UA	$-0{,}073$	Effekt	$-0{,}028$	—
5.4.3	SciEntsBank 3B: bidirektional gegen kausal	UA	$+0{,}032$	Hinweis	$+0{,}011$	—

auf UD als Effekt ($+0{,}029$), auf UQ als Hinweis ($+0{,}019$), während QWK in beiden Fällen keinen Unterschied nachweist.

Die Abweichung lässt sich an der Art der Fehler festmachen. Bei drei Stufen gewichtet QWK die Verwechslung von *incorrect* und *correct* viermal so stark wie die Verwechslung benachbarter Stufen; Macro-F_1 unterscheidet beide Fehlerarten nicht. Tabelle 5.25 zeigt, dass der Aufgabenkontext genau die weiten Fehler reduziert.

Ohne Kontext liegen Vorhersage und Referenz auf beiden Transfersplits bei gut $11\,\%$ der Instanzen zwei Stufen auseinander, mit Kontext bei rund $7\,\%$; die Bereiche über die Saaten überlappen in keinem Fall. Die Accuracy unterscheidet sich dagegen wenig, auf UQ liegt die Rubrik

Tabelle 5.25: SciEntsBank, Llama-3.2-1B, fester Klassifikationskopf: Anteil weiter Fehler (Vorhersage und Referenz liegen zwei Stufen auseinander) und Accuracy. Mittelwerte über drei Zufallssaaten, beim Anteil weiter Fehler mit Bereich über die Saaten.

	UQ		UD	
Bedingung	weite Fehler	Acc	weite Fehler	Acc
nur Kontext	0,068 (0,064–0,074)	0,652	0,074 (0,062–0,082)	0,641
nur Rubrik	0,117 (0,109–0,128)	0,666	0,114 (0,108–0,122)	0,627
Kontext und Rubrik	0,072 (0,065–0,079)	0,675	0,078 (0,072–0,084)	0,665

allein nominell sogar vorn. Der Kontext macht das Modell also nicht wesentlich häufiger richtig, sondern seltener grob falsch – ein Unterschied, den QWK belohnt und Macro-F_1 nicht erfasst. Umgekehrt erhöht der Rubriktext bei vorhandenem Kontext auf UD die Accuracy, ohne den Anteil weiter Fehler zu verändern; das erklärt, weshalb dort Macro-F_1 einen Beitrag anzeigt und QWK nicht. Die Aussage, Frage und Musterlösung seien dem Rubriktext überlegen, betrifft auf den Transfersplits somit die Schwere der Fehler, nicht ihre Häufigkeit.

Architektur

Fusion und Bezugsgröße. Unter den Fusionsvergleichen verschiebt sich das Urteil in neun Fällen, davon acht zwischen „nicht nachweisbar“ und „Hinweis“. Die einzige Verschiebung zum Effekt betrifft GATE gegenüber DIFF auf Beetle-UA mit Llama-3.2-3B, bei einer Differenz von lediglich $0{,}009$ Macro-F_1 und entsprechend enger Streuung. Das in Abschnitt 5.4.1 beschriebene Muster bleibt unter Macro-F_1 in der Tendenz erhalten: Beim kleineren Backbone liegt GATE auf Beetle-UQ mit disjunkten Spannweiten hinter CONDIFF und CONCAT, beim größeren vor DIFF; der Hinweis auf einen Vorsprung von GATE vor CONDIFF auf SciEntsBank-UQ entfällt dagegen, ebenso der Hinweis auf einen Vorsprung von CONDIFF vor GATE auf Beetle-UQ mit Mistral-7B. Sämtliche übrigen Fusionsvergleiche mit Mistral-7B sind unter beiden Metriken nicht nachweisbar. Der Hinweis auf einen Vorteil von t-concat auf Beetle-UA wird unter Macro-F_1 zum Effekt, mit einer Differenz von $0{,}014$.

Span-Alignment und fester Kopf. Die Vergleiche fallen unter beiden Metriken gleich aus, mit einer Ausnahme: Auf Beetle-UQ besteht der Vorsprung des Span-Alignments beim kleineren Backbone unter Macro-F_1 als Effekt ($+0{,}044$), während er unter QWK wegen überlappender Spannweiten nicht nachweisbar ist. Der Vorsprung auf Beetle-UA besteht unter beiden Metriken ($+0{,}088$ QWK, $+0{,}058$ Macro-F_1). Beim größeren Backbone ist auf Beetle unter keiner der beiden Metriken ein Unterschied nachweisbar.

Transfer. Der Einbruch bei der Übertragung von ASAP-SAS auf Beetle und SciEntsBank besteht unter beiden Metriken in allen zehn Zellen als Effekt.

Attention-Maske. Der Verlust des größeren Backbones auf Beetle-UQ und sein Gewinn auf SciEntsBank-UQ bestehen unter beiden Metriken als Effekt. Der Gewinn des kleineren Backbones auf Beetle-UA besteht mit drei Saaten unter beiden Metriken, mit acht Saaten unter keiner (Abschnitt 5.2). Nicht metrikrobust sind der Verlust des größeren Backbones auf Beetle-UA und der Hinweis auf SciEntsBank-UA. Hinzu kommt unter Macro-F_1 ein Verlust des kleineren

Backbones auf Beetle-UQ ($-0{,}041$), der auch mit acht Saaten besteht. Auf Beetle-UQ schadet die vollständige Aufhebung der Kausalität unter dieser Metrik somit beiden Backbones. Auf ASAP-SAS ist unter beiden Metriken kein Unterschied nachweisbar.

Folgerung

Robust gegenüber der Wahl der Metrik sind der Vorsprung des Span-Alignments vor dem festen Kopf auf Beetle-UA beim kleineren Backbone, der Einbruch ohne Aufgabeninformation, der Vorsprung des Kontexts auf UA, das Scheitern der Übertragung zwischen Benchmarks, das Fehlen von Fusionsunterschieden oberhalb der Rauschgrenze auf allen drei Backbones sowie die Maskeneffekte auf den UQ-Splits des größeren Backbones. Metrikabhängig sind die Überlegenheit des Kontexts auf den Transfersplits und der fehlende Beitrag des Rubriktexts bei vorhandenem Kontext; beide Aussagen gelten nur unter QWK, das grobe Fehlbewertungen stärker gewichtet.

5.6 Zusammenfassung der Befunde

Die Ergebnisse dieses Kapitels lassen sich entlang einer übergreifenden Unterscheidung ordnen: Entscheidend ist vor allem, *welche Information* dem Modell zur Verfügung steht, weniger, *wie* sie architektonisch verarbeitet wird.

RQ1: Span-Alignment gegenüber den Vergleichsbedingungen

1. **Gegenüber dem festen Klassifikationskopf zeigt das Span-Alignment einen Vorteil allein beim kleineren Backbone** (Abschnitt 5.3.1). Auf Beetle liegt es mit Llama-3.2-1B auf UA um $0{,}088$ QWK vorn, unter beiden Metriken und auch mit acht Saaten als Effekt. Auf SciEntsBank sind die Vorteile beim kleineren Backbone klein; mit Llama-3.2-3B ist auf keinem der beiden Benchmarks ein Unterschied nachweisbar.
2. **Aufgabenbezogene Information ist der bestimmende Faktor – nicht ihre Form** (Abschnitt 5.3.2). Wird dem Modell jede Aufgabeninformation entzogen, kostet das zwischen $0{,}235$ und $0{,}528$ QWK, und auf den Transfersplits fällt die Leistung auf oder unter das Zufallsniveau; zusätzliche Modellkapazität kompensiert das nicht. Der Rubriktext ist dabei jedoch *austauschbar*: Liegen Frage und Musterlösung vor, trägt er unter QWK nichts mehr bei ($-0{,}012$ bis $+0{,}015$ QWK, sämtlich im Rauschen), und als alleinige Informationsquelle ist er ihnen um $0{,}060$ bis $0{,}100$ QWK unterlegen. Unter Macro-F_1 gilt beides nur eingeschränkt: Die Unterlegenheit zeigt sich dort nur auf UA, und bei vorhandenem Kontext trägt der Rubriktext auf UD nachweisbar bei (Abschnitt 5.5.3).
3. **Gegenüber den Encoder-Modellen entscheidet die Wahl des Evaluationssplits** (Abschnitt 5.3.3). Auf UA sind Encoder-Modelle konkurrenzfähig; auf Beetle-UQ liegt Llama-3.2-1B um $0{,}221$ QWK vor RoBERTa – und ein deutlicher Rückstand des Encoders besteht bei jeder geprüften Lernrate.

4. **Die strukturelle Übertragbarkeit führt zu keiner Übertragung der Bewertung** (Abschnitt 5.3.4). Ausschließlich auf ASAP-SAS trainiert, fallen beide Llama-Größen auf Beetle und SciEntsBank auf Zufallsniveau ($-0{,}017$ bis $0{,}022$ QWK) und ordnen nahezu jede Antwort der untersten Stufe zu; ein Einzellauf mit Mistral-7B kollabiert ebenso. Mit den Daten vereinbar ist die Hypothese, dass die Modelle auf ASAP-SAS kurze Antworten mit niedrigen Stufen zu verbinden gelernt haben.

RQ2: Anpassung von Decoder-only-Modellen

5. **Die Ausgestaltung des Alignments ist ohne nachweisbare Wirkung** (Abschnitte 5.4.1 und 5.4.2). Weder die Wahl zwischen CONDIFF, CONCAT, DIFF und GATE noch die Bezugsgröße der Fusion erzeugen auf einem der drei Backbones Unterschiede oberhalb der Rauschgrenze. Der schwache Hinweis zugunsten von GATE auf Llama-3.2-3B, wo die Variante in vier von fünf Zellen vorn liegt, bestätigt sich auf Mistral-7B nicht.
6. **Die Attention-Maske wirkt, aber mit vom Benchmark abhängigem Vorzeichen** (Abschnitt 5.4.3). Die vollständige Aufhebung der Kausalität kostet Llama-3.2-3B auf Beetle $0{,}186$ QWK auf UQ und bringt ihm auf SciEntsBank $0{,}060$; auf ASAP-SAS ist bei beiden Llama-Größen kein Unterschied nachweisbar. Beim kleineren Backbone übersteht unter QWK kein Effekt die Erweiterung der Referenz auf acht Saaten; unter Macro-F_1 verliert es auf Beetle-UQ.
7. **Über die Backbone-Größe lässt sich keine Aussage treffen** (Abschnitt 5.4.4). Der scheinbar deutliche Größeneffekt ist mit der Lernrate konfundiert: Llama-3.2-1B erreicht bei seiner Referenzlernrate auf Beetle $0{,}779$ und $0{,}605$ QWK und liegt damit gleichauf mit dem Mittel über drei Mistral-7B-Läufe.

Übergreifend

8. **Die Streuung zwischen Aufgaben übertrifft alle Architektureffekte** (Abschnitt 5.5.1) und erreicht auf ASAP-SAS eine Spannweite von $0{,}21$ bis $0{,}25$ QWK zwischen den zehn Items desselben Benchmarks.
9. **Drei Saaten können die Streuung deutlich unterschätzen** (Abschnitt 5.2). Erweitert auf acht Saaten, wächst die Spannweite einer Gruppe von $0{,}023$ auf $0{,}079$ QWK; der Median der Dreiergruppen bestätigt dagegen die Rauschgrenze von $0{,}036$ als typischen Wert.

Die methodisch weitreichendste Konsequenz betrifft das Verhältnis von Befund und Messgenauigkeit. Mehrere Muster, die sich auf Einzelläufen klar abzeichneten – eine Umkehr der Fusionsrangfolge zwischen den Splits, ein Vorteil des Antwort-Span-Alignments, ein Verlust durch vollständige Bidirektionalität beim kleineren Backbone auf SciEntsBank –, halten der Wiederholung unter drei Zufallssaaten nicht stand. Ein Gewinn durch vollständige Bidirektionalität beim kleineren Backbone auf Beetle bestand die Auswertungsregel mit drei Saaten und entfiel erst mit acht. Ohne die in Abschnitt 5.2 durchgeführte Bestimmung der Rauschgrenze und ihre Prüfung wären diese Muster als Ergebnisse berichtet worden.

6 Diskussion

Dieses Kapitel beantwortet die in Abschnitt 1.3 formulierten Forschungsfragen auf Grundlage der Ergebnisse aus Kapitel 5, ordnet sie in die Literatur ein und benennt die Grenzen der Untersuchung. Maßstab sämtlicher Antworten ist die in Abschnitt 5.2 bestimmte Auswertungsregel: Als Effekt gilt nur ein Unterschied, der die Streuung über drei Zufallssaaten übersteigt.

6.1 Beantwortung der Forschungsfragen

RQ1: Übertrifft der span-basierte Klassifikator die Vergleichsbedingungen?

Gegenüber dem festen Klassifikationskopf zeigt das Span-Alignment einen Vorteil allein beim kleineren Backbone (Abschnitt 5.3.1). Auf Beetle liegt es mit Llama-3.2-1B auf UA um $0{,}088$ QWK vorn. Der Vorsprung übersteigt die Spannweiten beider Bedingungen deutlich, liegt mehr als doppelt so hoch wie der globale Median der Saat-Spannweite, besteht auch unter Macro-F_1 und bleibt erhalten, wenn die Span-Bedingung auf acht Saaten erweitert wird; unter Macro-F_1 ist zusätzlich der Vorsprung auf UQ als Effekt nachweisbar. Auf SciEntsBank fallen die Vorteile beim kleineren Backbone mit $0{,}021$ und $0{,}026$ QWK klein aus. Mit Llama-3.2-3B ist auf keinem der beiden Benchmarks ein Unterschied nachweisbar; auf SciEntsBank sind die Differenzen nominell negativ, auf Beetle mit $+0{,}008$ und $+0{,}027$ QWK klein.

Da beide Bedingungen die Rubriktexte in der Eingabe enthalten, misst dieser Vergleich nicht den Wert der Rubrikinformation, sondern allein den Wert ihrer expliziten Extraktion als Span. Weshalb dieser Wert beim kleineren Backbone auf Beetle deutlich größer ausfällt als auf SciEntsBank, lässt sich mit den vorliegenden Läufen nicht klären. Dass er beim größeren Backbone auf beiden Benchmarks entfällt, ist mit der Lesart vereinbar, ein größeres Modell verdichte die Rubrikinformation bereits in der Sequenzrepräsentation; wegen der nicht angepassten Lernrate ist sie jedoch nicht gesichert.

Bei der Übertragung zwischen Benchmarks scheitert das Span-Alignment (Abschnitt 5.3.4). Ausschließlich auf ASAP-SAS trainiert, lässt es sich zwar ohne jede Anpassung auf Beetle und SciEntsBank anwenden, erreicht dort aber nur Zufallsniveau und ordnet nahezu alle Antworten der untersten Stufe zu, auf beiden Llama-Größen ebenso wie in einem Einzellauf mit Mistral-7B. Mit den Daten vereinbar ist die Erklärung, dass die Modelle auf ASAP-SAS die Länge einer Antwort als Hinweis auf ihre Stufe gelernt haben und die durchweg kurzen Antworten

der Zielbenchmarks deshalb niedrig bewerten. Die Rubriktexte des Zielbenchmarks korrigieren diese Heuristik nicht.

Gegenüber Bedingungen ohne Rubriktext oder Aufgabeninformation ergibt sich ein zweigeteiltes Bild (Abschnitt 5.3.2). Aufgabenbezogene Information ist unverzichtbar: Wird sie dem Modell vollständig entzogen, verliert es auf SciEntsBank zwischen $0{,}235$ und $0{,}528$ QWK, und auf den Transfersplits fällt die Leistung auf oder unter das Zufallsniveau. Der Rubriktext als solcher ist dagegen austauschbar. Liegen Frage und Musterlösung vor, trägt er unter QWK nichts mehr bei; die Differenzen von $-0{,}012$ bis $+0{,}015$ QWK liegen sämtlich im Rauschen. Als alleinige Informationsquelle ist er Frage und Musterlösung um $0{,}060$ bis $0{,}100$ QWK unterlegen. Auf Beetle zeigt sich dasselbe Vorzeichen, dort allerdings auf Einzelläufen.

Die naheliegende Erklärung liegt in der Herkunft der Rubriktexte. Für Beetle und SciEntsBank wurden sie sprachmodellgestützt aus Frage und Musterlösung erzeugt und nehmen deren Inhalt erkennbar auf (Abschnitt 3.4). Sie sind damit keine unabhängige Informationsquelle, sondern eine Umformulierung derselben Information. Das Modell nutzt die Rubriktexte folglich als Träger aufgabenbezogener Information und nicht als Beschreibung von Bewertungskriterien, die über die Aufgabenstellung hinausginge. Einschränkend ist zu beachten, dass dieser Befund metrikabhängig ist. Unter Macro-F_1 trägt der Rubriktext bei vorhandenem Kontext auf SciEntsBank-UD nachweisbar bei, und die Überlegenheit von Frage und Musterlösung beschränkt sich auf UA (Abschnitt 5.5.3). Der Vorsprung des Kontexts auf den Transfersplits besteht demnach vor allem darin, dass grobe Fehlbewertungen seltener werden.

Gegenüber den Encoder-Modellen entscheidet der Evaluationssplit (Abschnitt 5.3.3). Auf UA-Splits ist RoBERTa konkurrenzfähig, auf Beetle-UQ liegt Llama-3.2-1B dagegen um $0{,}221$ QWK vorn, und ein deutlicher Rückstand des Encoders besteht bei jeder geprüften Lernrate. Da Encoder und Decoder sich zugleich in Architektur, Parameterzahl, Kontextlänge und Trainingskonfiguration unterscheiden, ist dieser Vorsprung nicht allein dem Span-Alignment zuzuschreiben.

Die Antwort auf RQ1 fällt damit differenziert aus. Der span-basierte Klassifikator übertrifft den festen Kopf unter bestimmten Bedingungen deutlich, auf Beetle mit dem kleineren Backbone, ohne dass dieser Vorteil über Benchmarks und Backbones hinweg verlässlich wäre. Seine Stärke liegt zudem in einer Eigenschaft, die sich in einem Genauigkeitsvergleich auf festen Labelräumen nicht zeigen kann: Er verarbeitet eine zur Laufzeit variable Zahl von Bewertungsstufen (Abschnitt 4.1) und ermöglicht so auf ASAP-SAS mit wechselnder Skalenlänge erst die gemeinsame Modellierung aller Aufgaben. Das Transferexperiment zeigt allerdings die Grenze dieser Eigenschaft: Sie macht die Übertragung auf neue Rubriken technisch möglich, sorgt aber nicht dafür, dass die neuen Rubriken auch inhaltlich genutzt werden. Die Prämisse, dass die Rubriktexte als Kriterienbeschreibung eine eigenständige Informationsquelle bilden, bestätigt sich für die hier verwendeten, aus der Aufgabenstellung abgeleiteten Rubriken dagegen nicht.

RQ2: Lassen sich Decoder-only-Modelle an den span-basierten Klassifikator anpassen?

Grundsätzlich ja: Mit Llama-3.2-1B, Llama-3.2-3B und Mistral-7B gelingt das Span-Alignment auf allen drei Benchmarks, und auf den Transfersplits liegen die Decoder-Modelle deutlich vor den Encoder-Modellen. Für die einzelnen Entwurfsentscheidungen ergibt sich folgendes Bild.

Die Ausgestaltung des Alignments ist ohne nachweisbare Wirkung. In allen fünfzehn untersuchten Konfigurationen aus Benchmark, Backbone und Split übersteigt die Streuung über die Zufallssaaten den Abstand zwischen den Fusionsvarianten, bei Mistral-7B um bis zu das Sechsfache (Abschnitt 5.4.1). Weder der parameterfreie Differenzterm von CONDIFF noch die zusätzlichen Parameter der Gate-Projektion bringen gegenüber der einfachen Konkatenation einen Vorteil oberhalb der Rauschgrenze. Der schwache Hinweis zugunsten von GATE auf Llama-3.2-3B, wo die Variante in vier von fünf Zellen nominell vorn liegt, bestätigt sich auf Mistral-7B nicht; dort wechselt die Rangfolge wie beim kleinsten Backbone ohne erkennbares Muster. Dasselbe gilt für die Bezugsgröße der Fusion, also für die Wahl zwischen einem Alignment der Rubrik-Spans mit der Sequenzrepräsentation oder mit dem Antwort-Span. Sie macht in vier von fünf Zellen einen Unterschied von höchstens $0{,}013$ QWK bei überlappenden Spannweiten; auf Beetle-UA bleibt ein schwacher Hinweis zugunsten des Antwort-Spans (Abschnitt 5.4.2). Bemerkenswert ist dies, weil beide Repräsentationen unter kausaler Attention unterschiedliche Information tragen: Der Antwort-Span hat die Rubriken nicht gesehen, die Sequenzrepräsentation hat sie alle gesehen. Dass dieser Unterschied folgenlos bleibt, spricht dafür, dass die für die Bewertung ausschlaggebende Information bereits in der Repräsentation der Antwort enthalten ist. Für die Praxis folgt daraus eine Empfehlung zugunsten der einfachsten Konstruktion, also CONCAT oder DIFF.

Die Attention-Maske ist wirksam, aber nicht verlässlich. Sie ist die einzige Variation innerhalb der Span-Alignment-Architektur, deren Wirkung die Rauschgrenze deutlich überschreitet, ihr Vorzeichen hängt jedoch von Benchmark und Backbone ab (Abschnitt 5.4.3). Die vollständige Aufhebung der Kausalität kostet Llama-3.2-3B auf Beetle $0{,}073$ QWK auf UA und $0{,}186$ auf UQ und erhöht zugleich die Streuung zwischen den Läufen. Auf SciEntsBank gewinnt dasselbe Backbone $0{,}060$ QWK auf UQ, auf ASAP-SAS bleibt die Maske bei beiden Llama-Größen ohne Wirkung. Beim kleineren Backbone ist unter QWK kein Effekt gesichert: Ein Gewinn auf Beetle-UA, der mit drei Saaten die Auswertungsregel knapp bestand, entfiel mit acht Saaten; unter Macro-F_1 verliert Llama-3.2-1B auf Beetle-UQ, in derselben Richtung wie das größere Backbone. Die anteilige Aufhebung zeigt über die Einzelläufe hinweg keinen monotonen Zusammenhang zwischen der Zahl bidirektionaler Schichten und der Leistung. Eine Empfehlung, Decoder-only-Modelle für ASAG grundsätzlich bidirektional zu betreiben, lässt sich aus den Daten ebenso wenig ableiten wie das Gegenteil; die Maske ist vielmehr als datensatz- und modellabhängiger Hyperparameter zu behandeln.

Über die Backbone-Größe ist keine Aussage möglich. Der scheinbar deutliche Vorsprung von Mistral-7B ist mit der Lernrate konfundiert: Bei seiner Referenzlernrate liegt Llama-3.2-1B auf Beetle gleichauf mit dem Mittel über drei Mistral-Läufe (Abschnitt 5.4.4).

Die Antwort auf RQ2 lautet damit: Decoder-only-Modelle lassen sich ohne Änderung ihrer Gewichtsarchitektur an den span-basierten Klassifikator anpassen, und die Ausgestaltung des Alignments ist dabei unkritisch. Der einzige wirksame Eingriff, die Aufhebung der kausalen Maske, verbessert die Anpassung jedoch nicht zuverlässig, sondern muss je Anwendung validiert werden.

6.2 Einordnung in die Forschung

Rubrik-geleitetes Scoring

Arbeiten zur Nutzung von Label-Semantik zeigen ihre Wirksamkeit vor allem in Zero- und Few-Shot-Szenarien, in denen das Modell die Bedeutung eines Labels nicht aus zahlreichen Trainingsbeispielen erschließen kann [47, 59]. Die vorliegende Arbeit untersucht dagegen ein vollständig überwachtes Szenario mit mehreren tausend Trainingsinstanzen je Benchmark. Dass der Rubriktext dort gegenüber Frage und Musterlösung keinen zusätzlichen Beitrag leistet, widerspricht diesen Befunden nicht, schränkt aber ihre Übertragbarkeit ein: Der Nutzen der Label-Semantik scheint dort am größten zu sein, wo wenig andere Information über die Aufgabe vorliegt. Das Transferexperiment zeigt zugleich, dass ein überwacht trainiertes Modell die Label-Semantik eines neuen Benchmarks nicht ohne Weiteres nutzt: Auf ASAP-SAS trainiert, folgt es einer dort gelernten Heuristik statt den Rubriktexten des Zielbenchmarks. Ein Zero-Shot-Szenario im Sinne der genannten Arbeiten setzt demnach voraus, dass das Training selbst auf die Nutzung der Rubriktexte hinwirkt, etwa durch Vielfalt der Trainingsaufgaben.

Gegenüber dem Ansatz von Gombert u. a. [22], der die Repräsentation des Antwort-Spans über ein bilineares Netz an den Rubrik-Spans ausrichtet, liefert die vorliegende Arbeit einen Befund zur Bezugsgröße: Auf einem Decoder-only-Backbone und mit konkatenativer Fusion ist es unerheblich, ob der Antwort-Span oder die Sequenzrepräsentation verwendet wird. Die bilineare Fusion selbst wurde nicht untersucht, sodass sich daraus keine Aussage über den Ansatz insgesamt ableiten lässt.

Sprachmodelle als Encoder

Die Arbeiten zur Umwidmung von Decoder-only-Modellen als Encoder sehen in der Aufhebung der kausalen Maske eine Verschiebung gegenüber der Vortrainingsbedingung, der durch ein zusätzliches maskiertes Weitertrainieren [3] oder durch Maßnahmen gegen den Attention-Sink [34] begegnet wird. In der vorliegenden Arbeit wurde die Maske ohne einen solchen Zwischenschritt allein im Rahmen des LoRA-Finetunings auf wenigen tausend Instanzen aufgehoben. Die uneinheitlichen Ergebnisse sind mit der Annahme vereinbar, dass das Modell die Nutzung des beidseitigen Kontexts unter diesen Bedingungen nicht zuverlässig erlernt. Ob ein vorgeschaltetes Weitertrainieren die Wirkung der Maske stabilisiert, ist eine offene Frage.

Der Vorsprung der Decoder-Modelle auf den Transfersplits fügt sich in die Motivation dieser Forschungslinie ein. Er ist mit der Annahme vereinbar, dass das im Vortraining erworbene Wissen eines größeren Sprachmodells vor allem bei ungesehenen Fragen zum Tragen kommt; belegt ist dieser Mechanismus nicht, da sich beide Modellklassen zugleich in mehreren Eigenschaften unterscheiden.

Varianz zwischen Läufen

Der Befund, dass die Wahl der Zufallssaat das Ergebnis eines Finetunings erheblich beeinflusst, ist für andere Aufgaben belegt [43, 14]. Die vorliegende Arbeit bestätigt ihn für ASAG

mit Decoder-only-Modellen: Die Spannweite über drei Saaten beträgt im Median $0{,}036$ und im Maximum $0{,}118$ QWK und übertrifft damit die meisten der untersuchten Architekturunterschiede. Mehrere Muster, die sich auf Einzelläufen deutlich abzeichneten, hielten der Wiederholung nicht stand; im Fall der Bezugsgröße hätten zwei von drei Zufallssaaten als Einzellauf einen Vorteil nahegelegt, den die dritte aufhebt (Abschnitt 5.4.2). Allerdings können auch drei Saaten die Streuung unterschätzen: In einer auf acht Saaten erweiterten Gruppe wuchs die Spannweite von $0{,}023$ auf $0{,}079$ QWK, und ein knapp bestandener Effekt entfiel (Abschnitt 5.2).

Wahl der Metrik

Die Kritik an QWK als alleiniger Kennzahl [15] findet in den Ergebnissen eine konkrete Entsprechung. QWK und Macro-F_1 kommen in 20 von 114 Paarvergleichen zu unterschiedlichen Urteilen (Abschnitt 5.5.3). Die Abweichungen sind dabei nicht zufällig, sondern erklären sich aus der Art der Fehler: Der Aufgabenkontext verringert vor allem weite Fehlbewertungen, die QWK stark gewichtet und Macro-F_1 nicht von benachbarten Verwechslungen unterscheidet. Beide Metriken messen damit verschiedene Eigenschaften eines Bewertungssystems und sollten gemeinsam berichtet werden.

6.3 Methodische Implikationen

Über die einzelnen Forschungsfragen hinaus ergeben sich drei methodische Folgerungen für die Evaluation von ASAG-Systemen.

Erstens sind Vergleiche zwischen Architekturvarianten ohne Wiederholung unter mehreren Zufallssaaten nicht interpretierbar, sobald die Unterschiede in der Größenordnung weniger Hundertstel QWK liegen. Befunde, die eine Auswertungsregel nur wegen ungewöhnlich enger Streuung bestehen, sollten mit zusätzlichen Saaten geprüft werden.

Zweitens entscheidet die Wahl des Evaluationssplits über die Schlussfolgerung. Hätte sich die Auswertung auf die UA-Splits von ASAP-SAS und Beetle beschränkt, wäre der Schluss naheliegend gewesen, dass Decoder-only-Modelle gegenüber Encodern keinen Mehrwert bieten. Ebenso fällt die Leistung ohne Aufgabeninformation nur auf den Transfersplits auf Zufallsniveau, während sie auf UA deutlich darüber bleibt. Aussagen über die Übertragbarkeit eines Systems erfordern daher UQ- und UD-Splits.

Drittens übertrifft die Streuung zwischen den Aufgaben eines Benchmarks alle untersuchten Architektureffekte; auf ASAP-SAS reicht das QWK je Aufgabe über eine Spannweite von $0{,}21$ beziehungsweise $0{,}25$ (Abschnitt 5.5.1). Aggregierte Benchmarkwerte hängen damit stark von der Zusammensetzung der Aufgaben ab und sind bei der Übertragung auf andere Aufgabensammlungen mit Vorsicht zu verallgemeinern.

6.4 Limitationen

Lernrate der Llama-Backbones. Sämtliche Decoder-Läufe verwenden die Lernrate $5 \cdot 10^{-5}$, die in der Referenzimplementierung für Modelle ab sieben Milliarden Parametern vorgesehen ist; für die Llama-Backbones wäre $2 \cdot 10^{-4}$ vorgesehen. Bei dieser Rate gewinnt Llama-3.2-1B auf Beetle-UQ $0{,}096$ QWK, während sich für Llama-3.2-3B ein gemischtes Bild ergibt (Abschnitt 5.4.4). Beide Befunde beruhen auf je einem Lauf. Vergleiche *innerhalb* eines Backbones sind davon nicht betroffen, Vergleiche *zwischen* Modellgrößen dagegen schon; die Arbeit trifft deshalb keine Aussage über den Einfluss der Backbone-Größe.

Unvollständige Auswertung für Mistral-7B. Für das größte Backbone liegen die Fusionsvarianten CONDIFF, CONCAT und GATE auf Beetle und SciEntsBank unter drei Zufallssaaten vor, die Variation der Attention-Maske dagegen nur als Einzelläufe mit drei Anteilen und ohne die vollständig bidirektionale Bedingung. Zwei dieser Läufe waren auffällig schwach; ihre Wiederholung liegt im Bereich der übrigen Läufe (Abschnitt 5.5.2). Auf ASAP-SAS liegen für Mistral-7B sämtliche Maskenbedingungen, aber nur als Einzelläufe vor, und der Transfer wurde mit einer einzigen Saat geprüft. Die Befunde zur Maske stützen sich daher auf die beiden Llama-Größen.

Gemischte Softwareumgebungen. In 21 der 39 Gruppen mit drei Zufallssaaten stammt der Referenzlauf aus einer anderen Softwareumgebung als die beiden Wiederholungen. Für die Vergleiche mit Befund ist damit nur die Richtung, nicht die Höhe der Effekte innerhalb einer Umgebung abgesichert (Abschnitt 5.2).

Herkunft der Rubriktexte. Für Beetle und SciEntsBank liegen keine originalen Bewertungsrichtlinien vor; die verwendeten Rubriktexte wurden mit einem Sprachmodell aus Frage und Musterlösung erzeugt. Die Aussagen zum Beitrag der Rubriktexte (RQ1) gelten daher zunächst für solche abgeleiteten Rubriken. Ob von Lehrkräften verfasste Rubriken, die Kriterien über die Musterlösung hinaus formulieren, einen eigenständigen Beitrag leisten, bleibt offen; ASAP-SAS enthält zwar originale Bewertungsrichtlinien, wurde aber nicht im 2×2-Schema untersucht.

Aufgabenkontext in den Hauptläufen. Die Hauptläufe, auf denen der Vergleich mit dem festen Kopf und sämtliche Befunde zu RQ2 beruhen, enthalten weder Frage noch Musterlösung (Abschnitt 4.1.1). Gerade diese Information erweist sich in Abschnitt 5.3.2 als wirksamster Faktor. Ob die Befunde zu festem Kopf, Fusion, Bezugsgröße und Maske in der stärkeren Konfiguration mit Aufgabenkontext bestehen bleiben, ist nicht geprüft. Zudem werden Frage und Musterlösung gemeinsam zu- oder abgeschaltet, sodass ihr jeweiliger Anteil am Kontext-Effekt nicht zu trennen ist.

Umfang der Datengrundlage. Alle drei Benchmarks sind englischsprachig. Einen UD-Split stellt allein SciEntsBank bereit, sodass alle Aussagen zum Domänentransfer auf einem Benchmark beruhen. ASAP-SAS liegt ausschließlich als UA-Split vor; unter drei Saaten wurden dort nur die kausale und die vollständig bidirektionale Bedingung der beiden Llama-Größen ausgewertet, alle übrigen Bedingungen als Einzelläufe. Die Übertragung zwischen Benchmarks wurde nur in eine Richtung geprüft, von ASAP-SAS auf Beetle und SciEntsBank, und die Längenerklärung für ihr Scheitern ist nicht kausal geprüft. Die Rauschgrenze schließlich beruht auf Gruppen mit drei Saaten; ihre Prüfung mit acht Saaten umfasst eine einzige Gruppe.

Weitere Einschränkungen. Die Modellauswahl erfolgt über die Accuracy auf der Validierungs-

menge und nicht über die primär berichteten Metriken (Abschnitt 4.6). Die Konfiguration der Encoder-Hauptläufe ist nicht durch Dateien belegt, und BERT scheitert auf SciEntsBank unabhängig von der Lernrate. Schließlich wurden paarweise Verfahren und generative Bewertung nicht als eigene Vergleichsbedingungen trainiert (Abschnitt 5.1); der Vergleich beschränkt sich auf Varianten innerhalb der Span-Alignment-Architektur, den festen Klassifikationskopf und die Encoder-Modelle.

6.5 Implikationen für die Praxis

Für den Einsatz rubrik-geleiteter ASAG-Systeme lassen sich aus den Ergebnissen vier Hinweise ableiten. Der wirksamste Hebel ist die Eingabe: Frage und Musterlösung sollten dem Modell zur Verfügung stehen, da ihr Fehlen durch keine der untersuchten Architekturvarianten und auch nicht durch zusätzliche Modellkapazität ausgeglichen wird. Bei der Architektur genügt eine einfache Fusion; aufwendigere Varianten bringen keinen nachweisbaren Vorteil. Die Attention-Maske kann die Leistung erheblich verändern, aber in beide Richtungen, und ist daher je Datensatz auf einem Transfersplit zu validieren. Schließlich spricht die strukturelle Eigenschaft des Span-Alignments, mit wechselnden Bewertungsskalen umzugehen, für seinen Einsatz dort, wo Aufgaben mit unterschiedlicher Stufenzahl in einem Modell bewertet werden sollen. Auf einen neuen Aufgabenbestand sollte ein solches Modell jedoch nicht ohne Training auf passenden Daten übertragen werden: Ein auf ASAP-SAS trainiertes Modell versagt auf Beetle und SciEntsBank vollständig (Abschnitt 5.3.4).

Für die Anforderung der lokalen Betreibbarkeit ist ein Befund aufschlussreich: Llama-3.2-1B erreicht mit Frage, Musterlösung und Antwort auf Beetle-UQ $0{,}602$ QWK und liegt damit praktisch gleichauf mit dem rund sechsmal größeren Mistral-7B, das dort ohne Aufgabenkontext im Mittel über drei Saaten $0{,}605$ erreicht (Abschnitt 5.3.2). Der Wert für Llama-3.2-1B beruht auf einem Einzellauf, und beide Bedingungen unterscheiden sich in der Eingabe; sie deuten aber darauf hin, dass ein kleines, lokal betreibbares Modell mit vollständiger Aufgabeninformation für diese Aufgabe nicht grundsätzlich im Nachteil ist.

7 Fazit und Ausblick

Diese Arbeit hat einen span-basierten Klassifikator für das rubrik-geleitete Bewerten kurzer Schülerantworten auf Decoder-only-Sprachmodelle übertragen und auf drei englischsprachigen Benchmarks mit drei Decoder-Backbones untersucht. Das Modell liest Antwort und Rubriktexte in einer gemeinsamen Sequenz, extrahiert die Rubrikstufen als Spans und bewertet die Antwort durch den Abgleich mit jeder Stufe. Sämtliche inhaltlichen Aussagen beruhen auf Mittelwerten über drei Zufallssaaten und wurden gegen eine empirisch bestimmte Rauschgrenze sowie unter zwei Metriken geprüft. Dieses Kapitel fasst die Antworten auf die beiden Forschungsfragen zusammen (Abschnitt 7.1) und benennt die Fragen, die sich aus ihnen ergeben (Abschnitt 7.2).

7.1 Fazit

RQ1: Übertrifft der span-basierte Klassifikator die Vergleichsbedingungen? Nur unter bestimmten Bedingungen. Gegenüber einem festen Klassifikationskopf, der dieselbe Eingabe erhält, liegt das Span-Alignment mit Llama-3.2-1B auf Beetle-UA um $0{,}088$ QWK vorn; dieser Vorsprung besteht unter beiden Metriken und auch mit acht Zufallssaaten. Auf SciEntsBank fällt der Vorteil beim kleineren Backbone klein aus, beim größeren Backbone ist er auf keinem der beiden Benchmarks nachweisbar. Gegenüber Encoder-Modellen entscheidet der Evaluationssplit: Auf bekannten Fragen ist RoBERTa konkurrenzfähig, auf neuen Fragen liegt Llama-3.2-1B um $0{,}221$ QWK vorn.

Der größte Effekt der Arbeit betrifft nicht die Architektur, sondern die Eingabe. Fehlt dem Modell jede aufgabenbezogene Information, verliert es bis zu $0{,}528$ QWK und fällt auf neuen Fragen auf Zufallsniveau. Die Rubriktexte erweisen sich dabei als austauschbar: Liegen Frage und Musterlösung vor, tragen sie unter QWK nichts mehr bei, und als alleinige Informationsquelle sind sie diesen unterlegen. Für die hier verwendeten, aus Frage und Musterlösung abgeleiteten Rubriken ist die Prämisse, Kriterienbeschreibungen bildeten eine eigenständige Informationsquelle, damit nicht bestätigt.

Die strukturelle Stärke des Span-Alignments, eine zur Laufzeit variable Zahl von Bewertungsstufen zu verarbeiten, ist real: Sie ermöglicht auf ASAP-SAS erst die gemeinsame Modellierung aller Aufgaben und erlaubt es, ein trainiertes Modell ohne Anpassung auf andere Benchmarks anzuwenden. Inhaltlich trägt diese Übertragbarkeit jedoch nicht. Auf ASAP-SAS trainiert, erreichen alle drei Backbones auf Beetle und SciEntsBank nur Zufallsniveau und ordnen nahezu

jede Antwort der untersten Stufe zu. Mit den Daten vereinbar ist die Erklärung, dass die Modelle auf ASAP-SAS die Antwortlänge als Hinweis auf die Stufe gelernt haben.

RQ2: Lassen sich Decoder-only-Modelle an den span-basierten Klassifikator anpassen? Ja, und zwar ohne Änderung ihrer Gewichtsarchitektur: Mit LoRA-Finetuning gelingt das Span-Alignment mit allen drei Backbones auf allen drei Benchmarks. Die Ausgestaltung des Alignments ist dabei unkritisch. Weder die Wahl zwischen CONDIFF, CONCAT, DIFF und GATE noch die Bezugsgröße der Fusion erzeugt auf einem der Backbones einen Unterschied oberhalb der Rauschgrenze; ein auf Llama-3.2-3B beobachteter schwacher Vorteil von GATE bestätigt sich auf Mistral-7B nicht. Die einzige wirksame Variation ist die Attention-Maske, und ihre Wirkung ist nicht verlässlich: Die vollständige Aufhebung der Kausalität kostet Llama-3.2-3B auf Beetle-UQ $0{,}186$ QWK, bringt demselben Backbone auf SciEntsBank-UQ $0{,}060$ und bleibt auf ASAP-SAS ohne Wirkung. Über den Einfluss der Backbone-Größe ist keine Aussage möglich, da die kleineren Backbones bei einem Viertel ihrer vorgesehenen Lernrate trainiert wurden; bei seiner Referenzlernrate liegt Llama-3.2-1B auf Beetle gleichauf mit Mistral-7B.

Methodisch zeigt die Arbeit, wie stark Befunde zu Architekturvarianten von der Messgenauigkeit abhängen. Die Spannweite über drei Zufallssaaten beträgt im Median $0{,}036$ QWK und übertrifft damit die meisten der untersuchten Architekturunterschiede. Mehrere Muster, die sich auf Einzelläufen deutlich abzeichneten, hielten der Wiederholung nicht stand, und ein Effekt, der die Auswertungsregel mit drei Saaten knapp bestand, entfiel mit acht. Hinzu kommt, dass die Wahl des Evaluationssplits und der Metrik einzelne Schlussfolgerungen umkehren kann und dass die Streuung zwischen den Aufgaben eines Benchmarks alle Architektureffekte übertrifft. Für die Evaluation von ASAG-Systemen folgt daraus, Ergebnisse über mehrere Saaten, mehrere Generalisierungsbedingungen und mehrere Metriken zu berichten.

Zusammengefasst ist für rubrik-geleitetes ASAG mit Decoder-Modellen vor allem entscheidend, *welche* Information das Modell erhält, und weniger, *wie* sie architektonisch verarbeitet wird. Eine einfache Fusion genügt; der wirksamste Hebel ist eine vollständige Beschreibung der Aufgabe.

7.2 Ausblick

Aus den Befunden und ihren Grenzen ergeben sich mehrere Fragen, die mit den vorliegenden Läufen nicht zu beantworten sind.

Rubriken von Lehrkräften. Die Austauschbarkeit der Rubriktexte wurde an Rubriken gezeigt, die sprachmodellgestützt aus Frage und Musterlösung erzeugt wurden. Ob von Lehrkräften verfasste Bewertungsrichtlinien, die Kriterien über die Musterlösung hinaus formulieren, einen eigenständigen Beitrag leisten, ist offen. ASAP-SAS bietet dafür originale Richtlinien und wäre der naheliegende Kandidat für das 2×2-Schema aus Abschnitt 5.3.2. Da die Bedingungen ohne Rubriktext den festen Klassifikationskopf erfordern, der an der wechselnden Stufenzahl scheitert, müsste das Schema dort getrennt für die drei- und die vierstufigen Aufgaben durchgeführt werden.

Frage und Musterlösung getrennt. In der verwendeten Implementierung werden Frage und Musterlösung gemeinsam zu- oder abgeschaltet. Eine getrennte Ablation würde klären, ob der Kontext-Effekt auf die Aufgabenstellung, die Musterlösung oder beide zurückgeht.

Architekturbefunde mit Aufgabenkontext. Alle Befunde zu Fusion, Bezugsgröße und Maske beruhen auf Läufen ohne Frage und Musterlösung, also auf einer schwächeren Konfiguration als der besten dieser Arbeit. Ob sie mit vollständiger Aufgabeninformation bestehen bleiben, wäre durch Wiederholung der Hauptläufe mit Aufgabenkontext zu prüfen.

Lernrate je Backbone. Eine belastbare Aussage über den Einfluss der Modellgröße erfordert, jedes Backbone bei einer für es geeigneten Lernrate zu trainieren. Die Einzelläufe bei $2 \cdot 10^{-4}$ zeigen, dass die günstige Rate zudem vom Datensatz abhängt; eine kleine Suche je Backbone und Benchmark unter mehreren Saaten wäre die Voraussetzung für einen fairen Größenvergleich.

Übertragung zwischen Benchmarks. Das Scheitern des Transfers wirft die Frage auf, ob ein Training über mehrere Benchmarks mit unterschiedlichen Rubriken die Modelle dazu bringt, die Rubriktexte tatsächlich zu nutzen, statt aufgabenspezifische Heuristiken wie die Antwortlänge zu lernen. Ebenso offen sind die umgekehrte Richtung, also Training auf Beetle oder SciEntsBank und Test auf ASAP-SAS, sowie eine Auswertung bei kontrollierter Antwortlänge, mit der sich die Längenhypothese direkt prüfen ließe.

Vorbereitung der Maskenaufhebung. In dieser Arbeit wurde die kausale Maske allein im Rahmen des LoRA-Finetunings aufgehoben. Arbeiten zur Umwidmung von Decoder-Modellen als Encoder schalten dem ein eigenes Weitertraining voraus [3]. Ob ein solcher Zwischenschritt die uneinheitliche Wirkung der Maske stabilisiert, ist eine offene Frage.

Bilineare Fusion. Die bilineare Ausrichtung des Antwort-Spans an den Rubrik-Spans nach Gombert u. a. [22] wurde nicht untersucht. Ein direkter Vergleich unter derselben Auswertungsregel würde zeigen, ob die Unempfindlichkeit gegenüber der Fusionsfunktion auch für diesen Mechanismus gilt.

Mehr Zufallssaaten. Die Erweiterung einer Gruppe auf acht Saaten hat gezeigt, dass drei Saaten die Streuung im Einzelfall deutlich unterschätzen. Für künftige Vergleiche liegt es nahe, mehr Saaten zu verwenden oder die Zahl der Saaten an der beobachteten Streuung auszurichten.

Weitere Sprachen und Datensätze. Alle drei Benchmarks sind englischsprachig. Im RUSPAN-Softwareprojekt liegen mit ALICE ein deutschsprachiger und mit PT-ASAG [20] ein portugiesischsprachiger Datensatz vor, die hier nicht ausgewertet wurden. Gerade für den deutschsprachigen Einsatz, für den rubrik-basierte Bewertung zuletzt im Rahmen eines Shared Tasks untersucht wurde [23], wäre die Übertragung der Befunde von Interesse.

Jenseits von ASAG. Das Prinzip, Klassen als Textbeschreibungen in die Eingabe zu legen und als Spans auszulesen, ist nicht an die Bewertung von Schülerantworten gebunden. Es lässt sich auf andere Sequenzklassifikationsaufgaben übertragen, für die Beschreibungen der Klassen vorliegen oder formuliert werden können, etwa die Erkennung von Standpunkten [25]. Ob die hier beobachtete Unempfindlichkeit gegenüber der Fusionsfunktion und die Abhängigkeit der Maskenwirkung vom Datensatz dort ebenso gelten, ist eine offene Frage.

Tabellenverzeichnis

3.1 ASAP-SAS: Aufgabenübersicht mit Fach, Klassenstufe, Label-Skala und Instanzzahlen (berechnet aus `train.csv` / `test_ua.csv`). 28

3.2 Beetle: Instanzzahlen und Fragenzahlen je Split (berechnet aus den bereitgestellten CSV-Dateien). 29

3.3 SciEntsBank: Instanzzahlen und Fragenzahlen je Split (berechnet aus den bereitgestellten CSV-Dateien). 31

3.4 Gegenüberstellung der drei verwendeten ASAG-Benchmarks. 32

4.1 Die vier verglichenen Fusionsmechanismen. d bezeichnet die Modelldimension, d_g die Eingabedimension des Scoring-Kopfs. 42

4.2 Aus dem Anteil ρ resultierende Zahl bidirektionaler Schichten n_{bidir} je Backbone nach Vorschrift (4.15). Die Zeilen sind nach der tatsächlichen Zahl bidirektionaler Schichten geordnet, nicht nach dem nominellen Wert von ρ. Die vollständig bidirektionale Bedingung $\rho = L$ liegt für Llama-3.2-1B und -3B vor, für Mistral-7B nicht; unter drei Zufallssaaten liegt sie für beide Llama-Größen vor. 45

4.3 Trainingskonfiguration der Decoder-Backbones. Die Werte entsprechen der in den ausgewerteten Decoder-Läufen verwendeten Konfiguration; die Abweichungen der Encoder-Baselines beschreibt der folgende Unterabschnitt. 49

4.4 Lernratenvariation der Encoder-Baselines mit CONDIFF-Fusion, QWK. Einzelläufe, Zufallssaat $114\,514$. Die BERT-Läufe verwenden Batchgröße 16 bei $1 \cdot 10^{-5}$ und $2 \cdot 10^{-5}$ sowie 32 bei $3 \cdot 10^{-5}$, die RoBERTa-Läufe durchgängig 16. Die letzte Spalte gibt den Hauptlauf aus Tabelle 5.9 wieder, dessen Lernrate nicht dokumentiert ist. 50

5.1 Spannweite Δ des QWK über drei Zufallssaaten, aggregiert über 93 Zellen. . . 56

5.2 Beetle, Llama-3.2-1B, CONDIFF: Streuung des QWK über acht Zufallssaaten und über die 56 daraus bildbaren Dreiergruppen. *Ursprünglich* bezeichnet die Gruppe aus den Saaten $114\,514$, 1 und 2, die den übrigen Tabellen dieses Kapitels zugrunde liegt. 57

5.3 Paarvergleiche mit CONDIFF, Llama-3.2-1B, Beetle: Urteil mit den drei ursprünglichen und mit allen acht Saaten der CONDIFF-Bedingung, QWK. Die jeweils andere Bedingung beruht auf drei Saaten. Δ wie in den Ergebnistabellen der jeweiligen Abschnitte; „—“ bedeutet nicht nachweisbar. 58

5.4 Span-Alignment (CONDIFF) gegenüber festem Klassifikationskopf, beide mit Rubriktexten und ohne Aufgabenkontext. Mittelwerte über drei Zufallssaaten, Spannweiten in Klammern. *Über Spannweite* bedeutet, dass die Differenz die größere der beiden zellspezifischen Spannweiten übersteigt. Fett: höherer Wert je Zeile. 59
5.5 SciEntsBank, Llama-3.2-1B, fester Klassifikationskopf: Verfügbarkeit von Aufgabenkontext (Frage und Musterlösung) und Rubriktext im vollständigen 2×2-Schema. Mittelwerte über drei Zufallssaaten, Spannweiten in Klammern. . . . 61
5.6 SciEntsBank: Ablation der Rubriktexte ohne Aufgabenkontext, über zwei Modellgrößen. Mittelwerte über drei Zufallssaaten, Spannweiten in Klammern. *Lücke* bezeichnet den Abstand zwischen dem schlechtesten Lauf mit und dem besten Lauf ohne Rubriktext. 63
5.7 Beetle, Llama-3.2-1B, fester Klassifikationskopf, ohne Aufgabenkontext: Ablation der Rubriktexte. Mittelwerte über drei Zufallssaaten, Spannweiten in Klammern. 63
5.8 Beetle, Llama-3.2-1B, fester Klassifikationskopf: Verfügbarkeit von Aufgabenkontext und Rubriktext. Sämtliche Werte bei der Zufallssaat $114\,514$, um die Zellen untereinander vergleichbar zu halten. Für die beiden unteren Zeilen liegen zusätzlich drei Saaten vor (Mittelwerte $0{,}641$ / $0{,}456$ beziehungsweise $0{,}587$ / $0{,}457$). 64
5.9 Encoder-Baselines gegenüber Llama-3.2-1B (jeweils CONDIFF, kausal), QWK. Encoder-Werte sind Einzelläufe einer frühen Trainingswelle, von der nur die Vorhersagen erhalten sind; Llama-Werte sind Mittelwerte über drei Zufallssaaten. ‡Lauf mit Ergebnis auf Zufallsniveau, von der Deutung ausgenommen (Abschnitt 4.6). 66
5.10 Übertragung von ASAP-SAS auf Beetle und SciEntsBank (CONDIFF, kausal), QWK. *Transfer*: ausschließlich auf ASAP-SAS trainiert; *In-Domain*: auf dem Zielbenchmark trainiert. Mittelwerte über drei Zufallssaaten, Spannweiten in Klammern. 67
5.11 ASAP-SAS (UA): Fusionsmechanismen bei kausaler Attention. Einzelläufe, Zufallssaat $114\,514$. Fett: höchster Wert je Spalte innerhalb eines Backbones; die Markierung trifft keine Aussage über die Nachweisbarkeit eines Unterschieds (vgl. Tabelle 5.13). 68
5.12 Beetle und SciEntsBank: Fusionsmechanismen bei kausaler Attention, QWK je Split. Mittelwerte über drei Zufallssaaten; DIFF wurde nur auf Llama-3.2-3B untersucht. Fett: höchster Wert je Spalte innerhalb eines Backbones; die Markierung trifft keine Aussage über die Nachweisbarkeit eines Unterschieds (vgl. Tabelle 5.13). 69
5.13 Unterschied zwischen den Fusionsmechanismen (Spannweite der Mittelwerte von CONDIFF, CONCAT und GATE, bei Llama-3.2-3B zusätzlich DIFF) gegenüber der größten Saat-Spannweite derselben Zellen. 70
5.14 Beste Fusionsvariante je Benchmark, Split und Backbone nach dem Mittelwert über drei Zufallssaaten. Die Rangfolge ist nach Tabelle 5.13 nicht belastbar und wird hier ausschließlich zur Illustration ihrer Beliebigkeit angegeben. 70
5.15 Bezugsgröße der Fusion auf Llama-3.2-3B: Antwort-Span (t-concat) gegenüber Sequenzrepräsentation (CONCAT, CONDIFF). Mittelwerte über drei Zufallssaaten, Spannweiten in Klammern. 71

5.16 ASAP-SAS (UA): Attention-Maske bei CONDIFF-Fusion, sortiert nach der tatsächlichen Zahl bidirektionaler Schichten n_{bidir}. Einzelläufe, Zufallssaat $114\,514$; für die kausale und die vollständig bidirektionale Bedingung der beiden Llama-Größen liegen zusätzlich drei Saaten vor (Tabellen 5.18 und 5.19). Für Mistral-7B stammt die vollständig bidirektionale Bedingung aus einer anderen Softwareumgebung als die übrigen Läufe dieser Spalte. Fett: höchster Wert je Spalte; die Markierung trifft keine Aussage über die Nachweisbarkeit eines Unterschieds. . 73
5.17 Beetle und SciEntsBank: Attention-Maske bei CONDIFF-Fusion, QWK je Split, sortiert nach n_{bidir}. Einzelläufe, Zufallssaat $114\,514$. Für Llama-3.2-3B und Mistral-7B liegen dieselben Bedingungen ebenfalls als Einzelläufe vor; sie werden hier nicht aufgeführt, da sie zu keiner Aussage beitragen, die nicht schon aus der vollständigen Aufhebung folgt. Fett: höchster Wert je Spalte; die Markierung trifft keine Aussage über die Nachweisbarkeit eines Unterschieds. 74
5.18 Vollständig bidirektionale Attention ($n_{\text{bidir}} = L = 28$) gegenüber kausaler Attention, Llama-3.2-3B, CONDIFF-Fusion. Mittelwerte über drei Zufallssaaten, Spannweiten in Klammern. 74
5.19 Vollständig bidirektionale Attention ($n_{\text{bidir}} = L = 16$) gegenüber kausaler Attention, Llama-3.2-1B, CONDIFF-Fusion. Mittelwerte über drei Zufallssaaten, Spannweiten in Klammern. *Über Spannweite* wie in Tabelle 5.4. Mit acht Saaten der kausalen Bedingung ist der Unterschied auf Beetle-UA nicht nachweisbar (Tabelle 5.3). 75
5.20 Effekt der Backbone-Größe bei CONDIFF und kausaler Attention (QWK). Mittelwerte über drei Zufallssaaten; für Mistral-7B auf ASAP-SAS ein Einzellauf. . . 76
5.21 CONDIFF bei der Referenzlernrate $2 \cdot 10^{-4}$ gegenüber den Läufen bei $5 \cdot 10^{-5}$ (Mittelwert und Bereich über drei Zufallssaaten), QWK. Die Läufe bei $2 \cdot 10^{-4}$ beruhen auf je einer Zufallssaat. 77
5.22 ASAP-SAS (UA): QWK je Aufgabe für CONDIFF mit kausaler Attention. Einzelläufe. Fett: höherer Wert je Zeile. 78
5.23 Diagnose der auffälligen Läufe. $\mathit{Acc}_{\mathit{Mehrheit}}$ ist die Accuracy bei konstanter Vorhersage der häufigsten Stufe, $\mathit{QWK}_{\mathit{perm}}$ das QWK bei einer einzelnen zufälligen Permutation der Vorhersagen. *Wdh.*: Wiederholung mit derselben Zufallssaat in der Softwareumgebung mit transformers 4.57.6. 80
5.24 Paarvergleiche mit drei Zufallssaaten, deren Urteil unter QWK und Macro-F_1 verschieden ausfällt. Δ ist die Differenz der Mittelwerte (erste minus zweite Bedingung); das Urteil folgt der Auswertungsregel aus Abschnitt 5.2, angewandt auf die jeweilige Metrik. „—“ bedeutet nicht nachweisbar. Kontext bezeichnet Frage und Musterlösung. 82
5.25 SciEntsBank, Llama-3.2-1B, fester Klassifikationskopf: Anteil weiter Fehler (Vorhersage und Referenz liegen zwei Stufen auseinander) und Accuracy. Mittelwerte über drei Zufallssaaten, beim Anteil weiter Fehler mit Bereich über die Saaten. 83

Abbildungsverzeichnis

2.1 Klassische und rubrik-konditionierte Aufgabenformulierung 7
2.2 Generalisierungsdimensionen UA, UQ und UD 8
2.3 Gewichtsmatrizen von Accuracy und QWK 10
2.4 Rauschgrenze und Interpretierbarkeit von Unterschieden 13
2.5 Drei Architekturfamilien für rubrik-geleitetes Scoring 17
2.6 Aufbau der Transformer-Architektur 19
2.7 Kausale und bidirektionale Attention-Maske 22
2.8 Schichtweise Aufhebung der kausalen Maske 23

3.1 Umfang und Split-Struktur der drei Benchmarks 32

4.1 Gesamtarchitektur des RUSPAN-Systems 36
4.2 Serialisierung und Span-Pooling 39
4.3 Konstruktionen der Fusionsmechanismen 42

5.1 Kontext und Rubriktext im 2×2-Schema 65
5.2 Attention-Maske über den Anteil bidirektionaler Schichten 74
5.3 QWK je Aufgabe auf ASAP-SAS 79

Literatur

[1] Jimmy Lei Ba, Jamie Ryan Kiros und Geoffrey E. Hinton. *Layer Normalization*. arXiv:1607.06450. 2016. arXiv: 1607.06450.

[2] Xiaoyu Bai und Manfred Stede. „A Survey of Current Machine Learning Approaches to Student Free-Text Evaluation for Intelligent Tutoring“. In: *International Journal of Artificial Intelligence in Education* 33.4 (2023), S. 994–1032. DOI: 10.1007/s40593-022-00323-0.

[3] Parishad BehnamGhader u. a. „LLM2Vec: Large Language Models Are Secretly Powerful Text Encoders“. In: *First Conference on Language Modeling (COLM)*. 2024. URL: https://openreview.net/forum?id=IW1PR7vEBf.

[4] Marie Bexte, Andrea Horbach und Torsten Zesch. „Similarity-Based Content Scoring – How to Make S-BERT Keep Up with BERT“. In: *Proceedings of the 17th Workshop on Innovative Use of NLP for Building Educational Applications (BEA 2022)*. Seattle, Washington: Association for Computational Linguistics, 2022, S. 118–123.

[5] Steven Burrows, Iryna Gurevych und Benno Stein. „The Eras and Trends of Automatic Short Answer Grading“. In: *International Journal of Artificial Intelligence in Education* 25.1 (2015), S. 60–117.

[6] Leon Camus und Anna Filighera. „Investigating Transformers for Automatic Short Answer Grading“. In: *Artificial Intelligence in Education: 21st International Conference, AIED 2020, Proceedings, Part II*. Springer, 2020, S. 43–48.

[7] Imran Chamieh, Torsten Zesch und Klaus Giebermann. „LLMs in Short Answer Scoring: Limitations and Promise of Zero-Shot and Few-Shot Approaches“. In: *Proceedings of the 19th Workshop on Innovative Use of NLP for Building Educational Applications (BEA 2024)*. Mexico City, Mexico: Association for Computational Linguistics, 2024, S. 309–315. URL: https://aclanthology.org/2024.bea-1.25/.

[8] Li-Hsin Chang und Filip Ginter. „Automatic Short Answer Grading for Finnish with ChatGPT“. In: *Proceedings of the AAAI Conference on Artificial Intelligence*. Bd. 38. 21. 2024, S. 23173–23181. DOI: 10.1609/aaai.v38i21.30363.

[9] Qian Chen u. a. „Enhanced LSTM for Natural Language Inference“. In: *Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*. Vancouver, Canada: Association for Computational Linguistics, 2017, S. 1657–1668.

[10] Jacob Cohen. „A Coefficient of Agreement for Nominal Scales“. In: *Educational and Psychological Measurement* 20.1 (1960), S. 37–46.

[11] Jacob Cohen. „Weighted Kappa: Nominal Scale Agreement Provision for Scaled Disagreement or Partial Credit“. In: *Psychological Bulletin* 70.4 (1968), S. 213–220.

[12] Alexis Conneau u. a. „Supervised Learning of Universal Sentence Representations from Natural Language Inference Data“. In: *Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. Copenhagen, Denmark: Association for Computational Linguistics, 2017, S. 670–680.

[13] Jacob Devlin u. a. „BERT: Pre-Training of Deep Bidirectional Transformers for Language Understanding“. In: *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (NAACL-HLT)*. Minneapolis, Minnesota: Association for Computational Linguistics, 2019, S. 4171–4186.

[14] Jesse Dodge u. a. *Fine-Tuning Pretrained Language Models: Weight Initializations, Data Orders, and Early Stopping*. arXiv:2002.06305. 2020. arXiv: 2002.06305.

[15] Afrizal Doewes, Nughthoh Arfawi Kurdhi und Akrati Saxena. „Evaluating Quadratic Weighted Kappa as the Standard Performance Metric for Automated Essay Scoring“. In: *Proceedings of the 16th International Conference on Educational Data Mining (EDM 2023)*. 2023. DOI: 10.5281/zenodo.8115784.

[16] Myroslava Dzikovska u. a. „SemEval-2013 Task 7: The Joint Student Response Analysis and 8th Recognizing Textual Entailment Challenge“. In: *Second Joint Conference on Lexical and Computational Semantics (*SEM), Volume 2: Proceedings of the Seventh International Workshop on Semantic Evaluation (SemEval 2013)*. Atlanta, Georgia, USA: Association for Computational Linguistics, 2013, S. 263–274.

[17] Ahmed Elshabrawy u. a. „Enabling Natural Zero-Shot Prompting on Encoder Models via Statement-Tuning“. In: *Findings of the Association for Computational Linguistics: NAACL 2025*. Albuquerque, New Mexico: Association for Computational Linguistics, 2025, S. 8302–8321.

[18] Europäisches Parlament und Rat der Europäischen Union. *Verordnung (EU) 2016/679 des Europäischen Parlaments und des Rates vom 27. April 2016 zum Schutz natürlicher Personen bei der Verarbeitung personenbezogener Daten, zum freien Datenverkehr und zur Aufhebung der Richtlinie 95/46/EG (Datenschutz-Grundverordnung)*. Amtsblatt der Europäischen Union, L 119 vom 4.5.2016, S. 1, https://eur-lex.europa.eu/legal-content/DE/TXT/?uri=CELEX:32016R0679. 2016.

[19] Rafael Ferreira Mello u. a. „Automatic Short Answer Grading in the LLM Era: Does GPT-4 with Prompt Engineering Beat Traditional Models?“ In: *Proceedings of the 15th International Learning Analytics and Knowledge Conference (LAK)*. ACM, 2025, S. 93–103.

[20] Lucas Galhardi u. a. „Portuguese Automatic Short Answer Grading“. In: *Simpósio Brasileiro de Informática na Educação (SBIE)*. 2018.

[21] Zorik Gekhman u. a. „Inside-Out: Hidden Factual Knowledge in LLMs“. In: *Second Conference on Language Modeling (COLM)*. 2025. URL: https://openreview.net/forum?id=f7GG1MbsSM.

[22] Sebastian Gombert u. a. „Are Rubrics All You Need? Towards Rubric-Based Automatic Short Answer Scoring via Guided Rubric-Answer Alignment“. In: *Proceedings of LAK26: 16th International Learning Analytics and Knowledge Conference*. 2026.

[23] Sebastian Gombert u. a. „Report on the BEA 2026 Shared Task on Rubric-Based Short Answer Scoring for German“. In: *Proceedings of the 21st Workshop on Innovative Use of NLP for Building Educational Applications (BEA 2026)*. Association for Computational Linguistics, 2026.

[24] Aaron Grattafiori u. a. *The Llama 3 Herd of Models*. arXiv:2407.21783. 2024. arXiv: 2407.21783.

[25] Momchil Hardalov u. a. „Few-Shot Cross-Lingual Stance Detection with Sentiment-Based Pre-Training“. In: *Proceedings of the AAAI Conference on Artificial Intelligence*. Bd. 36. 10. 2022, S. 10729–10737. DOI: 10.1609/aaai.v36i10.21318.

[26] Neil Houlsby u. a. „Parameter-Efficient Transfer Learning for NLP“. In: *Proceedings of the 36th International Conference on Machine Learning (ICML)*. 2019, S. 2790–2799.

[27] Edward J. Hu u. a. „LoRA: Low-Rank Adaptation of Large Language Models“. In: *The Tenth International Conference on Learning Representations (ICLR)*. 2022.

[28] Albert Q. Jiang u. a. *Mistral 7B*. arXiv:2310.06825. 2023. arXiv: 2310.06825.

[29] Gerd Kortemeyer. „Performance of the Pre-Trained Large Language Model GPT-4 on Automated Short Answer Grading“. In: *Discover Artificial Intelligence* 4.1 (2024).

[30] Yaman Kumar u. a. „Get IT Scored Using AutoSAS – An Automated System for Scoring Short Answers“. In: *Proceedings of the Thirty-Third AAAI Conference on Artificial Intelligence*. 2019, S. 9662–9669.

[31] Chankyu Lee u. a. „NV-Embed: Improved Techniques for Training LLMs as Generalist Embedding Models“. In: *The Thirteenth International Conference on Learning Representations (ICLR)*. 2025. URL: https://openreview.net/forum?id=DtFbrhsXfU.

[32] Xiang Lisa Li und Percy Liang. „Prefix-Tuning: Optimizing Continuous Prompts for Generation“. In: *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers)*. Association for Computational Linguistics, 2021, S. 4582–4597.

[33] Zhaohui Li u. a. „Answer-State Recurrent Relational Network (AsRRN) for Constructed Response Assessment and Feedback Grouping“. In: *Findings of the Association for Computational Linguistics: EMNLP 2023*. Singapore: Association for Computational Linguistics, 2023, S. 3879–3891.

[34] Ziyong Lin u. a. „Look Both Ways and No Sink: Converting LLMs into Text Encoders Without Training“. In: *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*. Vienna, Austria: Association for Computational Linguistics, 2025, S. 22839–22853.

[35] Chun Liu u. a. „LLMEmbed: Rethinking Lightweight LLM's Genuine Function in Text Classification“. In: *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*. Bangkok, Thailand: Association for Computational Linguistics, 2024, S. 7994–8004.

[36] Yinhan Liu u. a. *RoBERTa: A Robustly Optimized BERT Pretraining Approach*. arXiv:1907.11692. 2019. arXiv: 1907.11692.

[37] Kun Luo u. a. „Large Language Models as Foundations for Next-Gen Dense Retrieval: A Comprehensive Empirical Assessment“. In: *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*. Miami, Florida, USA: Association for Computational Linguistics, 2024, S. 1354–1365.

[38] Tom Mitchell u. a. „Towards Robust Computerised Marking of Free-Text Responses“. In: *Proceedings of the 6th International Computer Assisted Assessment (CAA) Conference*. Loughborough: Loughborough University, 2002. URL: https://hdl.handle.net/2134/1884.

[39] Michael Mohler und Rada Mihalcea. „Text-to-Text Semantic Similarity for Automatic Short Answer Grading“. In: *Proceedings of the 12th Conference of the European Chapter of the Association for Computational Linguistics (EACL)*. Association for Computational Linguistics, 2009, S. 567–575.

[40] Lili Mou u. a. „Natural Language Inference by Tree-Based Convolution and Heuristic Matching“. In: *Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers)*. Berlin, Germany: Association for Computational Linguistics, 2016, S. 130–136.

[41] Christopher Ormerod. *Short-Answer Scoring with Ensembles of Pretrained Language Models*. arXiv:2202.11558. 2022. arXiv: 2202.11558.

[42] Dan Qiao u. a. „Decoder-Only LLMs Can Be Masked Auto-Encoders“. In: *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers)*. Vienna, Austria: Association for Computational Linguistics, 2025, S. 713–723.

[43] Nils Reimers und Iryna Gurevych. „Reporting Score Distributions Makes a Difference: Performance Study of LSTM-Networks for Sequence Tagging“. In: *Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. Copenhagen, Denmark: Association for Computational Linguistics, 2017, S. 338–348.

[44] Nils Reimers und Iryna Gurevych. „Sentence-BERT: Sentence Embeddings Using Siamese BERT-Networks“. In: *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*. Hong Kong, China: Association for Computational Linguistics, 2019, S. 3982–3992.

[45] Brian Riordan u. a. „Investigating Neural Architectures for Short Answer Scoring“. In: *Proceedings of the 12th Workshop on Innovative Use of NLP for Building Educational Applications*. Copenhagen, Denmark: Association for Computational Linguistics, 2017, S. 159–168.

[46] Qian Ruan, Ilia Kuznetsov und Iryna Gurevych. „Are Large Language Models Good Classifiers? A Study on Edit Intent Classification in Scientific Document Revisions“. In: *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*. Miami, Florida, USA: Association for Computational Linguistics, 2024, S. 15049–15067. URL: https://aclanthology.org/2024.emnlp-main.839/.

[47] Timo Schick und Hinrich Schütze. „It's Not Just Size That Matters: Small Language Models Are Also Few-Shot Learners“. In: *Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*. Online: Association for Computational Linguistics, 2021, S. 2339–2352. URL: https://aclanthology.org/2021.naacl-main.185/.

[48] Noam Shazeer. *GLU Variants Improve Transformer*. arXiv:2002.05202. 2020. arXiv: 2002.05202.

[49] Mark D. Shermis. „Contrasting State-of-the-Art in the Machine Scoring of Short-Form Constructed Responses“. In: *Educational Assessment* 20.1 (2015), S. 46–65. DOI: 10.1080/10627197.2015.997617.

[50] Shashank Sonkar u. a. „Automated Long Answer Grading with RiceChem Dataset“. In: *Artificial Intelligence in Education (AIED 2024)*. Lecture Notes in Computer Science. Springer, 2024, S. 163–176. DOI: 10.1007/978-3-031-64302-6_12.

[51] Jianlin Su u. a. „RoFormer: Enhanced Transformer with Rotary Position Embedding“. In: *Neurocomputing* 568 (2024), S. 127063.

[52] Md Arafat Sultan, Cristobal Salazar und Tamara Sumner. „Fast and Easy Short Answer Grading with High Accuracy“. In: *Proceedings of the 2016 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (NAACL-HLT)*. Association for Computational Linguistics, 2016, S. 1070–1075.

[53] Chul Sung u. a. „Pre-Training BERT on Domain Resources for Short Answer Grading“. In: *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*. Hong Kong, China: Association for Computational Linguistics, 2019, S. 6071–6075.

[54] The Hewlett Foundation. *The Hewlett Foundation: Short Answer Scoring*. Kaggle-Wettbewerb (ASAP-SAS), https://www.kaggle.com/c/asap-sas. Abgerufen am 05.09.2026. 2012.

[55] Hugo Touvron, Louis Martin, Kevin Stone u. a. *Llama 2: Open Foundation and Fine-Tuned Chat Models*. arXiv:2307.09288. 2023. arXiv: 2307.09288.

[56] UK Department for Education. *Generative Artificial Intelligence (AI) in Education*. Policy paper, https://www.gov.uk/government/publications/generative-artificial-intelligence-in-education/generative-artificial-intelligence-ai-in-education. Zuletzt aktualisiert am 12.08.2025, abgerufen am 05.09.2026. 2025.

[57] Ashish Vaswani u. a. „Attention Is All You Need“. In: *Advances in Neural Information Processing Systems 30 (NIPS 2017)*. 2017, S. 5998–6008.

[58] Guangxuan Xiao u. a. „Efficient Streaming Language Models with Attention Sinks“. In: *The Twelfth International Conference on Learning Representations (ICLR)*. 2024.

[59] Haike Xu u. a. „A Universal Discriminator for Zero-Shot Generalization“. In: *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*. Toronto, Canada: Association for Computational Linguistics, 2023, S. 10559–10575.

[60] Biao Zhang und Rico Sennrich. „Root Mean Square Layer Normalization“. In: *Advances in Neural Information Processing Systems 32 (NeurIPS 2019)*. 2019.

Appendices